

สอนหน่วยเมตรให้โมเดลความลึกจากภาพเดี่ยวด้วย LiDAR ของโทรศัพท์เอง: เปรียบเทียบ Depth Anything V2 แบบ fine-tune กับ แบบ pretrained สำหรับการสร้างแบบจำลองห้อง โดยวัด เทียบกับ laser scanner

1st Panupong Duangdet
dept. Master of Science Programme
Software Engineering for Artificial Intelligence
Bangkok, Thailand
email: dev.panupong@gmail.com
No.68130702310

บทคัดย่อ— โทรศัพท์ส่วนใหญ่ไม่มี LiDAR จึงต้องสแกนห้องด้วยการประมาณความลึกจากภาพเดี่ยว แต่โมเดลสำเร็จรูปที่ให้ความลึกเป็นเมตร เช่น Depth Anything V2 (DA-v2) Metric-Indoor [1] ซึ่งฝึกด้วยภาพสังเคราะห์ ทำให้ห้องที่สร้างได้คลาดเคลื่อน 54.3 ซม. งานวิจัยนี้ศึกษาว่าการปรับจูน (fine-tune) โมเดลดังกล่าวด้วยความลึกจาก LiDAR ของโทรศัพท์เอง โดยค่านำหนักเรียนจาก LiDAR เพียงอย่างเดียว (ใช้ความลึกจากเครื่องสแกนเลเซอร์เฉพาะตอนเลือก checkpoint บนสามห้อง) ทำให้แม่นยำกว่าโมเดลเดิมหรือไม่ เมื่อวัดเทียบกับเครื่องสแกนเลเซอร์ Faro Focus S70 [2] ซึ่งเป็นค่าอ้างอิงของชุดข้อมูล ARKitScenes [3] โดยปรับจูนเฉพาะส่วน DPT head [4] (ตัวถอดรหัสความลึก โดยตรงส่วนเข้ารหัสภาพไว้) ด้วยความลึกจาก LiDAR ของ iPad บน 24 ห้อง ได้โมเดล FT-LiDAR-24 แล้วเปรียบเทียบกับโมเดลเดิมในกระบวนการเดียวกัน คือรวมความลึกรายเฟรมเป็นปริมาตร TSDF (truncated signed distance function) [5] แล้วสร้างเป็นพื้นผิวสามมิติ โดยให้แหล่งความลึกเป็นตัวแปรเดียว บนห้องที่ไม่เคยใช้ฝึก ได้แก่ 6 ห้องที่มีแบบจำลองอ้างอิงจากเครื่องสแกนเลเซอร์ และอีก 20 ห้องที่ประเมินรายเฟรม ผลคือ FT-LiDAR-24 ลดค่า Chamfer distance [6] (ระยะเฉลี่ยถึงจุดที่ใกล้ที่สุดระหว่างพื้นผิวที่สร้างได้กับพื้นผิวอ้างอิง วัดทั้งสองทิศ) จาก 54.3 ซม. เหลือ 15.7 ซม. (ดีขึ้น 3.5 เท่า และดีขึ้นทุกห้อง) และลดค่า AbsRel [7] (ความคลาดเคลื่อนสัมพัทธ์เฉลี่ยของความลึก) จาก 0.410 เหลือ 0.130 (ดีขึ้น 19 จาก 20 ห้อง) โดยไม่ต้องปรับเทียบหรือใช้เซนเซอร์ขณะใช้งาน และการใช้เครื่องสแกนเลเซอร์เป็นครูไม่ได้ดีกว่าอย่างวัดได้ ความคลาดเคลื่อนที่เหลือมาจากสเกลที่กว้างตามมุมมองของแต่ละเฟรม ซึ่งการปรับจูนขนาดไม่ได้ จึงยังด้อยกว่า LiDAR ของ iPad (3.0 ซม.) และยังไม่ถึงระดับความแม่นยำสำหรับดูภาพรวม (พื้นผิวของห้องอย่างน้อย 90% อยู่ภายใน 10 ซม.)

คำสำคัญ—การประมาณความลึกจากภาพเดี่ยว (monocular depth estimation), การเรียนรู้แบบถ่ายโอน (transfer learning), ความลึกแบบเมตริก (metric depth), การใช้ LiDAR เป็นข้อมูลสอน (LiDAR supervision), การรวมความลึกแบบ TSDF (TSDF fusion), การสร้างแบบจำลองสามมิติของห้อง (3D room reconstruction), ARKitScenes

I. บทนำ

การสแกนห้องเป็นแบบจำลองสามมิติเป็นความสามารถที่มีอยู่แล้วใน iPhone Pro และ iPad Pro (เช่น Apple RoomPlan [8]) โดยอาศัยเซนเซอร์ LiDAR วัดความลึกเป็นหน่วยเมตร แต่อุปกรณ์ที่มี LiDAR เป็นส่วนน้อย iPhone รุ่นที่ไม่ใช่ Pro และโทรศัพท์ Android แทบทุกรุ่นไม่มีเซนเซอร์นี้ ทางเลือกของอุปกรณ์เหล่านี้คือการประมาณความลึกจากภาพเดี่ยว (monocular depth

estimation) คือการทำนายความลึกจากภาพสีเพียงภาพเดี่ยว ซึ่งพัฒนาอย่างรวดเร็วตั้งแต่ MiDaS [9] จนถึง Depth Anything [1], [10] ทีมพัฒนานาลิตกัญจึงตั้งชื่อว่า **หากใช้โมเดลจากภาพเดี่ยวแทน LiDAR ห้องที่ได้จะคลาดเคลื่อนกี่เซนติเมตร และยังใช้งานแบบใดได้บ้าง** เกณฑ์วัดมาตรฐานแบบรายภาพ [7] ซึ่งเฉลี่ยความคลาดเคลื่อนของความลึกบนพิกเซลของภาพแต่ละภาพ ตอบคำถามนี้ไม่ได้ และระบบสร้างแบบจำลองแบบครบวงจร (end-to-end) [11]–[13] ก็ตอบไม่ได้ เพราะออกแบบกระบวนการทั้งหมดรอบโมเดลของตนเอง

โมเดลรุ่นใหม่บางตัว [1], [14], [15] ให้ความลึกเป็นเมตรได้โดยตรง แต่ฝึกด้วยภาพที่ไม่ได้มาจากกล้องโทรศัพท์ เช่น DA-v2 Metric-Indoor ฝึกด้วยภาพห้องสังเคราะห์จากชุดข้อมูล HyperSim [16] และในการทดลองของเรา ห้องที่สร้างด้วย DA-v2 Metric-Indoor คลาดเคลื่อนเฉลี่ย 54.3 ซม. วิธีแก้โดยตรงคือการปรับจูน (fine-tune) โมเดลด้วยความลึกจากอุปกรณ์เป้าหมาย คำถามคือข้อมูลสอน (label) นี้จะมาจากไหน ระหว่างเครื่องสแกนเลเซอร์ระดับงานสำรวจ [2] ซึ่งผู้พัฒนาแอปเพียงไม่กี่รายมีใช้ กับ LiDAR ที่มีอยู่แล้วในอุปกรณ์รุ่น Pro ซึ่งแอปเก็บความลึกได้ระหว่างการใช้งานปกติ หากวิธีหลังได้ผล อุปกรณ์ที่มี LiDAR ก็จะเป็นครูสอนอุปกรณ์ที่ไม่มี LiDAR ได้

งานวิจัยนี้จึงตั้งคำถามว่า DA-v2 Metric-Indoor ที่ปรับจูนด้วยความลึกจาก LiDAR ของ iPad โดยค่านำหนักเรียนจาก LiDAR เพียงอย่างเดียว (ความลึกจากเครื่องสแกนเลเซอร์ใช้เฉพาะตอนเลือก checkpoint บนสามห้องที่ไม่ใช่ห้องทดสอบ) แม่นยำกว่าโมเดลเดิมที่ไม่ได้ปรับจูนหรือไม่ เมื่อวัดเทียบกับเครื่องสแกนเลเซอร์ Faro ซึ่งเป็นค่าอ้างอิงของชุดข้อมูล ARKitScenes [3] บนห้องที่ไม่เคยใช้ฝึก โดยมีวัตถุประสงค์ 4 ข้อ ได้แก่ (1) ปรับจูนโมเดลด้วยความลึกจาก LiDAR ของ iPad จำนวน 24 ห้อง ได้โมเดล FT-LiDAR-24 แล้วเปรียบเทียบกับโมเดลเดิมบนห้องที่ไม่เคยใช้ฝึก โดยถือว่าดีกว่าเมื่อค่าเฉลี่ยความคลาดเคลื่อนต่ำกว่า และผลต่างรายห้องมีนัยสำคัญทางสถิติที่ระดับ 5% ตามการทดสอบ Wilcoxon signed-rank แบบ exact [17] (2) วัดว่าแหล่งของข้อมูลสอนมีผลหรือไม่ โดยเปรียบเทียบข้อมูลสอนจาก Faro กับจาก LiDAR บน 10 ห้องเดียวกัน (FT-Faro-10 กับ FT-LiDAR-10) เปรียบเทียบข้อมูลสอน

จาก LiDAR 10 ห้องกับ 24 ห้อง และเปรียบเทียบกับโมเดลที่ใช้ความยาวโฟกัสของกล้องแทนข้อมูลสอนจากโดเมนเป้าหมาย (Depth Pro [15]) (3) ระบุตำแหน่งของ FT-LiDAR-24 เทียบกับแหล่งความลึกที่ใช้ได้ขณะใช้งาน ได้แก่ LiDAR ของ iPad และโมเดลความลึกสัมพัทธ์ที่ปรับสเกลรายละเอียดด้วยจุดเบาบาง (sparse points) หรือปรับสเกลครั้งเดียวต่อห้อง และ (4) หาที่มาของความคลาดเคลื่อนที่การปรับจนแก้ไม่ได้ โดยหาสเกลความลึกที่เหมาะสมกับแต่ละเฟรม แล้วทดสอบว่าสเกลนั้นเปลี่ยนตามเวลา ซึ่งบ่งชี้การสะสมความคลาดเคลื่อน (drift) หรือเปลี่ยนตามสิ่งที่อยู่ในภาพ

ทุกการเปรียบเทียบวัดสองแบบ แบบแรกวัดเป็นแบบจำลองห้อง (mesh) ด้วย Chamfer distance [6] คือระยะเฉลี่ยจากแต่ละพื้นผิวถึงจุดที่ใกล้ที่สุดของอีกพื้นผิว และด้วย F-score ที่ 5 ซม. (F@5 cm) [18] ซึ่งรวมสัดส่วนของพื้นผิวที่สร้างได้ที่อยู่ภายใน 5 ซม. จากพื้นผิวอ้างอิง กับสัดส่วนของพื้นผิวอ้างอิงที่ถูกสร้างขึ้นภายใน 5 ซม. แบบที่สองวัดรายละเอียดด้วย AbsRel [7] คือความคลาดเคลื่อนสัมพัทธ์เฉลี่ยของความลึก และด้วยสัดส่วนของพิกเซลที่ความลึกที่ทำนายต่างจากค่าจริงไม่เกิน 1.25 เท่า (ไม่ว่าจะมากหรือน้อยกว่าค่าจริง) ซึ่งเรียกว่า within-1.25× [7] สำหรับวัตถุประสงค์ข้อ (3) สัดส่วนของพื้นผิวอ้างอิงที่ถูกสร้างขึ้นภายใน 2, 5 และ 10 ซม. ใช้แทนความแม่นยำที่งานวัดเพื่อปรับปรุงห้อง งานวางเฟอร์นิเจอร์ และงานดูภาพรวมของห้องต้องการ ตามลำดับ และถือว่ารองรับงานนั้นได้เมื่อสัดส่วนนี้ถึง 90 %

ขอบเขตของงานวิจัยมีดังนี้ ข้อมูลเป็นห้องในบ้านจากชุดข้อมูล ARKitScenes ที่ถ่ายด้วย iPad Pro รุ่นเดียว (ภาพสีขนาด 640×480 พิกเซล และความลึกจาก LiDAR ขนาด 256×192 พิกเซล) ค่าอ้างอิงคือความลึกจาก Faro ที่มากับชุดข้อมูล และไม่ใช่ LiDAR ของ iPad เป็นค่าอ้างอิง การปรับจนทำเฉพาะส่วน DPT head [4] ซึ่งเป็นตัวถอดรหัสความลึกของ DA-v2 Metric-Indoor ขนาด Large ด้วยสูตรการฝึกเดียว โดยตรงส่วนเข้ารหัสภาพไว้ ประเมินผลบนห้องทดสอบ 6 ห้องทั้งแบบแบบจำลองห้องและแบบรายละเอียด และอีก 20 ห้องแบบรายละเอียดเท่านั้น ทุกห้องไม่ซ้ำกับห้องที่ใช้ฝึกหรือใช้เลือก checkpoint ทุกแหล่งความลึกผ่านกระบวนการแบบออฟไลน์เดียวกัน คือความลึกรายละเอียด การปรับสเกล การรวมเป็นปริมาตร TSDF (truncated signed distance function) [5] และการสร้างพื้นผิว แหล่งความลึกจึงเป็นตัวแปรเดียว นอกจากนี้ ทุกแหล่งและค่าอ้างอิงใช้ตำแหน่งกล้องชุดเดียวกัน ซึ่งบันทึกโดย ARKit ความคลาดเคลื่อนของตำแหน่งกล้องจึงไม่อยู่ในผลการวัด สิ่งอยู่นอกขอบเขต ได้แก่ ระบบสร้างแบบจำลองที่เรียนรู้ทั้งกระบวนการ [11]–[13] กล้องโทรศัพท์รุ่นอื่นรวมถึง Android การประมวลผลแบบเรียลไทม์บนอุปกรณ์ และการประมาณตำแหน่งกล้อง

ประโยชน์ที่คาดว่าจะได้รับสอดคล้องกับวัตถุประสงค์ที่ละข้อ ข้อแรก ผู้พัฒนาแอปจะรู้ว่าข้อมูลที่เก็บได้อยู่แล้ว จากผู้ใช้อุปกรณ์รุ่น Pro ช่วยให้การสแกนห้องบนอุปกรณ์ที่ไม่มี LiDAR ดีขึ้นหรือไม่ โดยไม่ต้องปรับเทียบหรือใช้เซ็นเซอร์เพิ่มขณะใช้งาน ข้อสอง จะรู้ว่าการสร้างข้อมูลสอนจำเป็นต้องใช้เครื่องสแกนเลเซอร์หรือไม่ ข้อสาม จะรู้ว่าการปรับจนแก้ไม่ได้มี LiDAR รองรับงานแบบใดบ้าง พร้อมได้กระบวนการที่ประเมินแหล่งความลึกใหม่ได้ด้วยการแก้ค่าตั้งค่าเพียงรายการเดียว และข้อสี่ จะรู้ว่าการลงทุนพัฒนาส่วนใดต่อ ระหว่างสเกลรายละเอียด ข้อมูลฝึก หรือขนาดโมเดล

II. ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

บทนี้อธิบายทฤษฎีที่งานวิจัยนี้อาศัย ได้แก่ เหตุใดภาพเดียวจึงบอกความลึกเป็นเมตรไม่ได้ โมเดลที่เรานำมาปรับจนมีโครงสร้างและฝึกมาอย่างไร และความลึกรายละเอียดกลายเป็นแบบจำลองห้องได้อย่างไร พร้อมทั้งวางตำแหน่งของงานนี้เทียบกับงานก่อนหน้านี้ในแต่ละประเด็น

A. การประมาณความลึกจากภาพเดียว

ตามแบบจำลองกล้องรูเข็ม (pinhole camera) [19] ขนาดของวัตถุในภาพแปรผันตามขนาดจริงของวัตถุ หารด้วยระยะห่าง แล้วคูณด้วยความยาวโฟกัสของเลนส์ ห้องที่ใหญ่เป็นสองเท่าเมื่อมองจากระยะไกลเป็นสองเท่า จึงให้ภาพเหมือนกันทุกประการ เราคาดเดาเพียงอย่างเดียวจึงหาความลึกเป็นเมตรจากภาพเดียวไม่ได้ โครงข่ายประสาทเทียมทำได้เพียงอนุมานจากสิ่งที่เรียนรู้มา เช่น ความสูงปกติของประตูหรือโต๊ะ และแม้แต่ข้อมูลเหล่านี้ก็ขึ้นกับความยาวโฟกัส เพราะวัตถุเดียวกันที่ระยะเดียวกันจะดูใหญ่ขึ้นเมื่อใช้เลนส์ที่ยาวขึ้น Eigen และคณะ [7] เป็นงานแรก ๆ ที่ใช้โครงข่ายเชิงลึกกับปัญหานี้ และเพราะความกำกวมดังกล่าว จึงวัดความคลาดเคลื่อนบนลอการิทึมของความลึก ในรูปแบบที่แยกความคลาดเคลื่อนของสเกลโดยรวมของฉากออกจากความคลาดเคลื่อนของรูปทรง ฟังก์ชันสูญเสีย (loss) แบบไม่ขึ้นกับสเกลบนลอการิทึมในรูปแบบถ่วงน้ำหนัก เรียกว่า SiLog ใช้ฝึกทั้ง ZoeDepth [14] และโมเดลที่ปรับปรุงในงานนี้

โมเดลแบ่งได้เป็นสองกลุ่มตามวิธีจัดการกับสเกลที่หายไป กลุ่มแรกคือโมเดลความลึกสัมพัทธ์ (relative) ซึ่งไม่พยายามหาสเกล MiDaS [9] ฝึกโครงข่ายเดียวด้วยชุดข้อมูลหลายชุดที่วัดความลึกด้วยเซนเซอร์และหน่วยต่างกัน ซึ่งทำได้ก็ต่อเมื่อฟังก์ชันสูญเสียไม่สนใจสเกลและค่าเลื่อน (offset) ของแต่ละภาพ ผลลัพธ์จึงเป็นส่วนกลับของความลึก (disparity) ที่ถูกต้องเฉพาะเมื่อรู้สเกลและค่าเลื่อนของภาพนั้น ต้องหาตัวเลขสองตัวนี้จากข้อมูลอื่นก่อนจึงจะได้ความลึกเป็นเมตร Depth Anything [10] และ Depth Anything V2 [1] (DA-v2) ให้ผลลัพธ์แบบเดียวกัน แต่ฝึกด้วยภาพจำนวนมากกว่ามาก กลุ่มที่สองคือโมเดลความลึกแบบเมตริก (metric) ซึ่งให้ความลึกเป็นเมตรโดยตรง โดยเรียนรู้สเกลจากข้อมูลที่มีค่าความลึกกำกับ ZoeDepth [14] ต่อส่วนทำนายแบบเมตริกที่ปรับปรุงด้วย NYU Depth v2 [20] และ KITTI [21] เข้ากับโมเดลความลึกสัมพัทธ์ ส่วน DA-v2 มีรุ่นเมตริกที่ปรับปรุงจากรุ่นสัมพัทธ์ของตนเอง โดยรุ่นในอาคาร (DA-v2 Metric-Indoor) ปรับปรุงด้วยภาพห้องที่เรนเดอร์จากชุดข้อมูล Hypersim [16] อีกแนวทางหนึ่งจัดการกับความยาวโฟกัสโดยตรง Metric3D [22] แปลงทุกภาพให้เป็นภาพจากกล้องมาตรฐานที่มีความยาวโฟกัสคงที่ UniDepth [23] ทำนายพารามิเตอร์ของกล้องไปพร้อมกับความลึก และ Depth Pro [15] ประมาณความยาวโฟกัสเองเมื่อไม่ได้รับค่านีมา งานเหล่านี้รายงานผลเป็นตัวชี้วัดรายละเอียดบนชุดทดสอบมาตรฐาน เช่น NYU Depth v2 และ KITTI ตัวชี้วัดดังกล่าวเฉลี่ยจากภาพที่เป็นอิสระต่อกัน จึงไม่บอกว่าเป็นสเกลของโมเดลคงที่หรือไม่ ตลอดเฟรมของการสแกนครั้งเดียว ซึ่งเป็นสิ่งสำคัญเมื่อนำเฟรมทั้งหมดมารวมเป็นห้องเดียว

B. โครงสร้างและการฝึกของ Depth Anything V2

DA-v2 ประกอบด้วยส่วนเข้ารหัสภาพ (encoder) และส่วนถอดรหัสความลึก (decoder) ส่วนเข้ารหัสคือ DINOv2 [24] ซึ่งเป็น vision transformer (ViT) [25] โดยแบ่งภาพเป็นชิ้นสี่เหลี่ยมเล็ก ๆ (patch) แล้วให้แต่ละชิ้นดึงข้อมูลจากชิ้นอื่นทุกชิ้นผ่านกลไกที่เรียกว่า self-attention DINOv2 ผ่านการฝึกล่วงหน้าโดยไม่ใช้ข้อมูลกำกับ บนชุดภาพขนาดใหญ่ที่คัดสรรแล้ว เพื่อให้คุณลักษณะ (feature) ที่ได้ใช้กับงานได้หลากหลาย ส่วนถอดรหัสคือ Dense Prediction Transformer (DPT) [4] ซึ่งนำคุณลักษณะจากหลายชั้นของส่วนเข้ารหัสมาประกอบกลับเป็นแผนที่คล้ายภาพที่หลายความละเอียด แล้วรวมเป็นแผนที่ความลึกแบบหนาแน่นเพียงแผนที่เดียว โค้ดของโมเดลแบ่งส่วนถอดรหัสเป็น neck ซึ่งทำหน้าที่ประกอบและรวมคุณลักษณะ กับ head ซึ่งให้ค่าความลึกออกมา ในรายงานนี้คำว่า DPT head หมายถึงทั้งสองส่วน เช่นเดียวกับในบทนำ

DA-v2 เองก็ฝึกด้วยครู (teacher) กล่าวคือ ฝึกโมเดลขนาดใหญ่ด้วยภาพสังเคราะห์ซึ่งมีความลึกที่แม่นยำก่อน จากนั้นให้โมเดล

นี้กำกับความลึกให้ภาพจริงที่ไม่มีคามลึกราว 62 ล้านภาพ แล้วจึงให้โมเดลที่เผยแพร่เรียนรู้จากค่ากำกับที่โมเดลสร้างขึ้นนี้ ซึ่งเรียกว่า pseudo-label [1] ผู้พัฒนา DINOv2 รายงานว่าทำนายความลึกได้ดีแม้ครึ่งส่วนเข้ารหัสไว้ และฝึกเฉพาะส่วนถอดรหัส DPT ที่ต่อต้านบน [24] การนำโมเดลที่ฝึกกับงานหรือโดเมนหนึ่งมาปรับใช้กับอีกงานหรือโดเมนหนึ่ง เช่นนี้เรียกว่าการเรียนรู้แบบถ่ายโอน (transfer learning) [26] การฝึกเฉพาะส่วนถอดรหัสแบบที่งานนี้ทำให้หน่วยความจำน้อยกว่ามาก และยังคงคุณลักษณะทั่วไปที่ส่วนเข้ารหัสเรียนรู้มาจากภาพหลายล้านภาพไว้

C. การฝึกด้วยความลึกจากเซนเซอร์

โมเดลความลึกแบบมีผู้สอน (supervised) ใช้ความลึกที่วัดจากเซนเซอร์เป็นข้อมูลสอนมานานแล้ว โดยไม่ต้องให้คนกำกับ ตัวอย่างเช่น NYU Depth v2 ให้ความลึกในอาคารจากกล้อง Microsoft Kinect [20] KITTI ให้ความลึกบนถนนจากเครื่องสแกนเลเซอร์ที่ติดบนรถยนต์ [21] และ Eigen และคณะ [7] ฝึกด้วยทั้งสองชุด สิ่งที่แตกต่างกันระหว่างงานเหล่านี้คือคุณภาพของเซนเซอร์ บน iPhone Pro และ iPad Pro นั้น ARKit รวมค่าที่วัดได้จาก LiDAR กับภาพสีเป็นแผนที่ความลึกขนาด 256×192 พิกเซล พร้อมค่าความเชื่อมั่นของทุกพิกเซล [3] งานที่ทดสอบ LiDAR นี้เทียบกับวิธีสำรวจที่เป็นที่ยอมรับพบว่า แม่นยำราว 1 ซม. กับวัตถุที่ใหญ่กว่า 10 ซม. [27] และเพียงพอสำหรับการทำแผนที่สถาปัตยกรรมอย่างรวดเร็วที่มาตราส่วน 1:200 [28] จึงมีเหตุผลที่จะใช้เป็นครู ARKitScenes [3] ให้ความลึกนี้คู่กับความลึกจากเครื่องสแกนเลเซอร์ระดับงานสำรวจ Faro [2] ของห้องเดียวกัน โดยจัดให้ตรงกับเฟรมกล้องเดียวกัน และใช้ความลึกจาก Faro เป็นค่าอ้างอิง ในโจทย์ที่เพิ่มความละเอียดของความลึกจาก LiDAR โดยอาศัยภาพสี Prompt Depth Anything [29] ซึ่งเป็นงานที่ใช้ข้อมูลใกล้เคียงกับงานนี้ที่สุด ก็ป้อนความลึกจาก LiDAR ของ iPhone เข้าโมเดล Depth Anything เป็นข้อมูลนำเข้าเพิ่มเติมเช่นกัน ในทั้งสองงาน LiDAR ต้องมีอยู่ทุกครั้งที่โมเดลทำงาน ส่วนงานนี้ใช้ LiDAR เฉพาะตอนฝึก โมเดลที่นำไปใช้จึงต้องการเพียงภาพสี คำถามว่าครุที่มีสัญญาณรบกวนมากกว่านี้ ช่วยโมเดลขนาดใหญ่ที่ผ่านการฝึกล่วงหน้าได้เท่ากับเครื่องสแกนเลเซอร์หรือไม่ เมื่อตัดสินทั้งคู่ด้วยค่าอ้างอิงจากเลเซอร์ที่เป็นอิสระ คือเรื่องของวัตถุประสงค์ข้อ (1) และ (2)

D. จากแผนที่ความลึกสู่แบบจำลองห้อง

การรวมเฟรมต้องรู้ท่าทางกล้อง (camera pose) ของแต่ละเฟรมคือตำแหน่งและทิศทางของกล้อง ARKit ติดตามท่าทางกล้องด้วย visual-inertial odometry (VIO) ซึ่งติดตามจุดเด่นในภาพจากเฟรมหนึ่งไปอีกเฟรมหนึ่ง แล้วรวมกับเซนเซอร์วัดการเคลื่อนที่ของอุปกรณ์ [30] เนื่องจากเซนเซอร์วัดการเคลื่อนที่วัดความเร็วเป็นหน่วยเมตริก จุดที่ติดตามได้จึงมีตำแหน่งเป็นเมตร จุดเบาบาง (sparse points) เหล่านี้จึงให้สเกลและค่าเลื่อนที่โมเดลความลึกสัมพันธ์ขาดไปได้ที่ละเฟรม แนวคิดการใช้ความลึกจากโครงข่ายร่วมกับเรขาคณิตแบบเบาบางของระบบติดตามมีมาตั้งแต่ CNN-SLAM [31] และ MonoSDF [32] ก็หาสเกลและค่าเลื่อนของทุกภาพก่อนนำความลึกจากภาพเดียวไปช่วยสร้างพื้นผิว การปรับสเกลด้วยจุดเบาบางของงานนี้ในหัวข้อ III-C ก็อยู่ในแนวทางนี้

ขั้นต่อมาคือการสร้างห้อง ซึ่งทำโดยรวมความลึกเป็น truncated signed distance function (TSDF) [5] โดยแบ่งพื้นที่เป็นลูกบาศก์เล็ก ๆ เรียกว่า voxel แต่ละ voxel เก็บระยะถึงพื้นผิวที่ใกล้ที่สุดที่สังเกตได้ เป็นบวกเมื่ออยู่หน้าพื้นผิวและเป็นลบเมื่ออยู่หลังพื้นผิว ตัดทิ้ง (truncate) เมื่อไกลเกินไม่กี่ voxel แล้วเฉลี่ยค่านี้จากทุกเฟรมที่มองเห็น voxel นั้น จากนั้นจึงสกัดพื้นผิวตรงตำแหน่งที่ค่าเฉลี่ย

เปลี่ยนเครื่องหมาย ด้วยอัลกอริทึม marching cubes [33] Kinect-Fusion [34] ทำให้การรวมแบบนี้ทำงานได้แบบเรียลไทม์ กับความลึกจาก Kinect และงานนี้ใช้การทำงานที่มีอยู่ใน Open3D [35] การเฉลี่ยช่วยลดสัญญาณรบกวนที่สุมเปลี่ยนไปในแต่ละเฟรม แต่เฟรมที่มีสเกลไม่ตรงกันจะวางผนังเดียวกันไว้ที่ระยะต่างกัน ค่าเฉลี่ยจึงทำให้ผนังเบลอหรือหนาขึ้น ความคงที่ของสเกลระหว่างเฟรม ซึ่งตัวชี้วัดรายภาพไม่ได้วัด จึงกำหนดคุณภาพของห้อง นอกจากนี้ การรวมแบบ TSDF ไม่ขึ้นกับว่าความลึกเป็นเมตริกนั้นมาจากแหล่งใด จึงเป็นขั้นตอนคงที่ที่ยุติธรรมกับแหล่งความลึกทุกแหล่ง

ส่วนระบบสร้างแบบจำลองที่เรียนรู้ทั้งกระบวนการ (learned reconstruction) จะแทนที่บางขั้นตอนข้างต้น ด้วยโครงข่ายประสาทเทียม Atlas [11] ทำนาย TSDF โดยตรง จากคุณลักษณะของภาพหลายภาพที่รู้ท่าทางกล้อง NeuralRecon [12] ทำแบบเดียวกันที่ละส่วนและแบบเรียลไทม์ และ SimpleRecon [13] ประเมินความลึกจากหลายเฟรมข้างเคียง ก่อนรวมด้วยวิธีดั้งเดิม ทุกงานประเมินผลบน ScanNet [36] ซึ่งเป็นชุดการสแกนภาพสีและความลึกในอาคารขนาดใหญ่ แต่ละงานต้องใช้หลายเฟรมต่อการทำนายหนึ่งครั้ง และใช้โครงข่ายที่ฝึกมาสำหรับกระบวนการของตนเอง จึงตอบคำถามต่างจากงานนี้ ซึ่งถามว่าโมเดลจากภาพเดียวให้ห้องแบบใด เมื่อส่วนอื่นของกระบวนการไม่เปลี่ยน งานนี้จึงไม่เปรียบเทียบกับงานกลุ่มนี้

E. การวัดคุณภาพของแบบจำลองห้อง

แบบจำลองห้องที่สร้างได้จะเทียบกับพื้นผิวอ้างอิงผ่านระยะระหว่างจุดที่สุมบนพื้นผิวทั้งสอง Chamfer distance [6] เฉลี่ยระยะจากแต่ละจุดถึงจุดที่ใกล้ที่สุดของอีกพื้นผิวทั้งสองทิศทาง ส่วน Tanks and Temples [18] กำหนดระยะเกณฑ์ไว้ แล้วรายงานความแม่นยำ (precision) คือสัดส่วนของพื้นผิวที่สร้างได้ที่อยู่ภายในระยะเกณฑ์จากพื้นผิวอ้างอิง ความครบถ้วน (recall) คือสัดส่วนของพื้นผิวอ้างอิงที่อยู่ภายในระยะเกณฑ์จากพื้นผิวที่สร้างได้ และค่าเฉลี่ยฮาร์โมนิกของทั้งสอง คือ F-score ระยะเกณฑ์ทำให้คะแนนผูกกับการใช้งาน ซึ่งเป็นวิธีที่พบทั่วไปใช้เชื่อมระยะ 2, 5 และ 10 ซม. กับงานวัดเพื่อปรับปรุงห้อง งานวางเฟอร์นิเจอร์ และงานดูภาพรวมของห้อง สำหรับการวัดรายเฟรม งานนี้ใช้ AbsRel และ within-1.25× จากงานด้านการประมาณความลึกจากภาพเดียว [7]

F. ตำแหน่งของงานวิจัยนี้

โดยสรุป งานก่อนหน้ารายงานความแม่นยำรายภาพของโมเดลความลึกบนชุดทดสอบมาตรฐาน ปรับโมเดลเมตริกด้วยข้อมูลกำกับจากภาพสังเคราะห์หรือจากเซนเซอร์ของชุดข้อมูลสาธารณะ ป้อน LiDAR ของอุปกรณ์พกพาเข้าโมเดลขณะใช้งาน หรือทดสอบตัว LiDAR ของอุปกรณ์พกพาเองเทียบกับวิธีสำรวจ เราไม่พบงานที่รวมประเด็นเหล่านี้ไว้แบบงานนี้ กล่าวคือ ใช้ LiDAR ของอุปกรณ์ผู้บริโภคเป็นครูเฉพาะตอนฝึก เปรียบเทียบกับการใช้เครื่องสแกนเลเซอร์ระดับงานสำรวจเป็นครูบนห้องชุดเดียวกัน และตัดสินทั้งคู่ด้วยค่าอ้างอิงจากเลเซอร์ที่เป็นอิสระ ทั้งเป็นเซนติเมตรบนแบบจำลองห้องและแบบรายเฟรม

III. วิธีดำเนินการวิจัย

งานวิจัยนี้เปรียบเทียบแหล่งความลึกภายในกระบวนการสร้างแบบจำลองห้องที่คงที่เพียงกระบวนการเดียว (รูปที่ 1) สำหรับทุกห้องและทุกแหล่งความลึก กระบวนการจะ (1) อ่านภาพสีและท่าทางกล้อง (2) สร้างแผนที่ความลึกของทุกเฟรมจากแหล่งความลึกนั้น (3) แปลงความลึกเป็นเมตร หากแหล่งนั้นไม่ได้ให้ค่าเป็นเมตร (4) รวมทุกเฟรมเป็นแบบจำลองห้อง (mesh) และ (5) วัดทั้งความลึกรายเฟรมและแบบจำลองห้องเทียบกับค่าอ้างอิงจาก Faro ระหว่างแถวต่าง ๆ ของตารางผล มีเพียงขั้นที่ (2) และ (3) ที่เปลี่ยน โดยแต่ละขั้นเลือกได้ด้วยค่าตั้ง

ตารางที่ I

ห้องทดสอบ ประเมินทั้งแบบสามมิติและแบบรายเฟรม จำนวนเฟรม คือจำนวนเฟรมของ Faro ที่ใช้ประเมินทุกแถว

รหัสการสแกน	ห้อง	ขนาด (ม.)	จำนวนเฟรม
42444474	ครัวและห้องทานข้าว มีกระจก (ห้องที่ใช้ระหว่างพัฒนา)	$9.9 \times 5.1 \times 4.2$	236
47333774	ห้องนอนทั่วไป	$5.1 \times 4.9 \times 3.3$	375
47115299	ห้องนั่งเล่นขนาดใหญ่	$8.1 \times 6.1 \times 2.5$	324
42897743	ห้องน้ำ (กระจกเงา กระจกเงา)	$8.0 \times 3.4 \times 3.6$	448
47429736	ห้องนอนที่มีตู้เสื้อผ้า	$6.6 \times 6.4 \times 2.7$	504
45261556	ครัว (ตู้ครัวบาน)	$7.1 \times 6.1 \times 2.4$	465

ค่าเพียงรายการเดียว ส่วนขั้นตอนหลังจากนั้นใช้โค้ดเดียวกันและค่าตั้งค่าเดียวกันทุกครั้ง โมเดลที่ปรับปรุงแล้วเข้าสู่กระบวนการที่ขั้น (2) ในฐานะแหล่งความลึกแหล่งหนึ่งตามปกติ บทนี้อธิบายข้อมูล แต่ละขั้นตอน การปรับปรุง ตัวชี้วัดและสถิติ และการทดลอง

A. ข้อมูล ห้อง และค่าอ้างอิง

ARKitScenes [3] ให้ข้อมูลของห้องเดียวกันหลายอย่าง ได้แก่ วิดีโอสีจาก iPad Pro (ขนาด 640×480 พิกเซล) ความลึกจาก LiDAR ที่ ARKit สร้างขึ้น (ขนาด 256×192 พิกเซล พร้อมค่าความเชื่อมั่นระดับต่ำ กลาง หรือสูงของทุกพิกเซล) ทำทางกล้องของทุกเฟรมจาก visual-inertial odometry ของ ARKit และความลึกจากเครื่องสแกนเลเซอร์ Faro [2] ที่จัดให้ตรงกับทำทางกล้องเหล่านั้น (ขนาด 1920×1440 พิกเซล ประมาณสี่เฟรมต่อวินาที) **ค่าอ้างอิงคือความลึกจาก Faro ตามที่ชุดข้อมูลให้มา** สำหรับการประเมินรายเฟรม ความลึกนี้ถูกลดขนาดเป็น 256×192 โดยใช้พิกเซลที่ใกล้ที่สุด ค่าอ้างอิงทุกค่าจึงเป็นค่าที่วัดได้จริง สำหรับการประเมินแบบสามมิติ เนื่องจากชุดข้อมูลไม่มีแบบจำลองจากเลเซอร์ให้ เราจึงรวมความลึกจาก Faro ของทุกเฟรมด้วย voxel ขนาด 1 ซม. ครั้งเดียวต่อห้อง เป็นแบบจำลองอ้างอิง ด้วยวิธีรวมในหัวข้อ III-D เนื่องจากแบบจำลองอ้างอิงและแหล่งความลึกทุกแหล่งใช้ทำทางกล้องชุดเดียวกัน ความคลาดเคลื่อนของทำทางกล้องจึงไม่อยู่ในผลการวัดและความต่างทุกอย่างระหว่างแฉกมาจากแหล่งความลึกเท่านั้น งานนี้ไม่ใช่ LiDAR ของ iPad เป็นค่าอ้างอิงเลย

ห้องทดสอบทั้งหกห้อง (ตารางที่ I) ครอบคลุมห้องนอนทั่วไป ห้องขนาดใหญ่ และห้องที่มีกระจกเงาหรือพื้นผิวมันวาว ห้อง 42444474 ถูกใช้ระหว่างการพัฒนาระบบการ ผลของห้องนี้จึงไม่นับเป็นข้อมูลที่กันไว้ ผลรายห้องจึงช่วยให้ผู้อ่านตรวจสอบข้อสรุปทุกข้อกับอีกห้าห้องที่เหลือได้ ห้องสำหรับการปรับปรุงสุ่มเลือก (seed 0) จากการสแกนใน ARKitScenes ที่ยาว 60 ถึง 120 วินาที โดยตัดทุก visit ของห้องทดสอบออก visit คือการเก็บข้อมูลบ้านหลังหนึ่งในครั้งเดียว ซึ่งวิดีโอในครั้งนั้นแสดงห้องเดียวกัน ได้ห้องฝึก 10 ห้องที่มีทั้งความลึกจาก Faro และ LiDAR อีก 14 ห้องที่มีเฉพาะ LiDAR และ 3 ห้องจากกลุ่ม Validation ของชุดข้อมูลสำหรับเลือก checkpoint การทดลองที่ 7 เพิ่มอีก 20 ห้องจากกลุ่ม Validation โดยเลือกหนึ่งวิดีโอต่อ visit สุ่มด้วย seed 0 และตัดทุก visit ของห้องฝึก ห้องเลือก checkpoint และห้องทดสอบออก ห้องเหล่านี้ไม่ได้ใช้ตัดสินใจเรื่องใดเลย และประเมินแบบรายเฟรมเท่านั้น บนทุกเฟรมที่สองของ Faro (รวม 2,090 เฟรม)

B. แหล่งความลึก

งานนี้เปรียบเทียบแหล่งความลึกสี่ประเภท (1) ความลึกจาก Faro เอง ซึ่งแสดงว่ากระบวนการสูญเสียความแม่นยำเท่าใด เมื่อความลึกสมบูรณ์ เพราะที่ voxel ขนาด 4 ซม. ผลยังต่างจากแบบจำลองอ้างอิงที่ 1 ซม. และความต่างนี้คือความสูญเสียจากการแบ่งช่องของกระบวนการเอง (2) ความลึกจาก LiDAR ของ iPad ตามที่ ARKit บันทึก ซึ่งเป็นสิ่งที่อุปกรณ์รุ่น Pro ใช้อยู่ในปัจจุบัน (3) โมเดลความลึกสัมพัทธ์ ซึ่งต้องปรับสเกลตามหัวข้อ III-C ได้แก่

ตารางที่ II

วิธีปรับสเกล ทุกวิธียกเว้นแบบไม่ปรับ หาสเกลหนึ่งค่าและค่าเลื่อนหนึ่งค่าบนส่วนกลับของความลึก ด้วยวิธีกำลังสองน้อยที่สุดแบบตัดค่าผิดปกติ

วิธี	หาค่าจากข้อมูลใด และถ้านับอะไร
ไม่ปรับ	ไม่หาค่าใดเลย ใช้กับ Faro, LiDAR และโมเดลแบบเมตริก
oracle รายเฟรม	ความลึกจาก Faro ของเฟรมนั้นเอง แสดงขีดสูงสุดที่รูปทรงจากโมเดลทำได้ (ใช้ในผลิตภัณฑ์จริงไม่ได้)
ครั้งเดียวต่อห้อง	ความลึกจาก Faro ของ 10 เฟรมที่กระจายตลอดการสแกน หาค่าครั้งเดียวแล้วใช้กับทุกเฟรม เป็นขอบบนของการปรับเทียบเพียงครั้งเดียว
จุดเบาบาง	จุดที่รู้ความลึกเป็นเมตร 200 จุดต่อเฟรม ใช้แทนจุดเด่นของ VIO (บทที่ II) ARKitScenes ไม่ได้เก็บจุดเหล่านี้ไว้ จึงสุ่มจากพิกเซลของ LiDAR ที่มีความเชื่อมั่นสูง ซึ่งแม่นยำกว่าจุดที่คำนวณจากภาพ จึงเป็นขอบบนของระบบที่ใช้ VIO

DA-v2 Large ในการทดลองหลัก และ DA-v2 Small กับ Mi-DaS small [9] เมื่อทดลองเปลี่ยนขนาดโมเดล (4) โมเดลความลึกแบบเมตริก ซึ่งใช้โดยไม่ปรับสเกล ได้แก่ DA-v2 Metric-Indoor Large แบบเดิม โมเดลที่ปรับปรุงแล้วสามตัว (หัวข้อ III-E) และ Depth Pro [15] ซึ่งได้รับความยาวโฟกัสจริงของกล้อง 533 พิกเซล อันเป็นเงื่อนไขที่ได้เปรียบที่สุดของโมเดลนี้ โค้ดที่เรียกใช้ Depth Pro ผ่านการตรวจกับห้องสังเคราะห์ที่รู้ความลึกแน่นอนแล้ว และบนห้าเฟรมของห้อง 47115299 ยังรันโดยให้โมเดลประมาณมุมมองภาพ (field of view) เอง แล้ววัดผลหลังตัดสเกลของแต่ละเฟรมออกด้วย ARKitScenes เก็บภาพจาก iPad ที่ถือในแนวตั้งโดยหมุนไปหนึ่งในสี่รอบ โมเดลจากภาพเดียวทุกตัวจึงได้รับภาพที่หมุนให้ตั้งตรงก่อน แล้วจึงหมุนผลลัพธ์กลับ แหล่งความลึกทุกแหล่งถูกปรับขนาดด้วยพิกเซลที่ใกล้ที่สุดเป็นความละเอียดของ LiDAR คือ 256×192 เพื่อให้ทุกแหล่งถูกรวมและวัดผลบนตารางพิกเซลเดียวกัน


C. การปรับสเกล

โมเดลความลึกสัมพัทธ์ให้ส่วนกลับของความลึกที่ยังไม่รู้สเกลและค่าเลื่อนของแต่ละภาพ (บทที่ II) การปรับสเกลคือการหาสเกลและค่าเลื่อน ที่ทำให้ส่วนกลับของความลึกจากโมเดล ตรงกับส่วนกลับของความลึกอ้างอิงชุดหนึ่งมากที่สุด แล้วแปลงผลกลับเป็นความลึก การหาค่าบนส่วนกลับของความลึกแทนที่จะหาบนความลึกโดยตรง สอดคล้องกับวิธีที่โมเดลเหล่านี้ถูกฝึก และในห้องที่ใช้ระหว่างพัฒนา การเปลี่ยนนี้ลด Chamfer distance ของ oracle รายเฟรมจาก 15.2 เหลือ 5.4 ซม. การหาค่าใช้วิธีกำลังสองน้อยที่สุด (least squares) ทำซ้ำสามรอบ แต่ละรอบตัดพิกเซล 20 % ที่มีค่าคลาดเคลื่อนมากที่สุดออก เพราะขอบของวัตถุทำให้เกิดค่าคลาดเคลื่อนขนาดใหญ่มากจำนวนหนึ่ง ซึ่งจะดึงผลการหาค่าให้เพี้ยน วิธีปรับสเกลทั้งสี่แบบต่างกันเพียงความลึกอ้างอิงที่ใช้หาค่า (ตารางที่ II) แหล่งความลึกแบบเมตริกใช้แบบไม่ปรับเสมอ และกระบวนการจะไม่ยอมทำงานหากตั้งค่าเป็นอย่างอื่น

สำหรับวิธีจุดเบาบาง การหาค่าทำซ้ำสองรอบและตัดจุดที่แย่ที่สุด 10 % ออก เฟรมที่มีจุดใช้งานได้น้อยกว่า 20 จุดจะใช้สเกลและค่าเลื่อนของเฟรมก่อนหน้า เช่นเดียวกับที่ระบบจริงจะทำเมื่อการติดตามภาพหลุดไปชั่วคราว

D. การรวมเป็นแบบจำลองห้อง

แผนที่ความลึกถูกรวมด้วยวิธี TSDF (บทที่ II) ใน Open3D [35] โดยใช้ voxel ขนาด 4 ซม. ระยะตัด (truncation) 12 ซม. หรือสาม



รูปที่ 1. กระบวนการของงานวิจัย สองขั้นที่เน้นสีเป็นเพียงสองขั้นที่เปลี่ยนระหว่างแถวของตารางผล โดยเปลี่ยนด้วยค่าตั้งคํารายการเดียว ขั้นตอนหลังจากนั้นคงที่ทั้งหมด การปรับปรุง (เส้นประ) ทำครั้งเดียวล่วงหน้า และทำหน้าที่เพียงให้ค่าน้ำหนักของโมเดลจากภาพเดี่ยว

voxel และใช้ความลึกตั้งแต่ 0.1 ถึง 5 ม. ทุกแหล่งความลึกรวมเฉพาะ พิกเซลที่ Faro มีความลึก เพื่อให้ไม่ให้แหล่งใดเสียคะแนนจากการมองเห็นส่วนของห้องที่ค่าอ้างอิงไม่ครอบคลุม และทุกพิกเซลมีน้ำหนักเท่ากัน (มีเพียงการทดลองที่ 5 ที่ถ่วงน้ำหนักพิกเซลตามความเชื่อมั่นของ LiDAR) พื้นผิวถูกสกัดด้วย marching cubes [33] แล้วลบชิ้นส่วนที่เชื่อมกันน้อยกว่า 1000 สามเหลี่ยมออก เพราะเป็นสัญญาณรบกวนที่ลอยอยู่ ทุกแถวใช้ท่าทางกล้องจาก ARKit ที่มากับชุดข้อมูล

E. การปรับปรุง

โมเดลที่ปรับปรุงจาก DA-v2 Metric-Indoor Large มีสามตัว ใช้สูตรการฝึกเดียวกัน และต่างกันเพียงข้อมูลสอน FT-Faro-10 เรียนจากความลึกของ Faro บนห้องฝึก 10 ห้อง (3594 เฟรม) FT-LiDAR-10 เรียนจากความลึกของ LiDAR ของ iPad บน 10 ห้องเดียวกัน (8656 เฟรม) และ FT-LiDAR-24 ซึ่งเป็นโมเดลหลัก เรียนจากความลึกของ LiDAR บนห้อง 24 ห้อง (19896 เฟรม) พิกเซลของ LiDAR ที่มีความเชื่อมั่นต่ำถูกตัดออก และไม่ใช้ข้อมูลสอนที่ไกลเกิน 10 ม. ครึ่งทั้งสองแบบเห็นเฟรมไม่เหมือนกัน เพราะความลึกจาก Faro มีประมาณสี่เฟรมต่อวินาที ขณะที่ความลึกจาก LiDAR มากับภาพสีทุกเฟรม ซึ่งเราเลือกใช้ทุกเฟรมที่สาม (ประมาณสิบเฟรมต่อวินาที) FT-LiDAR-10 จึงเห็นมุมมองที่ต่างกัน มากกว่า FT-Faro-10 ประมาณ 2.4 เท่า

ส่วนเข้ารหัสภาพถูกตรึงไว้ และฝึกเฉพาะส่วนถอดรหัส DPT คือ neck และ head (บทที่ II) ภาพฝึกแต่ละภาพถูกหมุนให้ตั้งตรงปรับขนาดให้ด้านสั้นยาว 518 พิกเซล แล้วตัดเป็น 518×518 ที่ตำแหน่งสุ่ม โดยไม่ขยายภาพเลย เพราะการขยายภาพทำให้วัตถุใหญ่ขึ้นและจะสอนระยะเป็นเมตรที่ผิด การพลิกภาพแนวนอน (ความน่าจะเป็น 0.5) และการสุ่มปรับสี (ความแรง 0.2) ช่วยเพิ่มความหลากหลาย ฟังก์ชันสูญเสียคือ SiLog (บทที่ II) ซึ่งสำหรับแต่ละภาพ คือความแปรปรวนของผลต่างระหว่างลอการิทึมของความลึกที่ทำนายกับของข้อมูลสอน ซึ่งวัดรูปทรง บวกกับ 0.15 เท่าของกำลังสองของค่าเฉลี่ยของผลต่างนั้น ซึ่งวัดสเกลโดยรวม แล้วนำรากที่สองของผลรวมคูณด้วย 10 ตัวหาค่าเหมาะที่สุด (optimiser) คือ AdamW [37] ซึ่งเป็นรูปแบบหนึ่งของ Adam ที่แยกการลดค่าน้ำหนัก (weight decay) ออกจากขั้นตอนตามเกรเดียนต์ ใช้อัตราการเรียนรู้ 5×10^{-5} weight decay 0.01 เพิ่มอัตราการเรียนรู้แบบเส้นตรงในช่วง 200 ขั้นแรก แล้วลดลงแบบโคไซน์จนเป็นศูนย์ [38] แต่ละขั้นใช้ภาพ 8 ภาพ (ครึ่งละ 2 ภาพ และสะสมเกรเดียนต์ 4 ครั้ง) และจำกัดขนาดของเกรเดียนต์ไม่เกิน 1 การฝึกใช้ 6000 ขั้นสำหรับ FT-Faro-10 และ FT-LiDAR-10 และ 12 000 ขั้นสำหรับ FT-LiDAR-24 ทุก 500 ขั้น โมเดลจะถูกวัด AbsRel เทียบความลึกจาก Faro บนทุกเฟรมที่

ห้าของห้องเลือก checkpoint ทั้งสามห้อง แล้วเก็บ checkpoint ที่มี AbsRel ต่ำที่สุด ดังนั้นค่าน้ำหนักของโมเดลที่เรียนจาก LiDAR ได้มาจาก LiDAR เท่านั้น แต่การเลือก checkpoint ใช้ความลึกจาก Faro ของสามห้องนี้ การฝึก 6000 ขั้นใช้เวลาประมาณหนึ่งชั่วโมงบน GPU รุ่น NVIDIA RTX 3070 Ti ขณะทดสอบ โมเดลที่ปรับปรุงแล้วถูกใช้เหมือนโมเดลเดิมทุกประการ คือรับภาพสีและใช้ความลึกเป็นเมตร ไม่ปรับสเกล และเตรียมภาพนำเข้าแบบเดียวกัน

F. ตัวชี้วัดและสถิติ

แบบสามมิติ สุ่มจุด 200 000 จุดอย่างสม่ำเสมอแบบจำลองแต่ละอัน ความแม่นยำ (accuracy) คือระยะเฉลี่ยจากจุดบนแบบจำลองที่สร้างได้ถึงจุดที่ใกล้ที่สุดบนแบบจำลองอ้างอิง ความครบถ้วน (completeness) คือระยะเฉลี่ยในทิศทางกลับกัน และ Chamfer distance [6] คือค่าเฉลี่ยของทั้งสอง precision, recall และ F-score [18] (บทที่ II) คำนวณที่ระยะเกณฑ์ 2, 5 และ 10 ซม. โดยใช้ F@5cm เป็นตัวเลขหลัก สำหรับวัตถุประสงค์ข้อ (3) ถือว่ารองรับงานได้เมื่อ recall ที่ระยะเกณฑ์ของงานนั้นอย่างน้อย 0.9 รองรับได้บางส่วนเมื่ออยู่ระหว่าง 0.75 ถึง 0.9 และรองรับไม่ได้เมื่อต่ำกว่า 0.75 **แบบรายเฟรม** แผนที่ความลึกแต่ละภาพถูกเทียบกับความลึกจาก Faro บนตาราง 256×192 เฉพาะพิกเซลที่ความลึกจาก Faro อยู่ระหว่าง 0.1 ถึง 5 ม. และแหล่งความลึกให้ค่าออกมา ค่าที่ทำนายนอกช่วงนี้จะถูกตัดให้อยู่ในช่วงแทนที่จะถูกทิ้ง โมเดลที่วางแผนไกลเกินไปจึงยังถูกรัดผลที่ผ่นนั้น งานนี้รายงาน AbsRel, within-1.25x และรากที่สองของค่าเฉลี่ยกำลังสองของความคลาดเคลื่อน (RMSE) ของความลึก [7] โดยเฉลี่ยในแต่ละห้องก่อน แล้วจึงเฉลี่ยข้ามห้อง **สถิติ** ตารางแสดงค่าเฉลี่ย $\pm$ ส่วนเบี่ยงเบนมาตรฐานข้ามห้อง เนื่องจากหน่วยที่เป็นอิสระต่อกันคือห้อง ไม่ใช่เฟรม การเปรียบเทียบสองโมเดลจึงใช้ค่ารายห้องกับการทดสอบ Wilcoxon signed-rank แบบ exact สองทาง [17] การทดสอบนี้เรียงลำดับผลต่างรายห้องตามขนาด แล้วตรวจว่าลำดับของผลต่างที่เป็นบวกและลบสมดุลกันหรือไม่ คำว่า exact หมายถึงคำนวณค่า p จากทุกรูปแบบที่เป็นไปได้ของเครื่องหมาย ไม่ได้ใช้ค่าประมาณ ซึ่งสำคัญเมื่อมีห้องน้อย เมื่อมีหกห้อง ค่า p ที่เล็กที่สุดที่เป็นไปได้คือ $2/64 \approx 0.031$ ความต่างจึงมีนัยสำคัญที่ระดับ 5% ได้ก็ต่อเมื่อโมเดลหนึ่งชนะครบทั้งหกห้อง

G. การทดลอง

ตารางที่ III แสดงการทดลองและวัตถุประสงค์ที่แต่ละการทดลองตอบ การทดลองที่ 6 และ 7 ตอบคำถามหลัก (วัตถุประสงค์ข้อ 1 และ 2) การทดลองที่ 1 ระบุตำแหน่งของโมเดลเทียบกับแหล่งความลึก

ตารางที่ III
การทดลอง ในแต่ละการทดลองเปลี่ยนเฉพาะตัวแปรที่ระบุ ส่วนอื่นคงที่ทั้งหมด

การทดลอง	ชื่อ	ตัวแปร ห้อง และการประเมิน
6	1, 2	โมเดลเดิมเทียบกับ FT-LiDAR-24; FT-Faro-10, FT-LiDAR-10 และ Depth Pro; ห้องทดสอบ 6 ห้อง สามมิติและรายเฟรม
7	1	โมเดลเดิมเทียบกับ FT-LiDAR-24 โดยมี LiDAR ของ iPad เป็นแกวอ้างอิง; อีก 20 ห้อง รายเฟรม
1	3	แหล่งความลึกและวิธีปรับสเกล: Faro, LiDAR, DA-v2 Large กับ การปรับแต่ละแบบ, DA-v2 Metric แบบเดิม; ห้องทดสอบ 6 ห้อง สามมิติและรายเฟรม
–	4	การวิเคราะห์สเกลรายเฟรม (หัวข้อ III-H); ห้องทดสอบ 6 ห้อง ทุกเฟรมที่ห้า
2–5	–	ขนาด voxel; ระยะห่างของเฟรม; ขนาดโมเดล; ความเชื่อมั่นของ LiDAR; ห้องทดสอบ 6 ห้อง สามมิติ

ที่ใช้ได้ขณะใช้งาน (วัตถุประสงค์ข้อ 3) และการทดลองที่ 2–5 ทดสอบว่ากระบวนการวัดค่าตั้งค่าของตัวเองเพียงใด เวลาในการทดลองที่ 4 วัดด้วย PyTorch ที่ไม่ได้ปรับแต่งบนแพลตฟอร์ม Apple Silicon และใช้เปรียบเทียบเป็นอัตราส่วนเท่านั้น

H. การวิเคราะห์สเกลรายเฟรม


วัตถุประสงค์ข้อ (4) ถามว่าความคลาดเคลื่อนที่การปรับจนแก้ไขไม่ได้คืออะไร และมาจากเวลาหรือจากมุมมอง บนทุกเฟรมที่ห้าของห้องทดสอบทั้งหมด (471 เฟรม) เราคำนวณสำหรับโมเดลแบบเมตริกเดิม และ FT-LiDAR-24 อัตราส่วนของความลึกจาก Faro ต่อความลึกที่ห้านาย โดยใช้ค่ามัธยฐานบนพิกเซลของเฟรมนั้น ค่ามัธยฐานของอัตราส่วนนั้นบนเฟรมทั้งหมดของห้องบอกว่าสเกลของโมเดลคลาดไปเท่าใด และอัตราส่วนระหว่างเปอร์เซ็นต์ในสเกลที่ 95 กับที่ 5 ของอัตราส่วนนั้นบนเฟรมเหล่านั้น บอกว่าสเกลที่ต้องการแกวภายในห้องเดียวมากเพียงใด จากนั้นคำนวณ AbsRel เมื่อให้ความช่วยเหลือด้านสเกลเพิ่มขึ้นทีละระดับ ได้แก่ ไม่ช่วยเหลือ สเกลและค่าเลื่อนหนึ่งชุดต่อห้องที่หาจาก 10 เฟรมตามตารางที่ II สเกลที่ถูกต้องของทุกเฟรม (ค่ามัธยฐานของอัตราส่วนของเฟรมนั้น ไม่มีค่าเลื่อน) และสเกลกับค่าเลื่อนแบบ oracle รายเฟรม สำหรับโมเดลความลึกสัมพัทธ์ DA-v2 Large เราหาสเกลแบบ oracle รายเฟรมบนเฟรมชุดเดียวกัน แล้วคำนวณสัมประสิทธิ์สหสัมพันธ์ของ Pearson [39] ซึ่งวัดความสัมพันธ์เชิงเส้นในช่วง -1 ถึง $+1$ ระหว่างสเกลนี้กับเวลาของเฟรมในการสแกน และกับค่ามัธยฐานของความลึกจาก Faro ในเฟรมนั้น หากเป็นการสะสมความคลาดเคลื่อน (drift) ตามเวลา สหสัมพันธ์กับเวลาจะมีเครื่องหมายเดียวกันในทุกห้อง หากขึ้นกับมุมมอง สหสัมพันธ์กับความลึกของฉากตรงหน้ากล้องจะมีทิศทางเดียวกันอย่างสม่ำเสมอ

IV. ผลการทดลอง

บทนี้รายงานผลที่วัดได้จากการทดลองในตารางที่ III โดยจัดกลุ่มตามวัตถุประสงค์ ส่วนความหมายของผลจะอภิปรายในบทที่ V ระยะทั้งหมดมีหน่วยเป็นเซนติเมตร ค่าในตารางเป็นค่าเฉลี่ยข้ามห้อง และ $\pm$ คือส่วนเบี่ยงเบนมาตรฐานข้ามห้อง เมื่อเปรียบเทียบสองโมเดล เราระบุว่าโมเดลหนึ่งดีกว่าในกี่ห้อง พร้อมค่า p จากการทดสอบ Wilcoxon signed-rank แบบ exact บนค่ารายห้อง (หัวข้อ III-F)

A. โมเดลที่ปรับจนเทียบกับโมเดลเดิม (วัตถุประสงค์ข้อ 1)

บนห้องทดสอบทั้งหมด (ตารางที่ IV) FT-LiDAR-24 ลด Chamfer distance จาก 54.3 เหลือ 15.7 ซม. และต่ำกว่าโมเดลเดิมครบทั้งหกห้อง โดยต่ำกว่า 38.6 ± 8.6 ซม. ($p = 0.031$ ซึ่งเป็นค่า p ที่เล็กที่สุด



รูปที่ 2. AbsRel รายห้องเทียบกับ Faro: DA-v2 Metric-Indoor แบบเดิม (แกนนอน) กับ FT-LiDAR-24 (แกนตั้ง) จุดที่อยู่ใต้เส้นทแยงประคือห้องที่ FT-LiDAR-24 มี AbsRel ต่ำกว่า

ที่เป็นไปได้เมื่อมีหกห้อง) ความแม่นยำลดลงจาก 70.3 เหลือ 17.3 ซม. ความครบถ้วนลดลงจาก 38.3 เหลือ 14.0 ซม. และ $F@5\text{ cm}$ เพิ่มขึ้นจาก 0.03 เป็น 0.24 ซึ่งสูงกว่าครบทั้งหกห้อง ($p = 0.031$) ในการวัดรายเฟรม AbsRel ลดจาก 0.382 เหลือ 0.134 ซึ่งต่ำกว่าครบทั้งหกห้อง ($p = 0.031$, ตารางที่ VII) และ within-1.25 $\times$ เพิ่มขึ้นจาก 0.277 เป็น 0.812 ซึ่งสูงกว่าในห้าห้อง ($p = 0.063$) ส่วนในห้อง 47115299 ค่านี้ลดลงจาก 0.74 เหลือ 0.60

บนห้องอีก 20 ห้องของการทดลองที่ 7 (ตารางที่ V และรูปที่ 2) AbsRel ลดจาก 0.410 เหลือ 0.130 ซึ่งต่ำกว่าใน 19 จาก 20 ห้อง ($p = 3.8 \times 10^{-6}$) และ within-1.25 $\times$ เพิ่มขึ้นจาก 0.333 เป็น 0.827 ซึ่งสูงกว่าใน 19 ห้อง ($p = 9.5 \times 10^{-6}$) ในห้อง 19 ห้องนั้น AbsRel ของ FT-LiDAR-24 เท่ากับ 21 ถึง 64% ของโมเดลเดิม ส่วนห้องที่เหลือคือ 48018730 ซึ่ง AbsRel ของโมเดลเดิมต่ำเป็นอันดับห้าจาก 20 ห้อง AbsRel เปลี่ยนจาก 0.275 เป็น 0.281 และ within-1.25 $\times$ จาก 0.53 เป็น 0.35 เพื่อเปรียบเทียบ LiDAR ของ iPad มี AbsRel 0.019 บนห้องเหล่านี้ และมี Chamfer distance 3.0 ซม. บนห้องทดสอบ ส่วน DA-v2 Large ที่ปรับสเกลด้วยจุดเบางได้ 6.0 ซม. ซึ่งต่ำกว่า FT-LiDAR-24 อยู่ 9.7 ซม. (ตารางที่ IV)

B. แหล่งของข้อมูลสอน (วัตถุประสงค์ข้อ 2)

โมเดลที่ปรับจนทั้งสามได้ Chamfer distance 14.6 ซม. เมื่อเรียนจาก Faro (FT-Faro-10) 16.6 ซม. เมื่อเรียนจาก LiDAR บนห้องชุดเดียวกัน (FT-LiDAR-10) และ 15.7 ซม. เมื่อเรียนจาก LiDAR บน 24 ห้อง (FT-LiDAR-24) ส่วน AbsRel เท่ากับ 0.136, 0.136 และ 0.134 ตามลำดับ (ตารางที่ IV) เมื่อดูรายห้อง (ตารางที่ VII) FT-Faro-10 มี Chamfer distance ต่ำกว่า FT-LiDAR-10 ในสี่ห้อง ($p = 0.69$) และ FT-LiDAR-24 ต่ำกว่า FT-LiDAR-10 ในห้าห้อง ($p = 0.44$) ส่วน FT-Faro-10 ต่ำกว่า FT-LiDAR-24 ในสามห้อง สูงกว่าในสองห้อง และต่างกันไม่เกิน 0.1 ซม. ในหนึ่งห้อง ($p = 0.56$) ทั้งสามคู่นี้ไม่มีคู่ใดต่างกันอย่างมีนัยสำคัญ ทั้งใน Chamfer distance, $F@5\text{ cm}$, AbsRel และ within-1.25 $\times$ (ค่า p ทุกค่า ≥ 0.09) รูปที่ 3 แสดงความคลาดเคลื่อนของทุกจุดบนพื้นผิว ของทุกโมเดลในทุกห้อง

Depth Pro ซึ่งได้รับความยาวโฟกัสจริงของกล้องและไม่ได้ปรับจนได้ 155.4 ซม. และ AbsRel 2.007 ซึ่งสูงกว่า DA-v2 Metric-Indoor แบบเดิมครบทั้งหกห้องในทั้งสองค่า ($p = 0.031$) ในการตรวจบนห้าเฟรมของห้อง 47115299 (หัวข้อ III-B) มุมมองภาพแนวนอนที่โมเดลประมาณเอง อยู่ระหว่าง 48.0 ถึง 48.7° ขณะที่ของกล้อง

ตารางที่ IV

การทดลองที่ 6 บนห้องทดสอบทั้งหก: ใช้ภาพสีเท่านั้น ไม่ปรับสเกล และวัดเทียบกับ Faro สองแถวสุดท้ายต้องใช้เซนเซอร์ขณะใช้งาน จึงแสดงไว้เพื่ออ้างอิง (การทดลองที่ 1) Acc.: ความแม่นยำ, Compl.: ความครบถ้วน, F@5 และ R@10: F-score ที่ 5 ซม. และ recall ที่ 10 ซม.

โมเดล	ข้อมูลสอน	Chamfer	Acc.	Compl.	F@5	R@10	AbsRel	within-1.25×	RMSE
DA-v2 Metric-Indoor แบบเดิม	— (ห้องจำลอง Hypersim)	54.3 ± 10.6	70.3	38.3	0.03	0.10	0.382	0.277	49.3
Depth Pro ให้ความยาวโฟกัสจริง	—	155.4 ± 39.0	229.0	81.8	0.00	0.02	2.007	0.170	206.9
FT-Faro-10	Faro, 10 ห้อง	14.6 ± 4.0	13.2	15.9	0.31	0.57	0.136	0.780	20.7
FT-LiDAR-10	LiDAR ของ iPad, 10 ห้อง	16.6 ± 4.7	18.8	14.3	0.23	0.49	0.136	0.848	19.8
FT-LiDAR-24	LiDAR ของ iPad, 24 ห้อง	15.7 ± 4.0	17.3	14.0	0.24	0.51	0.134	0.812	20.2
อ้างอิง: LiDAR ของ iPad (เซนเซอร์)	—	3.0 ± 0.6	2.2	3.9	0.93	0.97	0.018	0.997	3.9
อ้างอิง: DA-v2 Large + จุดเบาบาง	—	6.0 ± 1.7	6.4	5.5	0.74	0.91	0.036	0.985	7.4

ตารางที่ V

การทดลองที่ 7: ตัวชี้วัดรายเฟรมบนห้องอีก 20 ห้องจากชุด Validation (2,090 เฟรม) ซึ่งไม่ได้ใช้ทำอย่างอื่นเลย ค่าเฉลี่ย ± ส่วนเบี่ยงเบนมาตรฐานข้ามห้อง

โมเดล	AbsRel	within-1.25×	RMSE (ซม.)
DA-v2 Metric-Indoor แบบเดิม	0.410 ± 0.164	0.333 ± 0.216	50.9
FT-LiDAR-24	0.130 ± 0.046	0.827 ± 0.135	18.4
อ้างอิง: LiDAR ของ iPad (เซนเซอร์)	0.019 ± 0.002	0.997 ± 0.002	3.8

ตารางที่ VI

การทดลองที่ 1: กระบวนการเดียวกัน เปลี่ยนเฉพาะแหล่งความลึกและวิธีปรับสเกล บนห้องทดสอบหกห้อง แกะ FT-LiDAR-24 มาจากการทดลองที่ 6 recall ที่ 10, 5 และ 2 ซม. แผนงานภาพรวมของห้อง การวางเฟอร์นิเจอร์ และการวัดเฟอร์นิเจอร์สำหรับแผนที่ใช้ได้ขณะใช้งาน ✓: รองรับ (≥ 0.9), ~: รองรับบางส่วน (0.75–0.9), ×: ไม่รองรับ (< 0.75)

แหล่งความลึก	การปรับสเกล	Chamfer	F@5	AbsRel	recall ที่		
					10 ซม.	5 ซม.	2 ซม.
Faro	ไม่ปรับ	2.1 ± 0.5	0.97	0	0.98	0.96	0.84
LiDAR ของ iPad	ไม่ปรับ	3.0 ± 0.6	0.93	0.018	✓ 0.97	✓ 0.91	× 0.52
DA-v2 Large	oracle รายเฟรม	5.3 ± 1.3	0.79	0.032	0.93	0.82	0.47
DA-v2 Large	จุดเบาบาง	6.0 ± 1.7	0.74	0.036	✓ 0.91	~ 0.77	× 0.39
DA-v2 Large	ครั้งเดียวต่อห้อง	22.9 ± 2.1	0.23	0.237	× 0.47	× 0.27	× 0.09
DA-v2 Metric-Indoor	ไม่ปรับ	54.3 ± 10.6	0.03	0.382	× 0.10	× 0.04	× 0.01
FT-LiDAR-24	ไม่ปรับ	15.7 ± 4.0	0.24	0.134	× 0.51	× 0.28	× 0.09

ตารางที่ VII

ผลรายห้องทดสอบ เรียงตามตารางที่ I (สีหลักแรกของรหัสการสแกน) DA-v2 L คือ DA-v2 Large

	4244	4733	4711	4289	4742	4526	เฉลี่ย
Chamfer distance (ซม.)							
Faro	1.8	1.2	1.9	2.8	2.4	2.3	2.1
LiDAR ของ iPad	2.8	2.4	2.9	4.1	3.1	3.0	3.0
DA-v2 L, oracle รายเฟรม	3.8	6.2	4.8	7.5	5.2	4.5	5.3
DA-v2 L, จุดเบาบาง	4.5	6.1	5.5	9.1	5.9	4.6	6.0
DA-v2 L, ครั้งเดียวต่อห้อง	24.1	26.0	19.9	23.2	21.4	23.1	22.9
DA-v2 Metric แบบเดิม	48.5	61.6	41.5	48.9	54.1	71.0	54.3
Depth Pro	131.1	165.2	172.9	196.4	177.9	88.9	155.4
FT-Faro-10	10.8	13.8	17.6	21.1	12.4	11.9	14.6
FT-LiDAR-10	13.9	19.0	12.8	12.5	16.6	24.6	16.6
FT-LiDAR-24	12.8	16.7	17.3	12.2	12.4	22.5	15.7
AbsRel							
DA-v2 Metric แบบเดิม	0.375	0.346	0.255	0.412	0.476	0.430	0.382
FT-LiDAR-24	0.127	0.156	0.193	0.087	0.141	0.101	0.134

รูปที่ 3. การทดลองที่ 6 เมื่อมองจากด้านบน: ทุกจุดบนแบบจำลองที่สร้างได้ ถูกระบายสีตามระยะถึงแบบจำลองจาก Faro จากน้ำเงินเข้ม (0 ซม.) ผ่านเขียวและเหลือง ไปจนถึงแดงเข้ม (10 ซม. ขึ้นไป) แกะคือห้องตามรหัสการสแกน คอลัมน์คือโมเดล

จริงคือ 61.6° และหลังตัดสเกลของแต่ละเฟรมออกแล้ว AbsRel ยังอยู่ระหว่าง 0.24 ถึง 0.54 เทียบกับ 0.04 ถึง 0.13 ของ DA-v2 Metric-Indoor แบบเดิมบนเฟรมชุดเดียวกัน

C. ตำแหน่งเทียบกับแหล่งความลึกที่ใช้ได้ขณะใช้งาน (วัตถุประสงค์ข้อ 3)


เมื่อผ่านกระบวนการเดียวกัน (ตารางที่ VI) ความลึกจาก Faro เองได้ 2.1 ซม. LiDAR ของ iPad ได้ 3.0 ซม. ซึ่งสูงกว่า Faro

0.98 ± 0.25 ซม. ต่อห้อง และสูงกว่าในทุกห้อง โดย recall ที่ 2 ซม. ของ LiDAR เท่ากับ 0.52 เทียบกับ 0.84 ของ Faro DA-v2 Large ที่ใช้ oracle รายเฟรมได้ 5.3 ซม. ซึ่งสูงกว่า LiDAR 2.29 ± 1.11 ซม. ต่อห้อง เมื่อปรับสเกลด้วยจุดเบาบางได้ 6.0 ซม. และเมื่อปรับครั้งเดียวต่อห้องได้ 22.9 ซม. โดยอยู่ระหว่าง 19.9 ถึง 26.0 ซม. ในทุกห้อง DA-v2 Metric-Indoor แบบเดิมได้ 54.3 ซม. และในห้อง 45261556 โมเดลนี้มี Chamfer distance สูงที่สุดของตัวเอง (71.0 ซม.) ขณะที่ oracle รายเฟรมต่ำเป็นอันดับสองในห้องเดียวกัน (4.5 ซม.; ตารางที่ VII) ตามเกณฑ์ในหัวข้อ III-F LiDAR ของ iPad รองรับงานภาพรวมและการวางเฟอร์นิเจอร์ จุดเบาบางรองรับงานภาพรวมและรองรับการวางเฟอร์นิเจอร์ได้บางส่วน และไม่มีแกวเอนเลย รวมถึง FT-LiDAR-24 ที่รองรับการวัดเฟอร์นิเจอร์

ตารางที่ VIII

สเกลรายเฟรมของโมเดลเดิมและ FT-LiDAR-24 บนทุกเฟรมที่ห้าของห้องทดสอบทั้งหก (471 เฟรม) อัตราส่วน คือความลึกจาก Faro หารด้วยความลึกที่ทำนาย โดยใช้ค่ามัธยฐานบนพิกเซลของเฟรม

	แบบเดิม	FT-LiDAR-24
อัตราส่วน ค่ามัธยฐานบนเฟรมของห้อง (ช่วงข้ามห้อง)	0.69–0.85	0.93–1.21
อัตราส่วน เปอร์เซ็นไทล์ที่ 95 หารด้วยที่ 5 ภายในห้อง (เฉลี่ย)	1.55	1.52
AbsRel ไม่ช่วยเหลือ	0.381	0.134
AbsRel สเกลและค่าเลื่อนหนึ่งชุดต่อห้องจาก 10 เฟรม	0.127	0.117
AbsRel สเกลที่ถูกต้องของทุกเฟรม	0.045	0.051
AbsRel สเกลและค่าเลื่อนแบบ oracle รายเฟรม	0.035	0.042



รูปที่ 4. โมเดลความลึกสัมพันธ์ DA-v2 Large บนทุกเฟรมที่ห้าของห้องทดสอบทั้งหก: สเกลแบบ oracle รายเฟรม หารด้วยสเกลที่ปรับครั้งเดียวต่อห้อง เทียบกับค่ามัธยฐานของความลึกจาก Faro ในเฟรมนั้น (469 เฟรม ไม่รวมสองเฟรมที่การหาค่าไม่ได้สเกลที่เป็นบวก) สหสัมพันธ์ของ Pearson ระหว่างลอการิทึมของสองค่าคือ -0.37

D. สเกลรายเฟรม (วัตถุประสงค์ข้อ 4)

สำหรับโมเดลเดิม ค่ามัธยฐานของอัตราส่วนความลึกจาก Faro ต่อความลึกที่ทำนาย อยู่ระหว่าง 0.69 ถึง 0.85 ในหกห้อง นั่นคือความลึกที่ทำนายเป็น 1.18 ถึง 1.45 เท่าของความลึกจาก Faro ส่วนของ FT-LiDAR-24 อยู่ระหว่าง 0.93 ถึง 1.21 (ตารางที่ VIII) ภายในห้องเดียว เปอร์เซ็นไทล์ที่ 95 ของอัตราส่วนนี้ มีค่าเฉลี่ยเป็น 1.55 เท่า ของเปอร์เซ็นไทล์ที่ 5 สำหรับโมเดลเดิม และ 1.52 เท่า สำหรับ FT-LiDAR-24 ในห้อง 47115299 อัตราส่วนของโมเดลเดิม อยู่ระหว่าง 0.43 ถึง 1.35 เมื่อไม่ช่วยด้านสเกลเลย FT-LiDAR-24 มี AbsRel 0.134 เทียบกับ 0.127 ของโมเดลเดิมที่ได้สเกลและค่าเลื่อนหนึ่งชุดต่อห้องซึ่งหาจากความลึกของ Faro เมื่อให้สเกลที่ถูกต้องทุกเฟรม AbsRel ของโมเดลเดิมลดเหลือ 0.045 ซึ่งเท่ากับ 97 % ของระยะทางจากกรณีไม่ช่วยเหลือไปถึง oracle และของ FT-LiDAR-24 ลดเหลือ 0.051

สำหรับโมเดลความลึกสัมพันธ์ DA-v2 Large สเกลแบบ oracle รายเฟรมแกว่งภายในห้องเดียว 2.6 ถึง 4.9 เท่า ระหว่างเปอร์เซ็นไทล์ที่ 5 กับที่ 95 สหสัมพันธ์ของสเกลนี้กับเวลาของเฟรมในการสแกน อยู่ระหว่าง -0.40 ถึง $+0.30$ โดยเป็นบวกในสามห้องและเป็นลบในสามห้อง ส่วนสหสัมพันธ์กับค่ามัธยฐานของความลึกจาก Faro ในเฟรมนั้น อยู่ระหว่าง -0.75 ถึง -0.27 และเป็นลบครบทั้งหกห้อง (รูปที่ 4)

E. ความไวของกระบวนการ (การทดลองที่ 2–5)

ตารางที่ IX แสดงผลการทดลองด้านความไว DA-v2 Small ได้ Chamfer distance สูงกว่า DA-v2 Large 1.0 ซม. และเร็วกว่า 6.4 เท่าต่อห้อง ที่สี่เฟรมต่อวินาที การประมวลผลใช้เวลา 3.6 เท่าของความยาววิดีโอเมื่อใช้ DA-v2 Large และ 0.6 เท่าเมื่อใช้ DA-v2 Small โดยการรวมเป็นแบบจำลองใช้เวลาไม่ถึง 3 % ของทั้งหมด

ตารางที่ IX

การทดลองด้านความไวบนห้องทดสอบทั้งหก เปลี่ยนค่าตั้งเพียงค่าเดียว ส่วนอื่นเหมือน บทที่ III

การทดลอง	ผล
2 ขนาด voxel (Faro)	2 / 4 / 8 ซม.: Chamfer 1.2 / 2.1 / 2.8 ซม. การรวมใช้เวลาไม่เกิน 2 วินาทีต่อห้องในทุกขนาด
3 ระยะห่างของเฟรม (Faro)	ทุกเฟรม / ทุกเฟรมที่ 5 / ทุกเฟรมที่ 10 (4 / 0.8 / 0.4 เฟรมต่อวินาที): ความแม่นยำ 1.3 / 1.2 / 1.2 ซม. ความครบถ้วน 2.8 / 7.5 / 16.6 ซม. F@5 cm 0.97 / 0.91 / 0.83
4 ขนาดโมเดล (oracle รายเฟรม)	DA-v2 Large (335 ล้าน พารามิเตอร์) / Small (25 ล้าน) / MiDaS small (21 ล้าน): Chamfer 5.33 / 6.35 / 13.24 ซม. ใช้เวลา 348 / 55 / 16 วินาทีต่อห้อง
5 ความเชื่อมั่นของ LiDAR	Chamfer 3.04 ซม. เมื่อใช้ทุกพิกเซล 3.07 ซม. เมื่อตัดพิกเซล ความเชื่อมั่นต่ำ 3.66 ซม. เมื่อใช้เฉพาะความเชื่อมั่นสูง (ความครบถ้วน 3.85 $\rightarrow$ 5.23 ซม.) และ 3.04 กับ 3.07 ซม. เมื่อถ่วงน้ำหนักพิกเซลตามความเชื่อมั่น

V. อภิปรายและสรุปผล

บทนี้เชื่อมโยงผลกับงานวิจัยก่อนหน้านี้ ตีความความคลาดเคลื่อนที่ยังเหลืออยู่ เสนอนัยต่อการนำไปใช้ ระบุข้อจำกัดและงานในอนาคต แล้วสรุปผลตามวัตถุประสงค์ที่ละข้อ

A. ความเชื่อมโยงกับงานวิจัยก่อนหน้านี้

DA-v2 Metric-Indoor เรียนหน่วยเมตรจากห้องจำลองของ Hypersim [1], [16] และวางห้องทดสอบจริงทุกห้องใกล้เคียงจริง 1.18 ถึง 1.45 เท่า ZoeDepth [14] และ DA-v2 ปรับส่วนหัวแบบเมตริกให้เข้ากับโดเมนเป้าหมาย ด้วยการปรับจนบนข้อมูลที่มีค่ากำกับ ผลของเราแสดงว่าวิธีเดียวกันนี้ใช้ได้ เมื่อข้อมูลสอนมาจาก LiDAR ของอุปกรณ์เป้าหมายเอง เช่นเดียวกับที่ผู้พัฒนา DINOv2 ทำกับงานประมาณความลึก [24] เราฝึกเฉพาะส่วนถอดรหัสบนส่วนเข้ารหัสที่ตรงไว้ และรูปทรงของผลทำนายแทบไม่เปลี่ยน (AbsRel แบบ oracle รายเฟรม 0.035 เทียบกับ 0.042) ซึ่งสอดคล้องกับแนวคิดว่าคุณลักษณะจากส่วนเข้ารหัสถ่ายโอนได้ [26] และส่วนหัวเรียนรู้สเกลเป็นหลัก

ความลึกจากเซนเซอร์ถูกใช้เป็นข้อมูลสอนมานาน ตั้งแต่ Kinect ในอาคารไปจนถึงเครื่องสแกนเลเซอร์บนรถยนต์ [7], [20], [21] ความคลาดเคลื่อนราว 1 ซม. ที่ LiDAR ของโทรศัพท์เพิ่มขึ้นจากความลึกของ Faro ในกระบวนการของเรา สอดคล้องกับความแม่นยำระดับเซนติเมตรที่รายงานไว้เมื่อเทียบกับวิธีการสำรวจ [27], [28] และความคลาดเคลื่อนของมันในฐานะข้อมูลสอน (AbsRel 0.018) ต่ำกว่าความคลาดเคลื่อนที่เหลือในโมเดลที่ปรับจนแล้ว (0.134) ราวหนึ่งอันดับขนาด ซึ่งอาจอธิบายได้ว่าทำไมครุที่เป็นเครื่องสแกนเลเซอร์จึงไม่ได้ให้ผลดีขึ้นอย่างวัดได้ Prompt Depth Anything [29] และงานเพิ่มความละเอียดความลึกของ ARKitScenes [3] ใช้ LiDAR ขณะใช้งาน ส่วนโมเดลของเราต้องการเพียงภาพสี แต่ต้องแลกด้วยความคลาดเคลื่อนที่สูงกว่ามาก (15.7 ซม. เทียบกับ 3.0 ซม.)

โมเดลที่คำนึงถึงกล้อง [15], [22], [23] มองว่าความยาวโฟกัสที่ไม่รู้ค่าเป็นอุปสรรคหลักของความลึกแบบเมตริก แต่สำหรับ Depth Pro บนภาพในอาคารขนาด 640×480 นี้ การให้ความยาวโฟกัส

จริงไม่ได้ทำให้ใช้งานได้ และความคลาดเคลื่อนหลังตัดสเกลออกยังสูงกว่าของ DA-v2 Metric-Indoor หลายเท่า เราไม่ได้ทดสอบ Metric3D หรือ UniDepth ข้อสรุปนี้จึงไม่ขยายไปถึงแนวทางนี้โดยรวม เกล็ดที่วัดแบบรายภาพ ไม่สามารถแสดงว่าสเกลคงที่ตลอดเฟรมของการสแกนหรือไม่ (บทที่ II) และเราพบว่าไม่คงที่ ทั้งในโมเดลความลึกสัมพัทธ์และแบบเมตริก Video Depth Anything [40] มุ่งแก้ความคงเส้นคงวาชั่วเฟรมของวิดีโอลักษณะนี้ ส่วนจุดเมตริกแบบบางที่ใช้ในแนวทางเดียวกับ CNN-SLAM และ MonoSDF [31], [32] ให้ผลห่างจาก oracle รายเฟรมเพียง 0.6 ซม. ในรูปแบบที่เป็นขอบบน ระบบสร้างแบบจำลองที่ใช้การเรียนรู้ [11]–[13] ใช้หลายเฟรมต่อการทำนายและใช้ข้อมูลชุดอื่น ตัวเลขของเราจึงเปรียบเทียบกับของงานเหล่านั้นโดยตรงไม่ได้

B. ทำไมความคลาดเคลื่อนของสเกลยังเหลืออยู่

การปรับปรุงเรียนรู้ตัวคูณของโดเมนแล้ว FT-LiDAR-24 ที่ไม่ได้ปรับเทียบเลย (AbsRel 0.134) ใกล้เคียงกับโมเดลเดิมที่ได้สเกลและค่าเลื่อนหนึ่งชุดต่อห้องซึ่งหาจากค่าอ้างอิง (0.127) สิ่งที่ทำให้การปรับเทียบครั้งเดียวเคยให้ จึงย้ายเข้าไปอยู่ในค่าน้ำหนักของส่วนหัวแล้ว แต่การแก้ของสเกลจากเฟรมหนึ่งไปอีกเฟรมไม่ได้ลดลง (1.52 เทียบกับ 1.55) เหตุผลที่เป็นไปได้มาจากแบบจำลองกล่องรีซึม (บทที่ II) คือ ภาพบางแบบ เช่น ภาพระยะใกล้ของหน้าโต๊ะ หรือภาพผนังเรียบ ดูเหมือนกันที่ระยะต่างกัน และไม่มีสิ่งใดบอกขนาดจริง โมเดลจึงเดาระยะตามแบบห้องทั่วไป สหสัมพันธ์เชิงลบระหว่างสเกลที่ต้องการกับความลึกของภาพ ซึ่งพบในทุกห้อง สอดคล้องกับคำอธิบายนี้ หากคำอธิบายนี้ถูก การเพิ่มหรือปรับปรุงข้อมูลสอนจะไม่จัดการแก้ และต้องใช้ข้อมูลเมตริกขณะใช้งาน จากนั้นการรวมแบบ TSDF [5] จะเฉลี่ยพื้นผิวเดียวกันที่ถูกวางไว้หลายระยะ ให้เป็นพื้นผิวที่หนาและเบลอ ซึ่งสอดคล้องกับการที่ความคลาดเคลื่อนรายเฟรมระดับปานกลาง กลายเป็น Chamfer distance 15.7 ซม.

C. นัยต่อการนำไปใช้

สำหรับแอปบนอุปกรณ์ที่ไม่มี LiDAR ผลลัพธ์ลำดับของงานดังนี้ อันดับแรกคือสเกลเมตริกรายเฟรม (ห่างจาก oracle รายเฟรมเพียง 0.6 ซม. เทียบกับ 22.9 ซม. เมื่อปรับเทียบครั้งเดียวต่อห้อง ซึ่งเป็นขอบบน เพราะจุดมาจาก LiDAR ไม่ใช่จาก VIO) ถัดมาคือโมเดลที่ปรับปรุงแล้ว ซึ่งขจัดความเอนเอียงของโดเมน โดยไม่ต้องใช้อะไรเพิ่มขณะใช้งาน และขนาดโมเดลสำคัญน้อยที่สุด (DA-v2 Small แยกกว่า Large 1.0 ซม. เมื่อใช้ oracle รายเฟรม แต่เร็วกว่า 6.4 เท่า) ข้อมูลสอนเก็บได้จากอุปกรณ์รุ่น Pro ระหว่างการใช้งานปกติ เพราะ ARKit ให้ภาพสี ความลึกจาก LiDAR และท่าทางกล้องมาพร้อมกัน และที่ 3.6 เท่าของความยาววิดีโอบนแอปหือป กระบวนการในรูปแบบที่ทดสอบจึงทำงานแบบออฟไลน์

D. ข้อจำกัด

การประเมินมีขนาดเล็ก คือห้องทดสอบหกห้องในแบบสามมิติ ซึ่งหนึ่งห้องถูกใช้ระหว่างพัฒนา และ 26 ห้องในแบบรายเฟรม ทั้งหมดเป็นบ้านที่ถ่ายด้วย iPad รุ่นเดียว ไม่มีสำนักงาน ห้องว่าง แสงน้อยหรือกล้องโทรศัพท์รุ่นอื่น และห้องน้ำที่มีกระจกเงาเป็นห้องที่ยากที่สุดสำหรับทุกแหล่งที่มีสเกลถูกต้อง (ตารางที่ VII) เมื่อมีหกห้อง การทดสอบ Wilcoxon ตรวจพบได้เฉพาะความต่างที่เกิดในทุกห้อง การเปรียบเทียบครุจึงตัดความเป็นไปได้ ของความต่างขนาดเท่าที่เห็นในค่าเฉลี่ย คือหนึ่งถึงสองเซนติเมตร ออกไปไม่ได้ การเปรียบเทียบหลักถูกกำหนดหลังจากประเมินห้องทดสอบทั้งหมดแล้ว ห้องอีก 20 ห้องของการทดลองที่ 7 จึงถูกเพิ่มภายหลัง เพื่อให้ข้อสรุปตั้งอยู่บนห้องที่ไม่ได้ใช้ตัดสินใจเรื่องใดเลยด้วย แบบจำลองอ้างอิงใช้ท่าทางกล้องจาก ARKit ชุดเดียวกับทุกแถว ระบบจริงบนโทรศัพท์จึงจะมีการเลื่อนของ

ท่าทางกล้องเพิ่มเข้ามา และความครบถ้วนหมายถึงครบเมื่อเทียบกับส่วนที่ Faro มองเห็นเท่านั้น งานนี้ปรับปรุงเฉพาะส่วนหัวของโมเดลเดียวด้วยสูตรเดียว และ FT-Faro-10 กับ FT-LiDAR-10 ต่างกันทั้งจำนวนมุมมองและข้อมูลสอน checkpoint ถูกเลือกด้วยความลึกจาก Faro รวมถึงของโมเดลที่เรียนจาก LiDAR บนสามห้อง FT-LiDAR-24 ถูกเลือกเป็นโมเดลหลัก เพราะดีที่สุดบนสามห้องนั้น และข้อมูลสอนไม่ต้องใช้เครื่องสแกนเลเซอร์ แต่ลำดับนั้นไม่เกิดข้ามห้องทดสอบ และ AbsRel ตอนเลือก checkpoint ของโมเดลนี้เปลี่ยนได้ถึง 0.1 ระหว่าง checkpoint ที่ห่างกัน 500 ชั้น การปรับสเกลครั้งเดียวต่อห้องและด้วยจุดบางแบบเป็นขอบบน เพราะปรับเทียบด้วยค่าอ้างอิง และด้วยจุด LiDAR ที่สะอาดตามลำดับ Depth Pro รันผ่านโค้ดเพียงชุดเดียว และการตรวจเรื่องความยาวโฟกัสครอบคลุมเพียงห้าเฟรมของห้องเดียว เกณฑ์ที่ผูก recall กับงานแต่ละแบบเป็นตัวอย่างที่เรากำหนดเอง ไม่ใช่มาตรฐานของอุตสาหกรรม และเวลาที่วัดได้มาจากโค้ดที่ไม่ได้ปรับแต่ง จึงใช้ได้เฉพาะในรูปอัตราส่วน

E. งานในอนาคต

งานในอนาคตเรียงตามผลกระทบที่คาดไว้ ได้แก่ (1) ใช้จุดเมตริกรายเฟรมจากระบบติดตามของอุปกรณ์ร่วมกับ FT-LiDAR-24 ซึ่งหัวข้อ IV-D ให้ AbsRel 0.051 เมื่อทุกเฟรมได้สเกลที่ถูกต้อง (2) เลือก checkpoint ด้วยความลึกจาก LiDAR เพื่อไม่ต้องใช้เครื่องสแกนเลเซอร์ในขั้นใดเลย และเปรียบเทียบครุบนเฟรมชุดเดียวกันกับห้องทดสอบที่มากขึ้น (3) ฝึกและประเมินกับกล้องโทรศัพท์รุ่นอื่น รวมถึง Android (4) ประเมินด้วยจุดเด่นจริงจาก ARKit หรือ ARCore และค่าอ้างอิงที่เก็บด้วยแอปเอง และ (5) ทดลองปรับปรุงส่วนอื่นของเครือข่ายเพิ่ม รวมถึงโมเดลวิดีโอที่รักษาสเกลให้คงที่ข้ามเฟรม [40]

F. สรุปผล

งานนี้ถามว่าการปรับปรุงโมเดลความลึกจากภาพเดียวแบบเมตริกด้วย LiDAR ของโทรศัพท์เอง ทำให้แม่นยำกว่าโมเดลเดิมหรือไม่ เมื่อวัดเทียบกับเครื่องสแกนเลเซอร์ สำหรับวัตถุประสงค์ข้อ (1) คำตอบคือใช่ บนห้องที่ทดสอบและตามเกณฑ์ในบทที่ II FT-LiDAR-24 ลด Chamfer distance จาก 54.3 เหลือ 15.7 ซม. ในห้องทดสอบครุทั้งหมด และลด AbsRel จาก 0.410 เหลือ 0.130 ใน 19 จาก 20 ห้อง โดยไม่ต้องปรับเทียบหรือใช้เซนเซอร์ขณะใช้งาน และค่าน้ำหนักเรียนจาก LiDAR เพียงอย่างเดียว แม้ within-1.25 $\times$ จะดีขึ้นเพียงห้าในหกห้องทดสอบ สำหรับข้อ (2) ข้อมูลสอนจากเลเซอร์ไม่ได้ดีกว่าจาก LiDAR อย่างวัดได้ และ 24 ห้องก็ไม่ได้ดีกว่า 10 ห้อง ภายใต้กำลังทางสถิติที่จำกัดของหกห้อง และการให้ความยาวโฟกัสจริงไม่ได้ทำให้ Depth Pro แข่งขันได้ สำหรับข้อ (3) โมเดลนี้อยู่ระหว่างโมเดลสัมพัทธ์ ที่ปรับเทียบครั้งเดียวต่อห้อง กับที่ปรับด้วยจุดบางแบบทุกเฟรม ไม่รองรับงานใดในสามแบบ และยังแทน LiDAR ของ iPad (3.0 ซม.) ไม่ได้ สำหรับข้อ (4) ความคลาดเคลื่อนที่เหลือคือสเกลที่แก้ตามมุมมอง ไม่ใช่การเลื่อนสะสมตามเวลา การปรับปรุงขจัดความเอนเอียงของสเกลได้ แต่ไม่ได้ลดการแก้จุดเมตริกรายเฟรมจากระบบติดตามของอุปกรณ์จึงเป็นขั้นตอนต่อไปที่น่าจะได้ผลที่สุด แต่การใช้ร่วมกับโมเดลที่ปรับปรุงแล้วยังต้องทดสอบต่อไป

เอกสารอ้างอิง

- [1] L. Yang, B. Kang, Z. Huang, Z. Zhao, X. Xu, J. Feng, and H. Zhao, "Depth anything V2," in *Advances in Neural Information Processing Systems* (NeurIPS), vol. 37, 2024.
- [2] FARO Technologies, "FARO Focus laser scanners," <https://www.faro.com/en/Products/Hardware/Focus-Laser-Scanners>, accessed 2026-09-29.

- [3] G. Baruch, Z. Chen, A. Dehghan, T. Dimry, Y. Feigin, P. Fu, T. Gebauer, B. Joffe, D. Kurz, A. Schwartz, and E. Shulman, "ARKitScenes: A diverse real-world dataset for 3D indoor scene understanding using mobile RGB-D data," in *Proc. Neural Information Processing Systems Track on Datasets and Benchmarks*, 2021.
- [4] R. Ranftl, A. Bochkovskiy, and V. Koltun, "Vision transformers for dense prediction," in *Proc. IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021, pp. 12 179–12 188.
- [5] B. Curless and M. Levoy, "A volumetric method for building complex models from range images," in *Proc. SIGGRAPH*, 1996, pp. 303–312.
- [6] H. Fan, H. Su, and L. J. Guibas, "A point set generation network for 3D object reconstruction from a single image," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 605–613.
- [7] D. Eigen, C. Puhrsch, and R. Fergus, "Depth map prediction from a single image using a multi-scale deep network," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 27, 2014, pp. 2366–2374.
- [8] Apple Inc., "RoomPlan – apple developer documentation," <https://developer.apple.com/documentation/roomplan>, 2022, accessed 2026-09-17.
- [9] R. Ranftl, K. Lasinger, D. Hafner, K. Schindler, and V. Koltun, "Towards robust monocular depth estimation: Mixing datasets for zero-shot cross-dataset transfer," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 44, no. 3, pp. 1623–1637, 2022.
- [10] L. Yang, B. Kang, Z. Huang, X. Xu, J. Feng, and H. Zhao, "Depth anything: Unleashing the power of large-scale unlabeled data," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024, pp. 10 371–10 381.
- [11] Z. Murez, T. van As, J. Bartolozzi, A. Sinha, V. Badrinarayanan, and A. Rabinovich, "Atlas: End-to-end 3D scene reconstruction from posed images," in *Proc. European Conference on Computer Vision (ECCV)*, 2020, pp. 414–431.
- [12] J. Sun, Y. Xie, L. Chen, X. Zhou, and H. Bao, "NeuralRecon: Real-time coherent 3D reconstruction without 3D convolutions," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021, pp. 15 598–15 607.
- [13] M. Sayed, J. Gibson, J. Watson, V. Prisacariu, M. Firman, and C. Godard, "SimpleRecon: 3D reconstruction without 3D convolutions," in *Proc. European Conference on Computer Vision (ECCV)*, 2022, pp. 1–19.
- [14] S. F. Bhat, R. Birkel, D. Wofk, P. Wonka, and M. Müller, "ZoeDepth: Zero-shot transfer by combining relative and metric depth," *arXiv preprint arXiv:2302.12288*, 2023.
- [15] A. Bochkovskii, A. Delaunoy, H. Germain, M. Santos, Y. Zhou, S. R. Richter, and V. Koltun, "Depth pro: Sharp monocular metric depth in less than a second," in *ICLR*, 2025.
- [16] M. Roberts, J. Ramapuram, A. Ranjan, A. Kumar, M. A. Bautista, N. Paczan, R. Webb, and J. M. Susskind, "Hypersim: A photorealistic synthetic dataset for holistic indoor scene understanding," in *Proc. IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021, pp. 10 892–10 902.
- [17] F. Wilcoxon, "Individual comparisons by ranking methods," *Biometrics Bulletin*, vol. 1, no. 6, pp. 80–83, 1945.
- [18] A. Knapitsch, J. Park, Q.-Y. Zhou, and V. Koltun, "Tanks and temples: Benchmarking large-scale scene reconstruction," *ACM Transactions on Graphics*, vol. 36, no. 4, pp. 78:1–78:13, 2017.
- [19] R. Hartley and A. Zisserman, *Multiple View Geometry in Computer Vision*, 2nd ed. Cambridge University Press, 2004.
- [20] N. Silberman, D. Hoiem, P. Kohli, and R. Fergus, "Indoor segmentation and support inference from RGBD images," in *Proc. European Conference on Computer Vision (ECCV)*, 2012, pp. 746–760.
- [21] A. Geiger, P. Lenz, and R. Urtasun, "Are we ready for autonomous driving? The KITTI vision benchmark suite," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2012, pp. 3354–3361.
- [22] W. Yin, C. Zhang, H. Wang, S. Niklaus, L. Mai, S. Chen, and C. Shen, "Metric3D: Towards zero-shot metric 3D prediction from a single image," in *Proc. IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023, pp. 9043–9053.
- [23] L. Piccinelli, Y.-H. Yang, C. Sakaridis, M. Segu, S. Li, L. Van Gool, and F. Yu, "UniDepth: Universal monocular metric depth estimation," in *CVPR*, 2024.
- [24] M. Oquab, T. Darcet, T. Moutakanni, H. Vo, M. Szafraniec, V. Khaidov, P. Fernandez, D. Haziza, F. Massa, A. El-Nouby et al., "DINOv2: Learning robust visual features without supervision," *Transactions on Machine Learning Research*, 2024.
- [25] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, "An image is worth 16x16 words: Transformers for image recognition at scale," in *Proc. International Conference on Learning Representations (ICLR)*, 2021.
- [26] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson, "How transferable are features in deep neural networks?" in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 27, 2014, pp. 3320–3328.
- [27] G. Luetzenburg, A. Kroon, and A. A. Bjørk, "Evaluation of the Apple iPhone 12 Pro LiDAR for an application in geosciences," *Scientific Reports*, vol. 11, p. 22221, 2021.
- [28] A. Spreafico, F. Chiabrando, L. Teppati Losè, and F. Giulio Tonolo, "The iPad Pro built-in LiDAR sensor: 3D rapid mapping tests and quality assessment," *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, vol. XLIII-B1-2021, pp. 63–69, 2021.
- [29] H. Lin, S. Peng, J. Chen, S. Peng, J. Sun, M. Liu, H. Bao, J. Feng, X. Zhou, and B. Kang, "Prompting depth anything for 4K resolution accurate metric depth estimation," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2025.
- [30] T. Qin, P. Li, and S. Shen, "VINS-Mono: A robust and versatile monocular visual-inertial state estimator," *IEEE Transactions on Robotics*, vol. 34, no. 4, pp. 1004–1020, 2018.
- [31] K. Tateno, F. Tombari, I. Laina, and N. Navab, "CNN-SLAM: Real-time dense monocular SLAM with learned depth prediction," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 6243–6252.
- [32] Z. Yu, S. Peng, M. Niemeyer, T. Sattler, and A. Geiger, "MonoSDF: Exploring monocular geometric cues for neural implicit surface reconstruction," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 35, 2022.
- [33] W. E. Lorensen and H. E. Cline, "Marching cubes: A high resolution 3D surface construction algorithm," in *Proc. SIGGRAPH*, 1987, pp. 163–169.
- [34] R. A. Newcombe, S. Izadi, O. Hilliges, D. Molyneaux, D. Kim, A. J. Davison, P. Kohli, J. Shotton, S. Hodges, and A. Fitzgibbon, "KinectFusion: Real-time dense surface mapping and tracking," in *Proc. IEEE International Symposium on Mixed and Augmented Reality (ISMAR)*, 2011, pp. 127–136.
- [35] Q.-Y. Zhou, J. Park, and V. Koltun, "Open3D: A modern library for 3D data processing," *arXiv preprint arXiv:1801.09847*, 2018.
- [36] A. Dai, A. X. Chang, M. Savva, M. Halber, T. Funkhouser, and M. Nießner, "ScanNet: Richly-annotated 3D reconstructions of indoor scenes," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 2432–2443.
- [37] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in *Proc. International Conference on Learning Representations (ICLR)*, 2019.
- [38] —, "SGDR: Stochastic gradient descent with warm restarts," in *Proc. International Conference on Learning Representations (ICLR)*, 2017.
- [39] K. Pearson, "Note on regression and inheritance in the case of two parents," *Proceedings of the Royal Society of London*, vol. 58, pp. 240–242, 1895.
- [40] S. Chen, H. Guo, S. Zhu, F. Zhang, Z. Huang, J. Feng, and B. Kang, "Video depth anything: Consistent depth estimation for super-long videos," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2025, pp. 22 831–22 840.