

สอนหน่วยเมตรให้โมเดลความลึกจากภาพเดี่ยวด้วย LiDAR ของโทรศัพท์เอง: เปรียบเทียบ Depth Anything V2 แบบ fine-tune กับ แบบ pretrained สำหรับการสร้างแบบจำลองห้อง โดยวัด เทียบกับ laser scanner

Author Name
Affiliation
email@example.com

บทคัดย่อ— โทรศัพท์ส่วนใหญ่ไม่มี LiDAR จึงต้องสแกนห้องด้วยการประมาณความลึกจากภาพเดี่ยว แต่โมเดลสำเร็จรูปที่ให้ความลึกเป็นเมตร เช่น Depth Anything V2 (DA-v2) Metric-Indoor [1] ซึ่งฝึกด้วยภาพสังเคราะห์ ทำให้ห้องที่สร้างได้คลาดเคลื่อน 54.3 ซม. งานวิจัยนี้ศึกษาว่าการปรับจูน (fine-tune) โมเดลดังกล่าวด้วยความลึกจาก LiDAR ของโทรศัพท์เอง โดยใช้เครื่องสแกนเลเซอร์ ทำให้แม่นยำกว่าโมเดลเดิมหรือไม่ เมื่อวัดเทียบกับเครื่องสแกนเลเซอร์ Faro Focus S70 [2] ซึ่งเป็นค่าอ้างอิงของชุดข้อมูล ARKitScenes [3] โดยปรับจูนเฉพาะส่วน DPT head [4] (ตัวถอดรหัสความลึก โดยตรงส่วนเข้ารหัสภาพไว้) ด้วยความลึกจาก LiDAR ของ iPad บน 24 ห้อง ได้โมเดล FT-LiDAR-24 แล้วเปรียบเทียบกับโมเดลเดิมในกระบวนการเดียวกัน คือรวมความลึกรายเฟรมเป็นปริมาตร TSDF (truncated signed distance function) [5] แล้วสร้างเป็นพื้นผิวสามมิติ โดยให้แหล่งความลึกเป็นตัวแปรเดียว บนห้องที่ไม่เคยใช้ฝึก ได้แค่ 6 ห้องที่มีแบบจำลองอ้างอิงจากเครื่องสแกนเลเซอร์ และอีก 20 ห้องที่ประเมินรายเฟรม ผลคือ FT-LiDAR-24 ลดค่า Chamfer distance [6] (ระยะเฉลี่ยถึงจุดที่ใกล้ที่สุดระหว่างพื้นผิวที่สร้างได้กับพื้นผิวอ้างอิง วัดทั้งสองทิศ) จาก 54.3 ซม. เหลือ 15.7 ซม. (ดีขึ้น 3.5 เท่า และดีขึ้นทุกห้อง) และลดค่า AbsRel [7] (ความคลาดเคลื่อนสัมพัทธ์เฉลี่ยของความลึก) จาก 0.410 เหลือ 0.130 (ดีขึ้น 19 จาก 20 ห้อง) โดยไม่ต้องปรับเทียบหรือใช้เซนเซอร์ขณะใช้งาน และการใช้เครื่องสแกนเลเซอร์เป็นครูไม่ได้ดีกว่าอย่างวัดได้ ความคลาดเคลื่อนที่เหลือมาจากสเกลที่กว้างตามมุมมองของแต่ละเฟรม ซึ่งการปรับจูนขจัดไม่ได้ จึงยังด้อยกว่า LiDAR ของ iPad (3.0 ซม.) และยังไม่ถึงระดับความแม่นยำสำหรับดูภาพรวม (พื้นผิวของห้องอย่างน้อย 90% อยู่ภายใน 10 ซม.)

คำสำคัญ—การประมาณความลึกจากภาพเดี่ยว (monocular depth estimation), การเรียนรู้แบบถ่ายโอน (transfer learning), ความลึกแบบเมตริก (metric depth), การใช้ LiDAR เป็นข้อมูลสอน (LiDAR supervision), การรวมความลึกแบบ TSDF (TSDF fusion), การสร้างแบบจำลองสามมิติของห้อง (3D room reconstruction), ARKitScenes

เอกสารอ้างอิง

- [1] L. Yang, B. Kang, Z. Huang, Z. Zhao, X. Xu, J. Feng, and H. Zhao, "Depth anything V2," in Advances in Neural Information Processing Systems (NeurIPS), vol. 37, 2024.
- [2] FARO Technologies, "FARO Focus laser scanners," <https://www.faro.com/en/Products/Hardware/Focus-Laser-Scanners>, accessed 2026-09-29.
- [3] G. Baruch, Z. Chen, A. Dehghan, T. Dimry, Y. Feigin, P. Fu, T. Gebauer, B. Joffe, D. Kurz, A. Schwartz, and E. Shulman, "ARKitScenes: A diverse real-world dataset for 3D indoor scene understanding using mobile RGB-D data," in Proc. Neural Information Processing Systems Track on Datasets and Benchmarks, 2021.
- [4] R. Ranftl, A. Bochkovskiy, and V. Koltun, "Vision transformers for dense prediction," in Proc. IEEE/CVF International Conference on Computer Vision (ICCV), 2021, pp. 12 179–12 188.

- [5] B. Curless and M. Levoy, "A volumetric method for building complex models from range images," in Proc. SIGGRAPH, 1996, pp. 303–312.
- [6] H. Fan, H. Su, and L. J. Guibas, "A point set generation network for 3D object reconstruction from a single image," in Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017, pp. 605–613.
- [7] D. Eigen, C. Puhrsch, and R. Fergus, "Depth map prediction from a single image using a multi-scale deep network," in Advances in Neural Information Processing Systems (NeurIPS), vol. 27, 2014, pp. 2366–2374.