

สอนหน่วยเมตรให้โมเดลความลึกจากภาพเดี่ยวด้วย LiDAR ของโทรศัพท์เอง: เปรียบเทียบ Depth Anything V2 แบบ fine-tune กับ แบบ pretrained สำหรับการสร้างแบบจำลองห้อง โดยวัด เทียบกับ laser scanner

Author Name
Affiliation
email@example.com

บทคัดย่อ— โทรศัพท์ส่วนใหญ่ไม่มี LiDAR จึงต้องสแกนห้องด้วยการประมาณความลึกจากภาพเดี่ยว แต่โมเดลสำเร็จรูปที่ให้ผลเป็นเมตร เช่น Depth Anything V2 (DA-v2) Metric-Indoor [1] ซึ่งฝึกด้วยภาพสังเคราะห์ ทำให้ห้องที่สร้างได้คลาดเคลื่อน 54.3 ซม. งานวิจัยนี้ศึกษาว่าการปรับจูน (fine-tune) โมเดลดังกล่าวด้วยความลึกจาก LiDAR ของโทรศัพท์เอง โดยใช้เครื่องสแกนเลเซอร์ ทำให้แม่นยำกว่าโมเดลเดิมหรือไม่ เมื่อวัดเทียบกับเครื่องสแกนเลเซอร์ Faro Focus S70 [2] ซึ่งเป็นค่าอ้างอิงของชุดข้อมูล ARKitScenes [3] โดยปรับจูนเฉพาะส่วน DPT head [4] (ตัวถอดรหัสความลึก โดยตรงส่วนเข้ารหัสภาพไว้) ด้วยความลึกจาก LiDAR ของ iPad บน 24 ห้อง ได้โมเดล FT-LiDAR-24 แล้วเปรียบเทียบกับโมเดลเดิมในกระบวนการเดียวกัน คือรวมความลึกรายเฟรมเป็นปริมาตร TSDF (truncated signed distance function) [5] แล้วสร้างเป็นพื้นผิวสามมิติ โดยให้แหล่งความลึกเป็นตัวแปรเดียว บนห้องที่ไม่เคยใช้ฝึก ได้แก่ 6 ห้องที่มีแบบจำลองอ้างอิงจากเครื่องสแกนเลเซอร์ และอีก 20 ห้องที่ประเมินรายเฟรม ผลคือ FT-LiDAR-24 ลดค่า Chamfer distance [6] (ระยะเฉลี่ยถึงจุดที่ใกล้ที่สุดระหว่างพื้นผิวที่สร้างได้กับพื้นผิวอ้างอิง วัดทั้งสองทิศ) จาก 54.3 ซม. เหลือ 15.7 ซม. (ดีขึ้น 3.5 เท่า และดีขึ้นทุกห้อง) และลดค่า AbsRel [7] (ความคลาดเคลื่อนสัมพัทธ์เฉลี่ยของความลึก) จาก 0.410 เหลือ 0.130 (ดีขึ้น 19 จาก 20 ห้อง) โดยไม่ต้องปรับเทียบหรือใช้เซนเซอร์ขณะใช้งาน และการใช้เครื่องสแกนเลเซอร์เป็นครุไม่ได้ดีกว่าอย่างวัดได้ ความคลาดเคลื่อนที่เลือกมาจากสเกลที่กว้างตามมุมมองของแต่ละเฟรม ซึ่งการปรับจูนขัดไม่ได้ จึงยังดีกว่า LiDAR ของ iPad (3.0 ซม.) และยังไปถึงระดับความแม่นยำสำหรับดูภาพรวม (พื้นผิวของห้องอย่างน้อย 90% อยู่ภายใน 10 ซม.)

คำสำคัญ— การประมาณความลึกจากภาพเดี่ยว (monocular depth estimation), การเรียนรู้แบบถ่ายโอน (transfer learning), ความลึกแบบเมตริก (metric depth), การใช้ LiDAR เป็นข้อมูลสอน (LiDAR supervision), การรวมความลึกแบบ TSDF (TSDF fusion), การสร้างแบบจำลองสามมิติของห้อง (3D room reconstruction), ARKitScenes

I. บทนำ

การสแกนห้องเป็นแบบจำลองสามมิติเป็นความสามารถที่มีอยู่แล้วใน iPhone Pro และ iPad Pro (เช่น Apple RoomPlan [8]) โดยอาศัยเซนเซอร์ LiDAR วัดความลึกเป็นหน่วยเมตร แต่อุปกรณ์ที่มี LiDAR เป็นส่วนน้อย iPhone รุ่นที่ไม่ใช่ Pro และโทรศัพท์ Android แทบทุกรุ่นไม่มีเซนเซอร์นี้ ทางเลือกของอุปกรณ์เหล่านี้คือการประมาณความลึกจากภาพเดี่ยว (monocular depth estimation) คือการทำนายความลึกจากภาพสีเพียงภาพเดี่ยว ซึ่งพัฒนาอย่างรวดเร็วตั้งแต่ MiDaS [9] จนถึง Depth Anything [1], [10] ทีมพัฒนาผลิตภัณฑ์จึงต้องรู้ว่า **หากใช้โมเดลจากภาพเดี่ยวแทน LiDAR ห้องที่ได้จะคลาดเคลื่อนกี่เซนติเมตร และยังใช้งานแบบใดบ้าง** เกณฑ์วัดมาตรฐานแบบรายภาพ [7] ซึ่งเฉลี่ย

ความคลาดเคลื่อนของความลึกบนพิกเซลของภาพแต่ละภาพ ตอบคำถามนี้ไม่ได้ และระบบสร้างแบบจำลองแบบครบวงจร (end-to-end) [11]–[13] ก็ตอบไม่ได้ เพราะออกแบบกระบวนการทั้งหมดรอบโมเดลของตนเอง

โมเดลรุ่น ใหม่ บาง ตัว ให้ ความ ลึก เป็น เมตร ได้ โดยตรง [1], [14], [15] แต่ฝึกด้วยภาพที่ไม่ได้มาจากกล้องโทรศัพท์ เช่น DA-v2 Metric-Indoor ฝึกด้วยภาพห้องสังเคราะห์จากชุดข้อมูล Hypersim [16] และในการทดลองของเรา ห้องที่สร้างด้วย DA-v2 Metric-Indoor คลาดเคลื่อนเฉลี่ย 54.3 ซม. วิธีแก้โดยตรงคือการปรับจูน (fine-tune) โมเดลด้วยความลึกจากอุปกรณ์เป้าหมาย คำถามคือข้อมูลสอน (label) นี้จะมาจากไหน ระหว่างเครื่องสแกนเลเซอร์ระดับงานสำรวจ [2] ซึ่งผู้พัฒนาแอปเพียงไม่กี่รายมีใช้ กับ LiDAR ที่มีอยู่แล้วในอุปกรณ์รุ่น Pro ซึ่งแอปเก็บความลึกได้ระหว่างการใช้งานปกติ หากวิธีหลังได้ผล อุปกรณ์ที่มี LiDAR ก็จะเป็นครูสอนอุปกรณ์ที่ไม่มี LiDAR ได้

งานวิจัยนี้จึงตั้งคำถามว่า DA-v2 Metric-Indoor ที่ปรับจูนด้วยความลึกจาก LiDAR ของ iPad โดยใช้เครื่องสแกนเลเซอร์ในการฝึก แม่นยำกว่าโมเดลเดิมที่ไม่ได้ปรับจูนหรือไม่ เมื่อวัดเทียบกับเครื่องสแกนเลเซอร์ Faro ซึ่งเป็นค่าอ้างอิงของชุดข้อมูล ARKitScenes [3] บนห้องที่ไม่เคยใช้ฝึก โดยมีวัตถุประสงค์ 4 ข้อ ได้แก่ (1) ปรับจูนโมเดลด้วยความลึกจาก LiDAR ของ iPad จำนวน 24 ห้อง ได้โมเดล FT-LiDAR-24 แล้วเปรียบเทียบกับโมเดลเดิมบนห้องที่ไม่เคยใช้ฝึก โดยถือว่าดีกว่าเมื่อค่าเฉลี่ยความคลาดเคลื่อนต่ำกว่า และผลต่างรายห้องมีนัยสำคัญทางสถิติที่ระดับ 5% ตามการทดสอบ Wilcoxon signed-rank แบบ exact [17] (2) วัดว่าแหล่งของข้อมูลสอนมีผลหรือไม่ โดยเปรียบเทียบข้อมูลสอนจาก Faro กับจาก LiDAR บน 10 ห้องเดียวกัน (FT-Faro-10 กับ FT-LiDAR-10) เปรียบเทียบข้อมูลสอนจาก LiDAR 10 ห้องกับ 24 ห้อง และเปรียบเทียบกับโมเดลที่ใช้ความยาวโฟกัสของกล้องแทนข้อมูลสอนจากโดเมนเป้าหมาย (Depth Pro [15]) (3) ระบุตำแหน่งของ FT-LiDAR-24 เทียบกับแหล่งความลึกที่ใช้ได้ขณะใช้งาน ได้แก่ LiDAR ของ iPad และโมเดลความลึกสัมพัทธ์ที่ปรับสเกลรายเฟรมด้วยจุดเบาบาง (sparse points) หรือปรับสเกลครั้งเดียวต่อห้อง และ (4) หาที่มาของความคลาดเคลื่อนที่การปรับจูนแก้ไม่ได้ โดยหาสเกลความลึกที่เหมาะสมกับแต่ละเฟรม แล้วทดสอบว่าสเกลนั้นเปลี่ยนตามเวลา ซึ่งบ่งชี้การสะสมความคลาดเคลื่อน (drift) หรือเปลี่ยนตามสิ่งที่อยู่ในภาพ

ทุกการเปรียบเทียบวัดสองแบบ แบบแรกวัดเป็นแบบจำลองห้อง

(mesh) ด้วย Chamfer distance [6] คือระยะเฉลี่ยจากแต่ละพื้นผิวถึงจุดที่ใกล้ที่สุดของอีกพื้นผิว และด้วย F-score ที่ 5 ซม. (F@5 cm) [18] ซึ่งรวมสัดส่วนของพื้นผิวที่สร้างได้ที่อยู่ภายใน 5 ซม. จากพื้นผิวอ้างอิง กับสัดส่วนของพื้นผิวอ้างอิงที่ถูกสร้างขึ้นภายใน 5 ซม. แบบที่สองวัดรายเฟรมด้วย AbsRel [7] คือความคลาดเคลื่อนสัมพัทธ์เฉลี่ยของความลึก และด้วยสัดส่วนของพิกเซลที่ความลึกที่ทำนายต่างจากค่าจริงไม่เกิน 1.25 เท่า (ไม่ว่าจะมากหรือน้อยกว่าค่าจริง) ซึ่งเรียกว่า within-1.25× [7] สำหรับวัตถุประสงค์ข้อ (3) สัดส่วนของพื้นผิวอ้างอิงที่ถูกสร้างขึ้นภายใน 2, 5 และ 10 ซม. ใช้แทนความแม่นยำที่งานวัดเพื่อปรับปรุงห้อง งานวางเฟอร์นิเจอร์ และงานดูภาพรวมของห้องต้องการ ตามลำดับ และถือว่ารองรับงานนั้นได้เมื่อสัดส่วนนี้ถึง 90 %

ขอบเขตของงานวิจัยมีดังนี้ ข้อมูลเป็นห้องในบ้านจากชุดข้อมูล ARKitScenes ที่ถ่ายด้วย iPad Pro รุ่นเดียว (ภาพสีขนาด 640×480 พิกเซล และความลึกจาก LiDAR ขนาด 256×192 พิกเซล) ค่าอ้างอิงคือความลึกจาก Faro ที่มากับชุดข้อมูล และไม่ใช่ LiDAR ของ iPad เป็นค่าอ้างอิง การปรับปรุงทำเฉพาะส่วน DPT head [4] ซึ่งเป็นตัวถอดรหัสความลึกของ DA-v2 Metric-Indoor ขนาด Large ด้วยสูตรการฝึกเดียว โดยตรงส่วนเข้ารหัสภาพไว้ ประเมินผลบนห้องทดสอบ 6 ห้องทั้งแบบแบบจำลองห้องและแบบรายเฟรม และอีก 20 ห้องแบบรายเฟรมเท่านั้น ทุกห้องไม่ซ้ำกับห้องที่ใช้ฝึกหรือใช้เลือก checkpoint ทุกแหล่งความลึกผ่านกระบวนการแบบออฟไลน์เดียวกัน คือความลึกรายเฟรม การปรับสเกล การรวมเป็นปริมาตร TSDF (truncated signed distance function) [5] และการสร้างพื้นผิว แหล่งความลึกจึงเป็นตัวแปรเดียว นอกจากนี้ ทุกแหล่งและค่าอ้างอิงใช้ตำแหน่งกล้องชุดเดียวกัน ซึ่งบันทึกโดย ARKit ความคลาดเคลื่อนของตำแหน่งกล้องจึงไม่อยู่ในผลการวัด สิ่งที่อยู่นอกขอบเขต ได้แก่ ระบบสร้างแบบจำลองที่เรียนรู้ทั้งกระบวนการ [11]–[13] กล้องโทรศัพท์รุ่นอื่นรวมถึง Android การประมวลผลแบบเรียลไทม์บนอุปกรณ์ และการประมาณตำแหน่งกล้อง

ประโยชน์ที่คาดว่าจะได้รับสอดคล้องกับวัตถุประสงค์ที่ละข้อ ข้อแรก ผู้พัฒนาแอปจะรู้ว่าข้อมูลที่เก็บได้โดยผู้ใช้งานจากผู้ใช้อุปกรณ์รุ่น Pro ช่วยให้การสแกนห้องบนอุปกรณ์ที่ไม่มี LiDAR ดีขึ้นหรือไม่ โดยไม่ต้องเปรียบเทียบหรือใช้เซนเซอร์เพิ่มเติมขณะใช้งาน ข้อสอง จะรู้ว่าการสร้างข้อมูลสอนจำเป็นต้องใช้เครื่องสแกนเลเซอร์หรือไม่ ข้อสาม จะรู้ว่าอุปกรณ์ที่ไม่มี LiDAR รองรับงานแบบใดบ้าง พร้อมได้กระบวนการที่ประเมินแหล่งความลึกใหม่ได้ด้วยการแก้ค่าตั้งค่าเพียงรายการเดียว และข้อสี่ จะรู้ว่าควรลงทุนพัฒนาส่วนใดต่อ ระหว่างสเกลรายเฟรม ข้อมูลฝึก หรือขนาดโมเดล

II. ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

บทนี้อธิบายทฤษฎีที่งานวิจัยนี้อาศัย ได้แก่ เหตุใดภาพเดียวจึงบอกความลึกเป็นเมตรไม่ได้ โมเดลที่เรานำมาปรับปรุงมีโครงสร้างและฝึกมาอย่างไร และความลึกภาพถ่ายกลายเป็นแบบจำลองห้องได้อย่างไร พร้อมทั้งวางตำแหน่งของงานนี้เทียบกับงานก่อนหน้านี้ในแต่ละประเด็น

A. การประมาณความลึกจากภาพเดียว

ตามแบบจำลองกล้องรูเข็ม (pinhole camera) [19] ขนาดของวัตถุในภาพแปรผันตามขนาดจริงของวัตถุ หากรู้ระยะห่าง แล้วคูณด้วยความยาวโฟกัสของเลนส์ ห้องที่ใหญ่เป็นสองเท่าเมื่อมองจากระยะไกลเป็นสองเท่า จึงให้ภาพเหมือนกันทุกประการ เราคาดเดาเพียงอย่างเดียวจึงหาความลึกเป็นเมตรจากภาพเดียวไม่ได้ โครงข่ายประสาทเทียมทำได้เพียงอนุมานจากสิ่งที่เรียนรู้มา เช่น ความสูงปกติของประตูหรือโต๊ะ และแม้แต่ข้อมูลเหล่านี้ก็ขึ้นกับความยาวโฟกัส เพราะวัตถุเดียวกันที่ระยะเดียวกันจะดูใหญ่ขึ้นเมื่อใช้เลนส์ที่ยาวขึ้น Eigen และคณะ [7] เป็นงานแรก ๆ ที่ใช้โครงข่ายเชิงลึกกับปัญหานี้ และเพราะ

ความกำกวมดังกล่าว จึงวัดความคลาดเคลื่อนบนลอการิทึมของความลึก ในรูปแบบที่แยกความคลาดเคลื่อนของสเกลโดยรวมของฉากออกจากความคลาดเคลื่อนของรูปทรง ฟังก์ชันสูญเสีย (loss) แบบไม่ขึ้นกับสเกลบนลอการิทึมนี้ในรูปแบบถ่วงน้ำหนัก เรียกว่า SiLog ใช้ฝึกทั้ง ZoeDepth [14] และโมเดลที่ปรับปรุงในงานนี้

โมเดลแบ่งได้เป็นสองกลุ่มตามวิธีจัดการกับสเกลที่หายไป กลุ่มแรกคือโมเดลความลึกสัมพัทธ์ (relative) ซึ่งไม่พยายามหาสเกล MiDaS [9] ฝึกโครงข่ายเดียวด้วยชุดข้อมูลหลายชุดที่วัดความลึกด้วยเซนเซอร์และหน่วยต่างกัน ซึ่งทำได้ก็ต่อเมื่อฟังก์ชันสูญเสียไม่สนใจสเกลและค่าเลื่อน (offset) ของแต่ละภาพ ผลลัพธ์จึงเป็นส่วนกลับของความลึก (disparity) ที่ถูกต้องเฉพาะเมื่อรู้สเกลและค่าเลื่อนของภาพนั้น ต้องหาตัวเลขสองตัวนี้จากข้อมูลอื่นก่อนจึงจะได้ความลึกเป็นเมตร Depth Anything [10] และ Depth Anything V2 [1] (DA-v2) ให้ผลลัพธ์แบบเดียวกัน แต่ฝึกด้วยภาพจำนวนมากมาก กลุ่มที่สองคือโมเดลความลึกแบบเมตริก (metric) ซึ่งให้ความลึกเป็นเมตรโดยตรง โดยเรียนรู้สเกลจากข้อมูลที่มีค่าความลึกกำกับ ZoeDepth [14] ต่อส่วนทำนายแบบเมตริกที่ปรับปรุงด้วย NYU Depth v2 [20] และ KITTI [21] เข้ากับโมเดลความลึกสัมพัทธ์ ส่วน DA-v2 มีรุ่นเมตริกที่ปรับปรุงจากรุ่นสัมพัทธ์ของตนเอง โดยรุ่นในอาคาร (DA-v2 Metric-Indoor) ปรับปรุงด้วยภาพห้องที่เรนเดอร์จากชุดข้อมูล Hypersim [16] อีกแนวทางหนึ่งจัดการกับความยาวโฟกัสโดยตรง Metric3D [22] แปลงทุกภาพให้เป็นภาพจากกล้องมาตรฐานที่มีความยาวโฟกัสคงที่ UniDepth [23] ทำนายพารามิเตอร์ของกล้องไปพร้อมกับความลึก และ Depth Pro [15] ประมาณความยาวโฟกัสเองเมื่อไม่ได้รับค่านีมา งานเหล่านี้รายงานผลเป็นตัวชี้วัดรายภาพบนชุดทดสอบมาตรฐาน เช่น NYU Depth v2 และ KITTI ตัวชี้วัดดังกล่าวเฉลี่ยจากภาพที่เป็นอิสระต่อกัน จึงไม่บอกว่าคุณค่าของโมเดลคงที่หรือไม่ ตลอดเฟรมของการสแกนครั้งเดียว ซึ่งเป็นสิ่งสำคัญเมื่อนำเฟรมทั้งหมดมารวมเป็นห้องเดียว

B. โครงสร้างและการฝึกของ Depth Anything V2

DA-v2 ประกอบด้วยส่วนเข้ารหัสภาพ (encoder) และส่วนถอดรหัสความลึก (decoder) ส่วนเข้ารหัสคือ DINOv2 [24] ซึ่งเป็น vision transformer (ViT) [25] โดยแบ่งภาพเป็นชิ้นสี่เหลี่ยมเล็ก ๆ (patch) แล้วให้แต่ละชิ้นดึงข้อมูลจากชิ้นอื่นทุกชิ้นผ่านกลไกที่เรียกว่า self-attention DINOv2 ผ่านการฝึกล่วงหน้าโดยไม่ใช้ข้อมูลกำกับ บนชุดภาพขนาดใหญ่ที่คัดสรรแล้ว เพื่อให้คุณลักษณะ (feature) ที่ได้ใช้กับงานได้หลากหลาย ส่วนถอดรหัสคือ Dense Prediction Transformer (DPT) [4] ซึ่งนำคุณลักษณะจากหลายชั้นของส่วนเข้ารหัสมาประกอบกลับเป็นแผนที่คล้ายภาพที่หลายความละเอียด แล้วรวมเป็นแผนที่ความลึกแบบหนาแน่นเพียงแผนที่เดียว โค้ดของโมเดลแบ่งส่วนถอดรหัสเป็น neck ซึ่งทำหน้าที่ประกอบและรวมคุณลักษณะ กับ head ซึ่งให้ค่าความลึกออกมา ในรายงานนี้คำว่า DPT head หมายถึงทั้งสองส่วน เช่นเดียวกับในบทนำ

DA-v2 เองก็ฝึกด้วยครู (teacher) กล่าวคือ ฝึกโมเดลขนาดใหญ่ด้วยภาพสังเคราะห์ซึ่งมีความลึกที่แม่นยำก่อน จากนั้นให้โมเดลนี้กำกับความลึกให้ภาพจริงที่ไม่มีมีความลึกราว 62 ล้านภาพ แล้วจึงให้โมเดลที่เผยแพร่เรียนรู้จากค่ากำกับที่โมเดลสร้างขึ้นนี้ ซึ่งเรียกว่า pseudo-label [1] ผู้พัฒนา DINOv2 รายงานว่าทำนายความลึกได้ดีแม้ตรงส่วนเข้ารหัสไว้ และฝึกเฉพาะส่วนถอดรหัส DPT ที่ต่อด้านบน [24] การนำโมเดลที่ฝึกกับงานหรือโดเมนหนึ่งมาปรับใช้กับอีกงานหรือโดเมนหนึ่ง เช่นนี้เรียกว่าการเรียนรู้แบบถ่ายโอน (transfer learning) [26] การฝึกเฉพาะส่วนถอดรหัสแบบที่งานนี้ทำใช้หน่วยความจำน้อยกว่ามาก และยังคงคุณลักษณะทั่วไปที่ส่วนเข้ารหัสเรียนรู้มาจากภาพหลายล้านภาพไว้

C. การฝึกด้วยความลึกจากเซนเซอร์

โมเดลความลึกแบบมีผู้สอน (supervised) ใช้ความลึกที่วัดจากเซนเซอร์เป็นข้อมูลสอนมานานแล้ว โดยไม่ต้องให้คนกำกับ ตัวอย่างเช่น NYU Depth v2 ให้ความลึกในอาคารจากกล้อง Microsoft Kinect [20] KITTI ให้ความลึกบนถนนจากเครื่องสแกนเลเซอร์ที่ติดบนรถยนต์ [21] และ Eigen และคณะ [7] ฝึกด้วยทั้งสองชุด สิ่งที่แตกต่างกันระหว่างงานเหล่านี้คือคุณภาพของเซนเซอร์ บน iPhone Pro และ iPad Pro นั้น ARKit รวมค่าที่วัดได้จาก LiDAR กับภาพสีเป็นแผนที่ความลึกขนาด 256×192 พิกเซล พร้อมค่าความเชื่อมั่นของทุกพิกเซล [3] งานที่ทดสอบ LiDAR นี้เทียบกับวิธีสำรวจที่เป็นที่ยอมรับพบว่า แม่นยำราว 1 ซม. กับวัตถุที่ใหญ่กว่า 10 ซม. [27] และเพียงพอสำหรับการทำแผนที่สถาปัตยกรรมอย่างรวดเร็วที่มาตรฐาน 1:200 [28] จึงมีเหตุผลที่จะใช้เป็นครู ARKitScenes [3] ให้ความลึกนี้คู่กับความลึกจากเครื่องสแกนเลเซอร์ระดับงานสำรวจ Faro [2] ของห้องเดียวกัน โดยจัดให้ตรงกับเฟรมกล้องเดียวกัน และใช้ความลึกจาก Faro เป็นค่าอ้างอิง ในโจทย์ที่เพิ่มความละเอียดของความลึกจาก LiDAR โดยอาศัยภาพสี Prompt Depth Anything [29] ซึ่งเป็นงานที่ใช้ข้อมูลใกล้เคียงกับงานนี้ที่สุด ก็ป้อนความลึกจาก LiDAR ของ iPhone เข้าโมเดล Depth Anything เป็นข้อมูลนำเข้าเพิ่มเติมเช่นกัน ในทั้งสองงาน LiDAR ต้องมีอยู่ทุกครั้งที่ไม่เดลทำงาน ส่วนงานนี้ใช้ LiDAR เฉพาะตอนฝึก โมเดลที่นำไปใช้จึงต้องการเพียงภาพสี คำถามว่าครูที่มีสัญญาณรบกวนมากกว่านี้ ช่วยโมเดลขนาดใหญ่ที่ผ่านการฝึกล่วงหน้าได้เท่ากับเครื่องสแกนเลเซอร์หรือไม่ เมื่อตัดสินใจด้วยค่าอ้างอิงจากเลเซอร์ที่เป็นอิสระ คือเรื่องของวัตถุประเภทข้อ (1) และ (2)

D. จากแผนที่ความลึกสู่แบบจำลองห้อง

การรวมเฟรมต้องรู้ท่าทางกล้อง (camera pose) ของแต่ละเฟรม คือตำแหน่งและทิศทางของกล้อง ARKit ติดตามท่าทางกล้องด้วย visual-inertial odometry (VIO) ซึ่งติดตามจุดเด่นในภาพจากเฟรมหนึ่งไปอีกเฟรมหนึ่ง แล้วรวมกับเซนเซอร์วัดการเคลื่อนที่ของอุปกรณ์ [30] เนื่องจากเซนเซอร์วัดการเคลื่อนที่วัดความเร่งเป็นหน่วยเมตริก จุดที่ติดตามได้จึงมีตำแหน่งเป็นเมตร จุดเบาบาง (sparse points) เหล่านี้จึงให้สเกลและค่าเลื่อนที่โมเดลความลึกสัมผัสขาดไปได้ที่เลเฟรม แนวคิดการใช้ความลึกจากโครงข่ายร่วมกับเรขาคณิตแบบเบาบางของระบบติดตามมีมาตั้งแต่ CNN-SLAM [31] และ MonoSDF [32] ก็หาสเกลและค่าเลื่อนของทุกภาพก่อนนำความลึกจากภาพเดียวไปช่วยสร้างพื้นผิว การปรับสเกลด้วยจุดเบาบางของงานนี้ในหัวข้อ III-C ก็อยู่ในแนวทางนี้

ขั้นตอนคือการสร้างห้อง ซึ่งทำโดยรวมความลึกเป็น truncated signed distance function (TSDF) [5] โดยแบ่งพื้นที่เป็นลูกบาศก์เล็ก ๆ เรียกว่า voxel แต่ละ voxel เก็บระยะถึงพื้นผิวที่ใกล้ที่สุดที่สังเกตได้ เป็นบวกเมื่ออยู่หน้าพื้นผิวและเป็นลบเมื่ออยู่หลังพื้นผิว ตัดทิ้ง (truncate) เมื่อไกลเกินไม่กี่ voxel แล้วเฉลี่ยค่านี้จากทุกเฟรมที่มองเห็น voxel นั้น จากนั้นจึงสกัดพื้นผิวตรงตำแหน่งที่ค่าเฉลี่ยเปลี่ยนเครื่องหมาย ด้วยอัลกอริทึม marching cubes [33] Kinect-Fusion [34] ทำให้การรวมแบบนี้ทำงานได้แบบเรียลไทม์ กับความลึกจาก Kinect และงานนี้ใช้การทำงานที่มีอยู่ใน Open3D [35] การเฉลี่ยช่วยลดสัญญาณรบกวนที่สุ่มเปลี่ยนไปในแต่ละเฟรม แต่เฟรมที่มีสเกลไม่ตรงกันจะวางแผนผังเดียวกันไว้ที่ระยะต่างกัน ค่าเฉลี่ยจึงทำให้แผนผังเบลอหรือหนาขึ้น ความคงที่ของสเกลระหว่างเฟรม ซึ่งตัวชี้วัดรายการภาพไม่ได้วัด จึงกำหนดคุณภาพของห้อง นอกจากนี้ การรวมแบบ TSDF ไม่ขึ้นกับว่าความลึกเป็นเมตรนั้นมาจากแหล่งใด จึงเป็นขั้นตอนคงที่ที่ยุติธรรมกับแหล่งความลึกทุกแหล่ง

ส่วนระบบสร้างแบบจำลองที่เรียนรู้ทั้งกระบวนการ (learned reconstruction) จะแทนที่บางขั้นตอนข้างต้น ด้วยโครงข่ายประสาท

เทียม Atlas [11] ทำนาย TSDF โดยตรง จากคุณลักษณะของภาพหลายภาพที่รู้ท่าทางกล้อง NeuralRecon [12] ทำแบบเดียวกันที่ละส่วนและแบบเรียลไทม์ และ SimpleRecon [13] ประเมินความลึกจากหลายเฟรมข้างเคียง ก่อนรวมด้วยวิธีดั้งเดิม ทดงานประเมินผลบน ScanNet [36] ซึ่งเป็นชุดการสแกนภาพสีและความลึกในอาคารขนาดใหญ่ แต่ละงานต้องใช้หลายเฟรมต่อการทำนายหนึ่งครั้ง และใช้โครงข่ายที่ฝึกมาสำหรับกระบวนการของตนเอง จึงตอบคำถามต่างจากงานนี้ ซึ่งถามว่าโมเดลจากภาพเดียวให้ห้องแบบใด เมื่อส่วนอื่นของกระบวนการไม่เปลี่ยน งานนี้จึงไม่เปรียบเทียบกับงานกลุ่มนี้

E. การวัดคุณภาพของแบบจำลองห้อง

แบบจำลองห้องที่สร้างได้จะเทียบกับพื้นผิวอ้างอิงผ่านระยะระหว่างจุดที่สุ่มบนพื้นผิวทั้งสอง Chamfer distance [6] เฉลี่ยระยะจากแต่ละจุดถึงจุดที่ใกล้ที่สุดของอีกพื้นผิวทั้งสองทิศทาง ส่วน Tanks and Temples [18] กำหนดระยะเกณฑ์ไว้ แล้วรายงานความแม่นยำ (precision) คือสัดส่วนของพื้นผิวที่สร้างได้ที่อยู่ภายในระยะเกณฑ์จากพื้นผิวอ้างอิง ความครบถ้วน (recall) คือสัดส่วนของพื้นผิวอ้างอิงที่อยู่ภายในระยะเกณฑ์จากพื้นผิวที่สร้างได้ และค่าเฉลี่ยฮาร์โมนิกของทั้งสอง คือ F-score ระยะเกณฑ์ทำให้คะแนนผูกกับการใช้งาน ซึ่งเป็นวิธีที่พบทั่วไปใช้เชื่อมระยะ 2, 5 และ 10 ซม. กับงานวัดเพื่อปรับปรุงห้อง งานวางเฟอร์นิเจอร์ และงานดูภาพรวมของห้อง สำหรับการวัดรายการเฟรม งานนี้ใช้ AbsRel และ within-1.25 $\times$ จากงานด้านการประมาณความลึกจากภาพเดียว [7]

F. ตำแหน่งของงานวิจัยนี้


โดยสรุป งานก่อนหน้ารายงานความแม่นยำรายการภาพของโมเดลความลึกบนชุดทดสอบมาตรฐาน ปรับโมเดลเมตริกด้วยข้อมูลกำกับจากภาพสังเคราะห์หรือจากเซนเซอร์ของชุดข้อมูลสาธารณะ ป้อน LiDAR ของอุปกรณ์พกพาเข้าโมเดลขณะใช้งาน หรือทดสอบตัว LiDAR ของอุปกรณ์พกพาเองเทียบกับวิธีสำรวจ เราไม่พบงานที่รวมประเด็นเหล่านี้ไว้แบบงานนี้ กล่าวคือ ใช้ LiDAR ของอุปกรณ์ผู้บริโภคเป็นครูเฉพาะตอนฝึก เปรียบเทียบกับการใช้เครื่องสแกนเลเซอร์ระดับงานสำรวจเป็นครูบนห้องชุดเดียวกัน และตัดสินใจด้วยค่าอ้างอิงจากเลเซอร์ที่เป็นอิสระ ทั้งเป็นเซนติเมตรบนแบบจำลองห้องและแบบรายการเฟรม

III. วิธีดำเนินการวิจัย

งานวิจัยนี้เปรียบเทียบแหล่งความลึกภายในกระบวนการสร้างแบบจำลองห้องที่คงที่เพียงกระบวนการเดียว (รูปที่ 1) สำหรับทุกห้องและทุกแหล่งความลึก กระบวนการจะ (1) อ่านภาพสีและท่าทางกล้อง (2) สร้างแผนที่ความลึกของทุกเฟรมจากแหล่งความลึกนั้น (3) แปลงความลึกเป็นเมตร หากแหล่งนั้นไม่ได้ให้ค่าเป็นเมตร (4) รวมทุกเฟรมเป็นแบบจำลองห้อง (mesh) และ (5) วัดทั้งความลึกรายการเฟรมและแบบจำลองห้องเทียบกับค่าอ้างอิงจาก Faro ระหว่างแถวต่าง ๆ ของตารางผล มีเพียงขั้นที่ (2) และ (3) ที่เปลี่ยน โดยแต่ละขั้นเลือกได้ด้วยค่าตั้งค่าเพียงรายการเดียว ส่วนขั้นตอนหลังจากนั้นใช้โค้ดเดียวกันและค่าตั้งค่าเดียวกันทุกครั้ง โมเดลที่ปรับจนแล้วเข้าสู่กระบวนการที่ขั้น (2) ในฐานะแหล่งความลึกแหล่งหนึ่งตามปกติ บทนี้อธิบายข้อมูล แต่ละขั้นตอน การปรับจน ตัวชี้วัดและสถิติ และการทดลอง

A. ข้อมูล ห้อง และค่าอ้างอิง

ARKitScenes [3] ให้ข้อมูลของห้องเดียวกันหลายอย่าง ได้แก่ วิดีโอสีจาก iPad Pro (ขนาด 640×480 พิกเซล) ความลึกจาก LiDAR ที่ ARKit สร้างขึ้น (ขนาด 256×192 พิกเซล พร้อมค่าความเชื่อมั่นระดับต่ำ กลาง หรือสูงของทุกพิกเซล) ท่าทางกล้องของทุกเฟรมจาก visual-inertial odometry ของ ARKit และความ



รูปที่ 1. กระบวนการของงานวิจัย สองขั้นที่เน้นสีเป็นเพียงสองขั้นที่เปลี่ยนระหว่างแถวของตารางผล โดยเปลี่ยนด้วยค่าตั้งคํารายการเดียว ขั้นตอนหลังจากนั้นคงที่ทั้งหมด การปรับปรุง (เส้นประ) ทำครั้งเดียวล่วงหน้า และทำหน้าที่เพียงให้ค่าน้ำหนักของโมเดลจากภาพเดี่ยว

ตารางที่ I

ห้องทดสอบ ประเมินทั้งแบบสามมิติและแบบรายเฟรม จำนวนเฟรม คือจำนวนเฟรมของ Faro ที่ใช้ประเมินทุกแถว

รหัสการสแกน	ห้อง	ขนาด (ม.)	จำนวนเฟรม
42444474	ครัวและห้องทานข้าว มีกระจก (ห้องที่ใช้ระหว่างพัฒนา)	9.9 × 5.1 × 4.2	236
47333774	ห้องนอนทั่วไป	5.1 × 4.9 × 3.3	375
47115299	ห้องนั่งเล่นขนาดใหญ่	8.1 × 6.1 × 2.5	324
42897743	ห้องน้ำ (กระจกเงา กระจกเงา)	8.0 × 3.4 × 3.6	448
47429736	ห้องนอนที่มีตู้เสื้อผ้า	6.6 × 6.4 × 2.7	504
45261556	ครัว (ตู้ครัวมันวาว)	7.1 × 6.1 × 2.4	465

ลึกจากเครื่องสแกนเลเซอร์ Faro [2] ที่จัดให้ตรงกับท่าทางกล้องเหล่านั้น (ขนาด 1920×1440 พิกเซล ประมาณสี่เฟรมต่อวินาที) ค่าอ้างอิงคือความลึกจาก Faro ตามที่ชุดข้อมูลให้มา สำหรับการประเมินรายเฟรม ความลึกนี้ถูกลดขนาดเป็น 256×192 โดยใช้พิกเซลที่ใกล้ที่สุด ค่าอ้างอิงทุกค่าจึงเป็นค่าที่วัดได้จริง สำหรับการประเมินแบบสามมิติ เนื่องจากชุดข้อมูลไม่มีแบบจำลองจากเลเซอร์ให้ เราจึงรวมความลึกจาก Faro ของทุกเฟรมด้วย voxel ขนาด 1 ซม. ครึ่งเดียวต่อห้อง เป็นแบบจำลองอ้างอิง ด้วยวิธีรวมในหัวข้อ III-D เนื่องจากแบบจำลองอ้างอิงและแหล่งความลึกทุกแหล่งใช้ท่าทางกล้องชุดเดียวกัน ความคลาดเคลื่อนของท่าทางกล้องจึงไม่อยู่ในผลการวัดและความต่างทุกอย่างระหว่างแถวมาจากแหล่งความลึกเท่านั้น งานนี้ไม่ใช่ LiDAR ของ iPad เป็นค่าอ้างอิงเลย

ห้องทดสอบทั้งหกห้อง (ตารางที่ I) ครอบคลุมห้องนอนทั่วไป ห้องขนาดใหญ่ และห้องที่มีกระจกเงาหรือพื้นผิวมันวาว ห้อง 42444474 ถูกใช้ระหว่างการพัฒนากระบวนการ ผลของห้องนี้จึงไม่นับเป็นข้อมูลที่กันไว้ ผลรายห้องจึงช่วยให้ผู้อ่านตรวจสอบข้อสรุปทุกข้อกับอีกห้าห้องที่เหลือได้ ห้องสำหรับการปรับปรุงสุ่มเลือก (seed 0) จากการสแกนใน ARKitScenes ที่ยาว 60 ถึง 120 วินาที โดยตัดทุก visit ของห้องทดสอบออก visit คือการเก็บข้อมูลบ้านหลังหนึ่งในครั้งเดียว ซึ่งวิดีโอในครั้งนั้นแสดงห้องเดียวกัน ได้ห้องฝึก 10 ห้องที่มีทั้งความลึกจาก Faro และ LiDAR อีก 14 ห้องที่มีเฉพาะ LiDAR และ 3 ห้องจากกลุ่ม Validation ของชุดข้อมูลสำหรับเลือก checkpoint การทดลองที่ 7 เพิ่มอีก 20 ห้องจากกลุ่ม Validation โดยเลือกหนึ่งวิดีโอต่อ visit สุ่มด้วย seed 0 และตัดทุก visit ของห้องฝึก ห้องเลือก checkpoint และห้องทดสอบออก ห้องเหล่านี้ไม่ได้ใช้ตัดสินใจเรื่องใดเลย และประเมินแบบรายเฟรมเท่านั้น บนทุกเฟรมที่สองของ Faro (รวม 2,090 เฟรม)

B. แหล่งความลึก

งานนี้เปรียบเทียบแหล่งความลึกสี่ประเภท (1) ความลึกจาก Faro เอง ซึ่งแสดงว่ากระบวนการสูญเสียความแม่นยำเท่าใด เมื่อความลึกสมบูรณ์ เพราะที่ voxel ขนาด 4 ซม. ผลยังต่างจากแบบจำลองอ้างอิงที่ 1 ซม. และความต่างนี้คือความสูญเสียจากการแบ่งช่องของกระบวนการเอง (2) ความลึกจาก LiDAR ของ iPad ตามที่ ARKit บันทึก ซึ่งเป็นสิ่งที่อุปกรณ์รุ่น Pro ใช้อยู่ในปัจจุบัน (3) โมเดลความลึกสัมผัส ซึ่งต้องปรับสเกลตามหัวข้อ III-C ได้แก่ DA-v2 Large ในการทดลองหลัก และ DA-v2 Small กับ MiDaS small [9] เมื่อทดลองเปลี่ยนขนาดโมเดล (4) โมเดลความลึกแบบเมตริก ซึ่งใช้โดยไม่ปรับสเกล ได้แก่ DA-v2 Metric-Indoor Large แบบเดิม โมเดลที่ปรับจนแล้วสามตัว (หัวข้อ III-E) และ Depth Pro [15] ซึ่งได้รับความยาวโฟกัสจริงของกล้อง 533 พิกเซล อันเป็นเงื่อนไขที่ได้เปรียบที่สุดของโมเดลนี้ ARKitScenes เก็บภาพจาก iPad ที่ถือในแนวตั้งโดยหมุนไปหนึ่งในสี่รอบ โมเดลจากภาพเดี่ยวทุกตัวจึงได้รับภาพที่หมุนให้ตั้งตรงก่อน แล้วจึงหมุนผลลัพธ์กลับ แหล่งความลึกทุกแหล่งถูกปรับขนาดด้วยพิกเซลที่ใกล้ที่สุดเป็นความละเอียดของ LiDAR คือ 256×192 เพื่อให้ทุกแหล่งถูกรวมและวัดผลบนตารางพิกเซลเดียวกัน

C. การปรับสเกล

โมเดลความลึกสัมผัสให้ส่วนกลับของความลึกที่ยังไม่รู้สเกลและค่าเลื่อนของแต่ละภาพ (บทที่ II) การปรับสเกลคือการหาสเกลและค่าเลื่อน ที่ทำให้ส่วนกลับของความลึกจากโมเดล ตรงกับส่วนกลับของความลึกอ้างอิงชุดหนึ่งมากที่สุด แล้วแปลงผลกลับเป็นความลึก การหาค่าบนส่วนกลับของความลึกแทนที่จะหาบนความลึกโดยตรงสอดคล้องกับวิธีที่โมเดลเหล่านี้ถูกฝึก และในห้องที่ใช้ระหว่างพัฒนา การเปลี่ยนนี้ลด Chamfer distance ของ oracle รายเฟรมจาก 15.2 เหลือ 5.4 ซม. การหาค่าใช้วิธีกำลังสองน้อยที่สุด (least squares) ทำซ้ำสามรอบ แต่ละรอบตัดพิกเซล 20 % ที่มีค่าคลาดเคลื่อนมากที่สุดออก เพราะขอบของวัตถุทำให้เกิดค่าคลาดเคลื่อนขนาดใหญ่มากจำนวนหนึ่ง ซึ่งจะดึงผลการหาค่าให้เพี้ยน วิธีปรับสเกลทั้งสี่แบบต่างกันเพียงความลึกอ้างอิงที่ใช้หาค่า (ตารางที่ II) แหล่งความลึกแบบเมตริกใช้แบบไม่ปรับสเกล และกระบวนการจะไม่สามารถทำงานหากตั้งค่าเป็นอย่างอื่น

สำหรับวิธีจุดเบาบาง การหาค่าทำซ้ำสองรอบและตัดจุดที่แย่ที่สุด 10 % ออก เฟรมที่มีจุดใช้งานได้น้อยกว่า 20 จุดจะใช้สเกลและค่าเลื่อนของเฟรมก่อนหน้า เช่นเดียวกับที่ระบบจริงจะทำได้เมื่อการติดตามภาพหลุดไปชั่วคราว

ตารางที่ II

วิธีปรับสเกล ทุกวิธียกเว้นแบบไม่ปรับ หาสเกลหนึ่งค่าและค่าเลื่อนหนึ่งค่าบนส่วนกลับของความลึก ด้วยวิธีกำลังสองน้อยที่สุดแบบตัดค่าผิดปกติ

วิธี	หาค่าจากข้อมูลใด และแถวนี้บอกอะไร
ไม่ปรับ	ไม่หาค่าใดเลย ใช้กับ Faro, LiDAR และโมเดลแบบเมตริก
oracle รายเฟรม	ความลึกจาก Faro ของเฟรมนั้นเอง แสดงขีดสูงสุดที่รูปทรงจากโมเดลทำได้ (ใช้ในผลิตภัณฑ์จริงไม่ได้)
ครั้งเดียวต่อห้อง	ความลึกจาก Faro ของ 10 เฟรมที่กระจายตลอดการสแกน หาค่าครั้งเดียวแล้วใช้กับทุกเฟรม เป็นขอบบนของการปรับเทียบเพียงครั้งเดียว
จุดเบาบาง	จุดที่รู้ความลึกเป็นเมตร 200 จุดต่อเฟรม ใช้แทนจุดเด่นของ VIO (บทที่ II) ARKitScenes ไม่ได้เก็บจุดเหล่านี้ไว้ จึงสุ่มจากพิกเซลของ LiDAR ที่มีความเชื่อมั่นสูง ซึ่งแม่นยำกว่าจุดที่คำนวณจากภาพ จึงเป็นขอบบนของระบบที่ใช้ VIO

D. การรวมเป็นแบบจำลองห้อง

แผนที่ความลึกถูกรวมด้วยวิธี TSDF (บทที่ II) ใน Open3D [35] โดยใช้ voxel ขนาด 4 ซม. ระยะตัด (truncation) 12 ซม. หรือสาม voxel และใช้ความลึกตั้งแต่ 0.1 ถึง 5 ม. ทุกแหล่งความลึกรวมเฉพาะพิกเซลที่ Faro มีความลึก เพื่อไม่ให้แหล่งใดเสียคะแนนจากการมองเห็นส่วนของห้องที่ค่าอ้างอิงไม่ครอบคลุม และทุกพิกเซลมีน้ำหนักเท่ากัน (มีเพียงการทดลองที่ 5 ที่ถ่วงน้ำหนักพิกเซลตามความเชื่อมั่นของ LiDAR) พื้นผิวถูกสกัดด้วย marching cubes [33] แล้วลบชิ้นส่วนที่เชื่อมกันน้อยกว่า 1000 สามเหลี่ยมออก เพราะเป็นสัญญาณรบกวนที่ลอยอยู่ ทุกแถวใช้ทำทางกล้องจาก ARKit ที่มากับชุดข้อมูล

E. การปรับจูน

โมเดลที่ปรับจูนจาก DA-v2 Metric-Indoor Large มีสามตัว ใช้สูตรการฝึกเดียวกัน และต่างกันเพียงข้อมูลสอน FT-Faro-10 เรียนจากความลึกของ Faro บนห้องฝึก 10 ห้อง (3594 เฟรม) FT-LiDAR-10 เรียนจากความลึกของ LiDAR ของ iPad บน 10 ห้องเดียวกัน (8656 เฟรม) และ FT-LiDAR-24 ซึ่งเป็นโมเดลหลัก เรียนจากความลึกของ LiDAR บนทั้ง 24 ห้อง (19896 เฟรม) พิกเซลของ LiDAR ที่มีความเชื่อมั่นต่ำถูกตัดออก และไม่ใช้ข้อมูลสอนที่ไกลเกิน 10 ม. ครึ่งทั้งสองแบบเห็นเฟรมไม่เหมือนกัน เพราะความลึกจาก Faro มีประมาณสี่เฟรมต่อวินาที ขณะที่ความลึกจาก LiDAR มากับภาพสี่เฟรมต่อวินาที ซึ่งเราเลือกใช้ทุกเฟรมที่สาม (ประมาณสิบเฟรมต่อวินาที) FT-LiDAR-10 จึงเห็นมุมมองที่ต่างกัน มากกว่า FT-Faro-10 ประมาณ 2.4 เท่า

ส่วนเข้ารหัสภาพถูกตรึงไว้ และฝึกเฉพาะส่วนถอดรหัส DPT คือ neck และ head (บทที่ II) ภาพฝึกแต่ละภาพถูกหมุนให้ตั้งตรงปรับขนาดให้ด้านสั้นยาว 518 พิกเซล แล้วตัดเป็น 518×518 ที่ตำแหน่งสุ่ม โดยไม่ขยายภาพเลย เพราะการขยายภาพทำให้วัตถุใหญ่ขึ้นและจะสอนระยะเป็นเมตรที่ผิด การพลิกภาพแนวนอน (ความน่าจะเป็น 0.5) และการสุ่มปรับสี (ความแรง 0.2) ช่วยเพิ่มความหลากหลาย ฟังก์ชันสูญเสียคือ SiLog (บทที่ II) ซึ่งสำหรับแต่ละภาพ คือความแปรปรวนของผลต่างระหว่างลอการิทึมของความลึกที่ทำนายกับของข้อมูลสอน ซึ่งวัดรูปทรง บวกกับ 0.15 เท่าของกำลังสองของค่าเฉลี่ยของผลต่างนั้น ซึ่งวัดสเกลโดยรวม แล้วนำรากที่สองของผลรวมคูณด้วย 10 ตัวหาค่าเหมาะที่สุด (optimiser) คือ AdamW [37] ซึ่งเป็นรูปแบบหนึ่งของ Adam ที่แยกการลดค่าน้ำหนัก (weight decay) ออกจากขั้นตอนตามเกรเดียนต์ ใช้อัตราการเรียนรู้ 5×10^{-5} weight decay 0.01 เพิ่มอัตราการเรียนรู้แบบเส้นตรงในช่วง 200

ขั้นแรก แล้วลดลงแบบโคไซน์จนเป็นศูนย์ [38] แต่ละขั้นใช้ภาพ 8 ภาพ (ครึ่งละ 2 ภาพ และสะสมเกรเดียนต์ 4 ครั้ง) และจำกัดขนาดของเกรเดียนต์ไม่เกิน 1 การฝึกใช้ 6000 ขั้นสำหรับ FT-Faro-10 และ FT-LiDAR-10 และ 12 000 ขั้นสำหรับ FT-LiDAR-24 ทุก 500 ขั้น โมเดลจะถูกวัด AbsRel เทียบความลึกจาก Faro บนทุกเฟรมที่ห้าของห้องเลือก checkpoint ทั้งสามห้อง แล้วเก็บ checkpoint ที่มี AbsRel ต่ำที่สุด ดังนั้นค่าน้ำหนักของโมเดลที่เรียนจาก LiDAR ได้มาจาก LiDAR เท่านั้น แต่การเลือก checkpoint ใช้ความลึกจาก Faro ของสามห้องนี้ การฝึก 6000 ขั้นใช้เวลาประมาณหนึ่งชั่วโมงบน GPU รุ่น NVIDIA RTX 3070 ขณะทดสอบ โมเดลที่ปรับจูนแล้วถูกใช้เหมือนโมเดลเดิมทุกประการ คือรับภาพสี่และให้ความลึกเป็นเมตร ไม่ปรับสเกล และเตรียมภาพนำเข้าแบบเดียวกัน

F. ตัวชี้วัดและสถิติ

แบบสามมิติ สุ่มจุด 200 000 จุดอย่างสม่ำเสมอแบบจำลองแต่ละอัน ความแม่นยำ (accuracy) คือระยะเฉลี่ยจากจุดบนแบบจำลองที่สร้างได้ถึงจุดที่ใกล้ที่สุดบนแบบจำลองอ้างอิง ความครบถ้วน (completeness) คือระยะเฉลี่ยในทิศทางกลับกัน และ Chamfer distance [6] คือค่าเฉลี่ยของทั้งสอง precision, recall และ F-score [18] (บทที่ II) คำนวณที่ระยะเกณฑ์ 2, 5 และ 10 ซม. โดยใช้ F@5 cm เป็นตัวเลखหลัก สำหรับวัตถุประสงค์ข้อ (3) ถือว่ารองรับงานได้เมื่อ recall ที่ระยะเกณฑ์ของงานนั้นอย่างน้อย 0.9 รองรับได้บางส่วนเมื่ออยู่ระหว่าง 0.75 ถึง 0.9 และรองรับไม่ได้เมื่อต่ำกว่า 0.75 **แบบรายเฟรม** แผนที่ความลึกแต่ละภาพถูกเทียบกับความลึกจาก Faro บนตาราง 256×192 เฉพาะพิกเซลที่ความลึกจาก Faro อยู่ระหว่าง 0.1 ถึง 5 ม. และแหล่งความลึกให้ค่าออกมา ค่าที่ทำนายนอกช่วงนี้จะถูกตัดให้อยู่ในช่วงแทนที่จะถูกทิ้ง โมเดลที่วางแผนไว้ไกลเกินไปจึงยังถูกวัดผลที่ผ่นนั้น งานนี้รายงาน AbsRel, within-1.25 $\times$ และรากที่สองของค่าเฉลี่ยกำลังสองของความคลาดเคลื่อน (RMSE) ของความลึก [7] โดยเฉลี่ยในแต่ละห้องก่อน แล้วจึงเฉลี่ยข้ามห้อง **สถิติ** ตารางแสดงค่าเฉลี่ย $\pm$ ส่วนเบี่ยงเบนมาตรฐานข้ามห้อง เนื่องจากหน่วยที่เป็นอิสระต่อกันคือห้อง ไม่ใช่เฟรม การเปรียบเทียบสองโมเดลจึงใช้ค่ารายห้องกับการทดสอบ Wilcoxon signed-rank แบบ exact สองทาง [17] การทดสอบนี้เรียงลำดับผลต่างรายห้องตามขนาด แล้วตรวจว่าลำดับของผลต่างที่เป็นบวกและลบสมดุลกันหรือไม่ คำว่า exact หมายถึงคำนวณค่า p จากทุกรูปแบบที่เป็นไปได้ของเครื่องหมาย ไม่ได้ใช้ค่าประมาณ ซึ่งสำคัญเมื่อมีห้องน้อย เมื่อมีหกห้อง ค่า p ที่เล็กที่สุดที่เป็นไปได้คือ $2/64 \approx 0.031$ ความต่างจึงมีนัยสำคัญที่ระดับ 5% ได้ก็ต่อเมื่อโมเดลหนึ่งชนะครบทั้งหกห้อง

G. การทดลอง

ตารางที่ III แสดงการทดลองและวัตถุประสงค์ที่แต่ละการทดลองตอบ การทดลองที่ 6 และ 7 ตอบคำถามหลัก (วัตถุประสงค์ข้อ 1 และ 2) การทดลองที่ 1 ระบุตำแหน่งของโมเดลเทียบกับแหล่งความลึกที่ใช้ได้ขณะใช้งาน (วัตถุประสงค์ข้อ 3) และการทดลองที่ 2–5 ทดสอบว่ากระบวนการวัดค่าตั้งค่าของตัวเองเพียงใด เวลาในการทดลองที่ 4 วัดด้วย PyTorch ที่ไม่ได้ปรับแต่งบนแพลตฟอร์ม Apple Silicon และใช้เปรียบเทียบเป็นอัตราส่วนเท่านั้น

H. การวิเคราะห์สเกลรายเฟรม

วัตถุประสงค์ข้อ (4) ถามว่าความคลาดเคลื่อนที่การปรับจูนแก้ไขได้คืออะไร และมาจากเวลาหรือจากมุมมอง บนทุกเฟรมที่ห้าของห้องทดสอบทั้งหก (471 เฟรม) เราคำนวณสำหรับโมเดลแบบเมตริกเดิมและ FT-LiDAR-24 อัตราส่วนของความลึกจาก Faro ต่อความลึกที่ทำนาย โดยใช้ค่ามัธยฐานบนพิกเซลของเฟรมนั้น ค่ามัธยฐาน

ตารางที่ III
การทดลอง ในแต่ละการทดลองเปลี่ยนเฉพาะตัวแปรที่ระบุ ส่วนอื่นคงที่ทั้งหมด

การทดลอง	ข้อ	ตัวแปร ห้อง และการประเมิน
6	1, 2	โมเดลเดิมเทียบกับ FT-LiDAR-24; FT-Faro-10, FT-LiDAR-10 และ Depth Pro; ห้องทดสอบ 6 ห้อง สามมิติและรายเฟรม
7	1	โมเดลเดิมเทียบกับ FT-LiDAR-24 โดยมี LiDAR ของ iPad เป็นแกวอ้างอิง; อีก 20 ห้อง รายเฟรม
1	3	แหล่งความลึกและวิธีปรับสเกล: Faro, LiDAR, DA-v2 Large กับการปรับแต่ละแบบ, DA-v2 Metric แบบเดิม; ห้องทดสอบ 6 ห้อง สามมิติและรายเฟรม
–	4	การวิเคราะห์สเกลรายเฟรม (หัวข้อ III-H); ห้องทดสอบ 6 ห้อง ทุกเฟรมที่หา
2–5	–	ขนาด voxel; ระยะห่างของเฟรม; ขนาดโมเดล; ความเชื่อมั่นของ LiDAR; ห้องทดสอบ 6 ห้อง สามมิติ

ของอัตราส่วนนั้นบนเฟรมทั้งหมดของห้องบอกว่าสเกลของโมเดลคลาดไปเท่าใด และอัตราส่วนระหว่างเปอร์เซ็นต์โวลุ่มที่ 95 กับที่ 5 ของอัตราส่วนนั้นบนเฟรมเหล่านั้น บอกว่าสเกลที่ต้องการแกวภายในห้องเดียวมากเพียงใด จากนั้นคำนวณ AbsRel เมื่อให้ความช่วยเหลือด้านสเกลเพิ่มขึ้นทีละระดับ ได้แก่ ไม่ช่วยเลย สเกลและค่าเลื่อนหนึ่งชุดต่อห้องที่ห่างจาก 10 เฟรมตามตารางที่ II สเกลที่ถูกต้องของทุกเฟรม (คำมัยฐานของอัตราส่วนของเฟรมนั้น ไม่มีค่าเลื่อน) และสเกลกับค่าเลื่อนแบบ oracle รายเฟรม สำหรับโมเดลความลึกสัมพัทธ์ DA-v2 Large เราหาสเกลแบบ oracle รายเฟรมบนเฟรมชุดเดียวกันแล้วคำนวณสัมประสิทธิ์สหสัมพันธ์ของ Pearson [39] ซึ่งวัดความสัมพันธ์เชิงเส้นในช่วง -1 ถึง $+1$ ระหว่างสเกลนี้กับเวลาของเฟรมในการสแกน และกับคำมัยฐานของความลึกจาก Faro ในเฟรมนั้น หากเป็นการสะสมความคลาดเคลื่อน (drift) ตามเวลา สหสัมพันธ์กับเวลาจะมีเครื่องหมายเดียวกันในทุกห้อง หากขึ้นกับมุมมอง สหสัมพันธ์กับความลึกของฉากตรงหน้ากล้องจะมีทิศทางเดียวกันอย่างสม่ำเสมอ

เอกสารอ้างอิง

- [1] L. Yang, B. Kang, Z. Huang, Z. Zhao, X. Xu, J. Feng, and H. Zhao, "Depth anything V2," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 37, 2024.
- [2] FARO Technologies, "FARO Focus laser scanners," <https://www.faro.com/en/Products/Hardware/Focus-Laser-Scanners>, accessed 2026-09-29.
- [3] G. Baruch, Z. Chen, A. Dehghan, T. Dimry, Y. Feigin, P. Fu, T. Gebauer, B. Joffe, D. Kurz, A. Schwartz, and E. Shulman, "ARKitScenes: A diverse real-world dataset for 3D indoor scene understanding using mobile RGB-D data," in *Proc. Neural Information Processing Systems Track on Datasets and Benchmarks*, 2021.
- [4] R. Ranftl, A. Bochkovskii, and V. Koltun, "Vision transformers for dense prediction," in *Proc. IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021, pp. 12 179–12 188.
- [5] B. Curless and M. Levoy, "A volumetric method for building complex models from range images," in *Proc. SIGGRAPH*, 1996, pp. 303–312.
- [6] H. Fan, H. Su, and L. J. Guibas, "A point set generation network for 3D object reconstruction from a single image," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 605–613.
- [7] D. Eigen, C. Puhrsch, and R. Fergus, "Depth map prediction from a single image using a multi-scale deep network," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 27, 2014, pp. 2366–2374.
- [8] Apple Inc., "RoomPlan – apple developer documentation," <https://developer.apple.com/documentation/roomplan>, 2022, accessed 2026-09-17.

- [9] R. Ranftl, K. Lasinger, D. Hafner, K. Schindler, and V. Koltun, "Towards robust monocular depth estimation: Mixing datasets for zero-shot cross-dataset transfer," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 44, no. 3, pp. 1623–1637, 2022.
- [10] L. Yang, B. Kang, Z. Huang, X. Xu, J. Feng, and H. Zhao, "Depth anything: Unleashing the power of large-scale unlabeled data," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024, pp. 10 371–10 381.
- [11] Z. Murez, T. van As, J. Bartolozzi, A. Sinha, V. Badrinarayanan, and A. Rabinovich, "Atlas: End-to-end 3D scene reconstruction from posed images," in *Proc. European Conference on Computer Vision (ECCV)*, 2020, pp. 414–431.
- [12] J. Sun, Y. Xie, L. Chen, X. Zhou, and H. Bao, "NeuralRecon: Real-time coherent 3D reconstruction from monocular video," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021, pp. 15 598–15 607.
- [13] M. Sayed, J. Gibson, J. Watson, V. Prisacariu, M. Firman, and C. Godard, "SimpleRecon: 3D reconstruction without 3D convolutions," in *Proc. European Conference on Computer Vision (ECCV)*, 2022, pp. 1–19.
- [14] S. F. Bhat, R. Birkel, D. Wofk, P. Wonka, and M. Müller, "ZoeDepth: Zero-shot transfer by combining relative and metric depth," *arXiv preprint arXiv:2302.12288*, 2023.
- [15] A. Bochkovskii, A. Delaunoy, H. Germain, M. Santos, Y. Zhou, S. R. Richter, and V. Koltun, "Depth pro: Sharp monocular metric depth in less than a second," in *ICLR*, 2025.
- [16] M. Roberts, J. Ramapuram, A. Ranjan, A. Kumar, M. A. Bautista, N. Paczan, R. Webb, and J. M. Susskind, "Hypersim: A photorealistic synthetic dataset for holistic indoor scene understanding," in *Proc. IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021, pp. 10 892–10 902.
- [17] F. Wilcoxon, "Individual comparisons by ranking methods," *Biometrics Bulletin*, vol. 1, no. 6, pp. 80–83, 1945.
- [18] A. Knapitsch, J. Park, Q.-Y. Zhou, and V. Koltun, "Tanks and temples: Benchmarking large-scale scene reconstruction," *ACM Transactions on Graphics*, vol. 36, no. 4, pp. 78:1–78:13, 2017.
- [19] R. Hartley and A. Zisserman, *Multiple View Geometry in Computer Vision*, 2nd ed. Cambridge University Press, 2004.
- [20] N. Silberman, D. Hoiem, P. Kohli, and R. Fergus, "Indoor segmentation and support inference from RGBD images," in *Proc. European Conference on Computer Vision (ECCV)*, 2012, pp. 746–760.
- [21] A. Geiger, P. Lenz, and R. Urtasun, "Are we ready for autonomous driving? The KITTI vision benchmark suite," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2012, pp. 3354–3361.
- [22] W. Yin, C. Zhang, H. Wang, S. Niklaus, L. Mai, S. Chen, and C. Shen, "Metric3D: Towards zero-shot metric 3D prediction from a single image," in *Proc. IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023, pp. 9043–9053.
- [23] L. Piccinelli, Y.-H. Yang, C. Sakaridis, M. Segu, S. Li, L. Van Gool, and F. Yu, "UniDepth: Universal monocular metric depth estimation," in *CVPR*, 2024.
- [24] M. Oquab, T. Darcet, T. Moutakanni, H. Vo, M. Szafraniec, V. Khalidov, P. Fernandez, D. Haziza, F. Massa, A. El-Nouby et al., "DINOv2: Learning robust visual features without supervision," *Transactions on Machine Learning Research*, 2024.
- [25] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, "An image is worth 16x16 words: Transformers for image recognition at scale," in *Proc. International Conference on Learning Representations (ICLR)*, 2021.
- [26] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson, "How transferable are features in deep neural networks?" in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 27, 2014, pp. 3320–3328.
- [27] G. Luetzenburg, A. Kroon, and A. A. Bjørk, "Evaluation of the Apple iPhone 12 Pro LiDAR for an application in geosciences," *Scientific Reports*, vol. 11, p. 22221, 2021.
- [28] A. Spreafico, F. Chiabrando, L. Teppati Losè, and F. Giulio Tonolo, "The iPad Pro built-in LiDAR sensor: 3D rapid mapping tests and quality assessment," *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, vol. XLIII-B1-2021, pp. 63–69, 2021.

- [29] H. Lin, S. Peng, J. Chen, S. Peng, J. Sun, M. Liu, H. Bao, J. Feng, X. Zhou, and B. Kang, "Prompting depth anything for 4K resolution accurate metric depth estimation," in Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2025.
- [30] T. Qin, P. Li, and S. Shen, "VINS-Mono: A robust and versatile monocular visual-inertial state estimator," *IEEE Transactions on Robotics*, vol. 34, no. 4, pp. 1004–1020, 2018.
- [31] K. Tateno, F. Tombari, I. Laina, and N. Navab, "CNN-SLAM: Real-time dense monocular SLAM with learned depth prediction," in Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017, pp. 6243–6252.
- [32] Z. Yu, S. Peng, M. Niemeyer, T. Sattler, and A. Geiger, "MonoSDF: Exploring monocular geometric cues for neural implicit surface reconstruction," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 35, 2022.
- [33] W. E. Lorensen and H. E. Cline, "Marching cubes: A high resolution 3D surface construction algorithm," in Proc. SIGGRAPH, 1987, pp. 163–169.
- [34] R. A. Newcombe, S. Izadi, O. Hilliges, D. Molyneaux, D. Kim, A. J. Davison, P. Kohli, J. Shotton, S. Hodges, and A. Fitzgibbon, "KinectFusion: Real-time dense surface mapping and tracking," in Proc. IEEE International Symposium on Mixed and Augmented Reality (ISMAR), 2011, pp. 127–136.
- [35] Q.-Y. Zhou, J. Park, and V. Koltun, "Open3D: A modern library for 3D data processing," *arXiv preprint arXiv:1801.09847*, 2018.
- [36] A. Dai, A. X. Chang, M. Savva, M. Halber, T. Funkhouser, and M. Nießner, "ScanNet: Richly-annotated 3D reconstructions of indoor scenes," in Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017, pp. 2432–2443.
- [37] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in Proc. International Conference on Learning Representations (ICLR), 2019.
- [38] —, "SGDR: Stochastic gradient descent with warm restarts," in Proc. International Conference on Learning Representations (ICLR), 2017.
- [39] K. Pearson, "Note on regression and inheritance in the case of two parents," *Proceedings of the Royal Society of London*, vol. 58, pp. 240–242, 1895.