

สอนหน่วยเมตรให้โมเดลความลึกจากภาพเดี่ยวด้วย LiDAR ของโทรศัพท์เอง: เปรียบเทียบ Depth Anything V2 แบบ fine-tune กับ แบบ pretrained สำหรับการสร้างแบบจำลองห้อง โดยวัด เทียบกับ laser scanner

Author Name
Affiliation
email@example.com

บทคัดย่อ— โทรศัพท์ส่วนใหญ่ไม่มี LiDAR จึงต้องสแกนห้องด้วยการประมาณความลึกจากภาพเดี่ยว แต่โมเดลสำเร็จรูปที่ให้ผลเป็นเมตร เช่น Depth Anything V2 (DA-v2) Metric-Indoor [1] ซึ่งฝึกด้วยภาพสังเคราะห์ ทำให้ห้องที่สร้างได้คลาดเคลื่อน 54.3 ซม. งานวิจัยนี้ศึกษาว่าการปรับจูน (fine-tune) โมเดลดังกล่าวด้วยความลึกจาก LiDAR ของโทรศัพท์เอง โดยใช้เครื่องสแกนเลเซอร์ ทำให้แม่นยำกว่าโมเดลเดิมหรือไม่ เมื่อวัดเทียบกับเครื่องสแกนเลเซอร์ Faro Focus S70 [2] ซึ่งเป็นค่าอ้างอิงของชุดข้อมูล ARKitScenes [3] โดยปรับจูนเฉพาะส่วน DPT head [4] (ตัวถอดรหัสความลึก โดยตรงส่วนเข้ารหัสภาพไว้) ด้วยความลึกจาก LiDAR ของ iPad บน 24 ห้อง ได้โมเดล FT-LiDAR-24 แล้วเปรียบเทียบกับโมเดลเดิมในกระบวนการเดียวกัน คือรวมความลึกรายเฟรมเป็นปริมาตร TSDF (truncated signed distance function) [5] แล้วสร้างเป็นพื้นผิวสามมิติ โดยให้แหล่งความลึกเป็นตัวแปรเดียว บนห้องที่ไม่เคยใช้ฝึก ได้แก่ 6 ห้องที่มีแบบจำลองอ้างอิงจากเครื่องสแกนเลเซอร์ และอีก 20 ห้องที่ประเมินรายเฟรม ผลคือ FT-LiDAR-24 ลดค่า Chamfer distance [6] (ระยะเฉลี่ยถึงจุดที่ใกล้ที่สุดระหว่างพื้นผิวที่สร้างได้กับพื้นผิวอ้างอิง วัดทั้งสองทิศ) จาก 54.3 ซม. เหลือ 15.7 ซม. (ดีขึ้น 3.5 เท่า และดีขึ้นทุกห้อง) และลดค่า AbsRel [7] (ความคลาดเคลื่อนสัมพัทธ์เฉลี่ยของความลึก) จาก 0.410 เหลือ 0.130 (ดีขึ้น 19 จาก 20 ห้อง) โดยไม่ต้องปรับเทียบหรือใช้เซนเซอร์ขณะใช้งาน และการใช้เครื่องสแกนเลเซอร์เป็นครูไม่ได้ดีกว่าอย่างวัดได้ ความคลาดเคลื่อนที่เลือกมาจากสเกลที่กว้างตามมุมมองของแต่ละเฟรม ซึ่งการปรับจูนขัดไม่ได้ จึงยังดีกว่า LiDAR ของ iPad (3.0 ซม.) และยังไปถึงระดับความแม่นยำสำหรับดูภาพรวม (พื้นผิวของห้องอย่างน้อย 90% อยู่ภายใน 10 ซม.)

คำสำคัญ—การประมาณความลึกจากภาพเดี่ยว (monocular depth estimation), การเรียนรู้แบบถ่ายโอน (transfer learning), ความลึกแบบเมตริก (metric depth), การใช้ LiDAR เป็นข้อมูลสอน (LiDAR supervision), การรวมความลึกแบบ TSDF (TSDF fusion), การสร้างแบบจำลองสามมิติของห้อง (3D room reconstruction), ARKitScenes

I. บทนำ

การสแกนห้องเป็นแบบจำลองสามมิติเป็นความสามารถที่มีอยู่แล้วใน iPhone Pro และ iPad Pro (เช่น Apple RoomPlan [8]) โดยอาศัยเซนเซอร์ LiDAR วัดความลึกเป็นหน่วยเมตร แต่อุปกรณ์ที่มี LiDAR เป็นส่วนน้อย iPhone รุ่นที่ไม่ใช่ Pro และโทรศัพท์ Android แทบทุกรุ่นไม่มีเซนเซอร์นี้ ทางเลือกของอุปกรณ์เหล่านี้คือการประมาณความลึกจากภาพเดี่ยว (monocular depth estimation) คือการทำนายความลึกจากภาพสีเพียงภาพเดี่ยว ซึ่งพัฒนาอย่างรวดเร็วตั้งแต่ MiDaS [9] จนถึง Depth Anything [1], [10] ทีมพัฒนาผลิตภัณฑ์จึงต้องรู้ว่า **หากใช้โมเดลจากภาพเดี่ยวแทน LiDAR ห้องที่ได้จะคลาดเคลื่อนกี่เซนติเมตร และยังใช้งานแบบใดบ้าง** เกณฑ์วัดมาตรฐานแบบรายภาพ [7] ซึ่งเฉลี่ย

ความคลาดเคลื่อนของความลึกบนพิกเซลของภาพแต่ละภาพ ตอบคำถามนี้ไม่ได้ และระบบสร้างแบบจำลองแบบครบวงจร (end-to-end) [11]–[13] ก็ตอบไม่ได้ เพราะออกแบบกระบวนการทั้งหมดรอบโมเดลของตนเอง

โมเดลรุ่น ใหม่ บาง ตัว ให้ ความ ลึก เป็น เมตร ได้ โดยตรง [1], [14], [15] แต่ฝึกด้วยภาพที่ไม่ได้มาจากกล้องโทรศัพท์ เช่น DA-v2 Metric-Indoor ฝึกด้วยภาพห้องสังเคราะห์จากชุดข้อมูล Hypersim [16] และในการทดลองของเรา ห้องที่สร้างด้วย DA-v2 Metric-Indoor คลาดเคลื่อนเฉลี่ย 54.3 ซม. วิธีแก้โดยตรงคือการปรับจูน (fine-tune) โมเดลด้วยความลึกจากอุปกรณ์เป้าหมาย คำถามคือข้อมูลสอน (label) นี้จะมาจากไหน ระหว่างเครื่องสแกนเลเซอร์ระดับงานสำรวจ [2] ซึ่งผู้พัฒนาแอปเพียงไม่กี่รายมีใช้ กับ LiDAR ที่มีอยู่แล้วในอุปกรณ์รุ่น Pro ซึ่งแอปเก็บความลึกได้ระหว่างการใช้งานปกติ หากวิธีหลังได้ผล อุปกรณ์ที่มี LiDAR ก็จะเป็นครูสอนอุปกรณ์ที่ไม่มี LiDAR ได้

งานวิจัยนี้จึงตั้งคำถามว่า DA-v2 Metric-Indoor ที่ปรับจูนด้วยความลึกจาก LiDAR ของ iPad โดยใช้เครื่องสแกนเลเซอร์ในการฝึก แม่นยำกว่าโมเดลเดิมที่ไม่ได้ปรับจูนหรือไม่ เมื่อวัดเทียบกับเครื่องสแกนเลเซอร์ Faro ซึ่งเป็นค่าอ้างอิงของชุดข้อมูล ARKitScenes [3] บนห้องที่ไม่เคยใช้ฝึก โดยมีวัตถุประสงค์ 4 ข้อ ได้แก่ (1) ปรับจูนโมเดลด้วยความลึกจาก LiDAR ของ iPad จำนวน 24 ห้อง ได้โมเดล FT-LiDAR-24 แล้วเปรียบเทียบกับโมเดลเดิมบนห้องที่ไม่เคยใช้ฝึก โดยถือว่าดีกว่าเมื่อค่าเฉลี่ยความคลาดเคลื่อนต่ำกว่า และผลต่างรายห้องมีนัยสำคัญทางสถิติที่ระดับ 5% ตามการทดสอบ Wilcoxon signed-rank แบบ exact [17] (2) วัดว่าแหล่งของข้อมูลสอนมีผลหรือไม่ โดยเปรียบเทียบข้อมูลสอนจาก Faro กับจาก LiDAR บน 10 ห้องเดียวกัน (FT-Faro-10 กับ FT-LiDAR-10) เปรียบเทียบข้อมูลสอนจาก LiDAR 10 ห้องกับ 24 ห้อง และเปรียบเทียบกับโมเดลที่ใช้ความยาวโฟกัสของกล้องแทนข้อมูลสอนจากโดเมนเป้าหมาย (Depth Pro [15]) (3) ระบุตำแหน่งของ FT-LiDAR-24 เทียบกับแหล่งความลึกที่ใช้ได้ขณะใช้งาน ได้แก่ LiDAR ของ iPad และโมเดลความลึกสัมพัทธ์ที่ปรับสเกลรายเฟรมด้วยจุดเบาบาง (sparse points) หรือปรับสเกลครั้งเดียวต่อห้อง และ (4) หาที่มาของความคลาดเคลื่อนที่การปรับจูนแก้ไม่ได้ โดยหาสเกลความลึกที่เหมาะสมกับแต่ละเฟรม แล้วทดสอบว่าสเกลนั้นเปลี่ยนตามเวลา ซึ่งบ่งชี้การสะสมความคลาดเคลื่อน (drift) หรือเปลี่ยนตามสิ่งที่อยู่ในภาพ

ทุกการเปรียบเทียบวัดสองแบบ แบบแรกวัดเป็นแบบจำลองห้อง

(mesh) ด้วย Chamfer distance [6] คือระยะเฉลี่ยจากแต่ละพื้นผิวถึงจุดที่ใกล้ที่สุดของอีกพื้นผิว และด้วย F-score ที่ 5 ซม. (F@5 cm) [18] ซึ่งรวมสัดส่วนของพื้นผิวที่สร้างได้ที่อยู่ภายใน 5 ซม. จากพื้นผิวอ้างอิง กับสัดส่วนของพื้นผิวอ้างอิงที่ถูกสร้างขึ้นภายใน 5 ซม. แบบที่สองวัดรายเฟรมด้วย AbsRel [7] คือความคลาดเคลื่อนสัมพัทธ์เฉลี่ยของความลึก และด้วยสัดส่วนของพิกเซลที่ความลึกที่ทำนายต่างจากค่าจริงไม่เกิน 1.25 เท่า (ไม่ว่าจะมากหรือน้อยกว่าค่าจริง) ซึ่งเรียกว่า within-1.25× [7] สำหรับวัตถุประสงค์ข้อ (3) สัดส่วนของพื้นผิวอ้างอิงที่ถูกสร้างขึ้นภายใน 2, 5 และ 10 ซม. ใช้แทนความแม่นยำที่งานวัดเพื่อปรับปรุงห้อง งานวางเฟอร์นิเจอร์ และงานดูภาพรวมของห้องต้องการ ตามลำดับ และถือว่ารองรับงานนั้นได้เมื่อสัดส่วนนี้ถึง 90 %

ขอบเขตของงานวิจัยมีดังนี้ ข้อมูลเป็นห้องในบ้านจากชุดข้อมูล ARKitScenes ที่ถ่ายด้วย iPad Pro รุ่นเดียว (ภาพสีขนาด 640×480 พิกเซล และความลึกจาก LiDAR ขนาด 256×192 พิกเซล) ค่าอ้างอิงคือความลึกจาก Faro ที่มากับชุดข้อมูล และไม่ใช่ LiDAR ของ iPad เป็นค่าอ้างอิง การปรับปรุงทำเฉพาะส่วน DPT head [4] ซึ่งเป็นตัวถอดรหัสความลึกของ DA-v2 Metric-Indoor ขนาด Large ด้วยสูตรการฝึกเดียว โดยตรงส่วนเข้ารหัสภาพไว้ ประเมินผลบนห้องทดสอบ 6 ห้องทั้งแบบแบบจำลองห้องและแบบรายเฟรม และอีก 20 ห้องแบบรายเฟรมเท่านั้น ทุกห้องไม่ซ้ำกับห้องที่ใช้ฝึกหรือใช้เลือก checkpoint ทุกแหล่งความลึกผ่านกระบวนการแบบออฟไลน์เดียวกัน คือความลึกรายเฟรม การปรับสเกล การรวมเป็นปริมาตร TSDF (truncated signed distance function) [5] และการสร้างพื้นผิว แหล่งความลึกจึงเป็นตัวแปรเดียว นอกจากนี้ ทุกแหล่งและค่าอ้างอิงใช้ตำแหน่งกล้องชุดเดียวกัน ซึ่งบันทึกโดย ARKit ความคลาดเคลื่อนของตำแหน่งกล้องจึงไม่อยู่ในผลการวัด สิ่งที่อยู่นอกขอบเขต ได้แก่ ระบบสร้างแบบจำลองที่เรียนรู้ทั้งกระบวนการ [11]–[13] กล้องโทรศัพท์รุ่นอื่นรวมถึง Android การประมวลผลแบบเรียลไทม์บนอุปกรณ์ และการประมาณตำแหน่งกล้อง

ประโยชน์ที่คาดว่าจะได้รับสอดคล้องกับวัตถุประสงค์ที่ละข้อ ข้อแรก ผู้พัฒนาแอปจะรู้ว่าข้อมูลที่เก็บได้โดยผู้ใช้งานจากผู้ใช้อุปกรณ์รุ่น Pro ช่วยให้การสแกนห้องบนอุปกรณ์ที่ไม่มี LiDAR ดีขึ้นหรือไม่ โดยไม่ต้องเปรียบเทียบหรือใช้เซนเซอร์เพิ่มเติมขณะใช้งาน ข้อสอง จะรู้ว่าการสร้างข้อมูลสอนจำเป็นต้องใช้เครื่องสแกนเลเซอร์หรือไม่ ข้อสาม จะรู้ว่าอุปกรณ์ที่ไม่มี LiDAR รองรับงานแบบใดบ้าง พร้อมได้กระบวนการที่ประเมินแหล่งความลึกใหม่ได้ด้วยการแก้ค่าตั้งค่าเพียงรายการเดียว และข้อสี่ จะรู้ว่าควรลงทุนพัฒนาส่วนใดต่อ ระหว่างสเกลรายเฟรม ข้อมูลฝึก หรือขนาดโมเดล

II. ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

บทนี้อธิบายทฤษฎีที่งานวิจัยนี้อาศัย ได้แก่ เหตุใดภาพเดียวจึงบอกความลึกเป็นเมตรไม่ได้ โมเดลที่เรานำมาปรับปรุงมีโครงสร้างและฝึกมาอย่างไร และความลึกภาพถ่ายกลายเป็นแบบจำลองห้องได้อย่างไร พร้อมทั้งวางตำแหน่งของงานนี้เทียบกับงานก่อนหน้านี้ในแต่ละประเด็น

A. การประมาณความลึกจากภาพเดียว

ตามแบบจำลองกล้องรูเข็ม (pinhole camera) [19] ขนาดของวัตถุในภาพแปรผันตามขนาดจริงของวัตถุ หากรู้ระยะห่าง แล้วคูณด้วยความยาวโฟกัสของเลนส์ ห้องที่ใหญ่เป็นสองเท่าเมื่อมองจากระยะไกลเป็นสองเท่า จึงให้ภาพเหมือนกันทุกประการ เราคาดเดาเพียงอย่างเดียวจึงหาความลึกเป็นเมตรจากภาพเดียวไม่ได้ โครงข่ายประสาทเทียมทำได้เพียงอนุมานจากสิ่งที่เรียนรู้มา เช่น ความสูงปกติของประตูหรือโต๊ะ และแม้แต่ข้อมูลเหล่านี้ก็ขึ้นกับความยาวโฟกัส เพราะวัตถุเดียวกันที่ระยะเดียวกันจะดูใหญ่ขึ้นเมื่อใช้เลนส์ที่ยาวขึ้น Eigen และคณะ [7] เป็นงานแรก ๆ ที่ใช้โครงข่ายเชิงลึกกับปัญหานี้ และเพราะ

ความกำกวมดังกล่าว จึงวัดความคลาดเคลื่อนบนลอการิทึมของความลึก ในรูปแบบที่แยกความคลาดเคลื่อนของสเกลโดยรวมของฉากออกจากความคลาดเคลื่อนของรูปทรง ฟังก์ชันสูญเสีย (loss) แบบไม่ขึ้นกับสเกลบนลอการิทึมนี้ในรูปแบบถ่วงน้ำหนัก เรียกว่า SiLog ใช้ฝึกทั้ง ZoeDepth [14] และโมเดลที่ปรับปรุงในงานนี้

โมเดลแบ่งได้เป็นสองกลุ่มตามวิธีจัดการกับสเกลที่หายไป กลุ่มแรกคือโมเดลความลึกสัมพัทธ์ (relative) ซึ่งไม่พยายามหาสเกล MiDaS [9] ฝึกโครงข่ายเดียวด้วยชุดข้อมูลหลายชุดที่วัดความลึกด้วยเซนเซอร์และหน่วยต่างกัน ซึ่งทำได้ก็ต่อเมื่อฟังก์ชันสูญเสียไม่สนใจสเกลและค่าเลื่อน (offset) ของแต่ละภาพ ผลลัพธ์จึงเป็นส่วนกลับของความลึก (disparity) ที่ถูกต้องเฉพาะเมื่อรู้สเกลและค่าเลื่อนของภาพนั้น ต้องหาตัวเลขสองตัวนี้จากข้อมูลอื่นก่อนจึงจะได้ความลึกเป็นเมตร Depth Anything [10] และ Depth Anything V2 [1] (DA-v2) ให้ผลลัพธ์แบบเดียวกัน แต่ฝึกด้วยภาพจำนวนมากมาก กลุ่มที่สองคือโมเดลความลึกแบบเมตริก (metric) ซึ่งให้ความลึกเป็นเมตรโดยตรง โดยเรียนรู้สเกลจากข้อมูลที่มีค่าความลึกกำกับ ZoeDepth [14] ต่อส่วนทำนายแบบเมตริกที่ปรับปรุงด้วย NYU Depth v2 [20] และ KITTI [21] เข้ากับโมเดลความลึกสัมพัทธ์ ส่วน DA-v2 มีรุ่นเมตริกที่ปรับปรุงจากรุ่นสัมพัทธ์ของตนเอง โดยรุ่นในอาคาร (DA-v2 Metric-Indoor) ปรับปรุงด้วยภาพห้องที่เรนเดอร์จากชุดข้อมูล Hypersim [16] อีกแนวทางหนึ่งจัดการกับความยาวโฟกัสโดยตรง Metric3D [22] แปลงทุกภาพให้เป็นภาพจากกล้องมาตรฐานที่มีความยาวโฟกัสคงที่ UniDepth [23] ทำนายพารามิเตอร์ของกล้องไปพร้อมกับความลึก และ Depth Pro [15] ประมาณความยาวโฟกัสเองเมื่อไม่ได้รับค่านีมา งานเหล่านี้รายงานผลเป็นตัวชี้วัดรายภาพบนชุดทดสอบมาตรฐาน เช่น NYU Depth v2 และ KITTI ตัวชี้วัดดังกล่าวเฉลี่ยจากภาพที่เป็นอิสระต่อกัน จึงไม่บอกว่าคุณค่าของโมเดลคงที่หรือไม่ ตลอดเฟรมของการสแกนครั้งเดียว ซึ่งเป็นสิ่งสำคัญเมื่อนำเฟรมทั้งหมดมารวมเป็นห้องเดียว

B. โครงสร้างและการฝึกของ Depth Anything V2

DA-v2 ประกอบด้วยส่วนเข้ารหัสภาพ (encoder) และส่วนถอดรหัสความลึก (decoder) ส่วนเข้ารหัสคือ DINOv2 [24] ซึ่งเป็น vision transformer (ViT) [25] โดยแบ่งภาพเป็นชิ้นสี่เหลี่ยมเล็ก ๆ (patch) แล้วให้แต่ละชิ้นดึงข้อมูลจากชิ้นอื่นทุกชิ้นผ่านกลไกที่เรียกว่า self-attention DINOv2 ผ่านการฝึกล่วงหน้าโดยไม่ใช้ข้อมูลกำกับ บนชุดภาพขนาดใหญ่ที่คัดสรรแล้ว เพื่อให้คุณลักษณะ (feature) ที่ได้ใช้กับงานได้หลากหลาย ส่วนถอดรหัสคือ Dense Prediction Transformer (DPT) [4] ซึ่งนำคุณลักษณะจากหลายชั้นของส่วนเข้ารหัสมาประกอบกลับเป็นแผนที่คล้ายภาพที่หลายความละเอียด แล้วรวมเป็นแผนที่ความลึกแบบหนาแน่นเพียงแผนที่เดียว โค้ดของโมเดลแบ่งส่วนถอดรหัสเป็น neck ซึ่งทำหน้าที่ประกอบและรวมคุณลักษณะ กับ head ซึ่งให้ค่าความลึกออกมา ในรายงานนี้คำว่า DPT head หมายถึงทั้งสองส่วน เช่นเดียวกับในบทนำ

DA-v2 เองก็ฝึกด้วยครู (teacher) กล่าวคือ ฝึกโมเดลขนาดใหญ่ด้วยภาพสังเคราะห์ซึ่งมีความลึกที่แม่นยำก่อน จากนั้นให้โมเดลนี้กำกับความลึกให้ภาพจริงที่ไม่มีมีความลึกราว 62 ล้านภาพ แล้วจึงให้โมเดลที่เผยแพร่เรียนรู้จากค่ากำกับที่โมเดลสร้างขึ้นนี้ ซึ่งเรียกว่า pseudo-label [1] ผู้พัฒนา DINOv2 รายงานว่าทำนายความลึกได้ดีแม้ตรงส่วนเข้ารหัสไว้ และฝึกเฉพาะส่วนถอดรหัส DPT ที่ต่อด้านบน [24] การนำโมเดลที่ฝึกกับงานหรือโดเมนหนึ่งมาปรับใช้กับอีกงานหรือโดเมนหนึ่ง เช่นนี้เรียกว่าการเรียนรู้แบบถ่ายโอน (transfer learning) [26] การฝึกเฉพาะส่วนถอดรหัสแบบที่งานนี้ทำใช้หน่วยความจำน้อยกว่ามาก และยังคงคุณลักษณะทั่วไปที่ส่วนเข้ารหัสเรียนรู้มาจากภาพหลายล้านภาพไว้

C. การฝึกด้วยความลึกจากเซนเซอร์

โมเดลความลึกแบบมีผู้สอน (supervised) ใช้ความลึกที่วัดจากเซนเซอร์เป็นข้อมูลสอนมานานแล้ว โดยไม่ต้องให้คนกำกับ ตัวอย่างเช่น NYU Depth v2 ให้ความลึกในอาคารจากกล้อง Microsoft Kinect [20] KITTI ให้ความลึกบนถนนจากเครื่องสแกนเลเซอร์ที่ติดบนรถยนต์ [21] และ Eigen และคณะ [7] ฝึกด้วยทั้งสองชุด สิ่งที่แตกต่างกันระหว่างงานเหล่านี้คือคุณภาพของเซนเซอร์ บน iPhone Pro และ iPad Pro นั้น ARKit รวมค่าที่วัดได้จาก LiDAR กับภาพสีเป็นแผนที่ความลึกขนาด 256×192 พิกเซล พร้อมค่าความเชื่อมั่นของทุกพิกเซล [3] งานที่ทดสอบ LiDAR นี้เทียบกับวิธีสำรวจที่เป็นที่ยอมรับพบว่า แม่นยำราว 1 ซม. กับวัตถุที่ใหญ่กว่า 10 ซม. [27] และเพียงพอสำหรับการทำแผนที่สถาปัตยกรรมอย่างรวดเร็วที่มาตรฐาน 1:200 [28] จึงมีเหตุผลที่จะใช้เป็นครู ARKitScenes [3] ให้ความลึกนี้คู่กับความลึกจากเครื่องสแกนเลเซอร์ระดับงานสำรวจ Faro [2] ของห้องเดียวกัน โดยจัดให้ตรงกับเฟรมกล้องเดียวกัน และใช้ความลึกจาก Faro เป็นค่าอ้างอิง ในโจทย์ที่เพิ่มความละเอียดของความลึกจาก LiDAR โดยอาศัยภาพสี Prompt Depth Anything [29] ซึ่งเป็นงานที่ใช้ข้อมูลใกล้เคียงกับงานนี้ที่สุด ก็ป้อนความลึกจาก LiDAR ของ iPhone เข้าโมเดล Depth Anything เป็นข้อมูลนำเข้าเพิ่มเติมเช่นกัน ในทั้งสองงาน LiDAR ต้องมีอยู่ทุกครั้งที่ไม่เดลทำงาน ส่วนงานนี้ใช้ LiDAR เฉพาะตอนฝึก โมเดลที่นำไปใช้จึงต้องการเพียงภาพสี คำถามว่าครูที่มีสัญญาณรบกวนมากกว่านี้ ช่วยโมเดลขนาดใหญ่ที่ผ่านการฝึกล่วงหน้าได้เท่ากับเครื่องสแกนเลเซอร์หรือไม่ เมื่อตัดสินใจด้วยค่าอ้างอิงจากเลเซอร์ที่เป็นอิสระ คือเรื่องของวัตถุประสงค์ข้อ (1) และ (2)

D. จากแผนที่ความลึกสู่แบบจำลองห้อง

การรวมเฟรมต้องรู้ท่าทางกล้อง (camera pose) ของแต่ละเฟรม คือตำแหน่งและทิศทางของกล้อง ARKit ติดตามท่าทางกล้องด้วย visual-inertial odometry (VIO) ซึ่งติดตามจุดเด่นในภาพจากเฟรมหนึ่งไปอีกเฟรมหนึ่ง แล้วรวมกับเซนเซอร์วัดการเคลื่อนที่ของอุปกรณ์ [30] เนื่องจากเซนเซอร์วัดการเคลื่อนที่วัดความเร่งเป็นหน่วยเมตริก จุดที่ติดตามได้จึงมีตำแหน่งเป็นเมตร จุดเบาบาง (sparse points) เหล่านี้จึงให้สเกลและค่าเลื่อนที่โมเดลความลึกสัมผัสขาดไปได้ทีละเฟรม แนวคิดการใช้ความลึกจากโครงข่ายร่วมกับเรขาคณิตแบบเบาบางของระบบติดตามมีมาตั้งแต่ CNN-SLAM [31] และ MonoSDF [32] ก็หาสเกลและค่าเลื่อนของทุกภาพก่อนนำความลึกจากภาพเดียวไปช่วยสร้างพื้นผิว การปรับสเกลด้วยจุดเบาบางของงานนี้ ซึ่งอธิบายไว้ในบทการออกแบบระบบ ก็อยู่ในแนวทางนี้

ขั้นตอนคือการสร้างห้อง ซึ่งทำโดยรวมความลึกเป็น truncated signed distance function (TSDF) [5] โดยแบ่งพื้นที่เป็นลูกบาศก์เล็ก ๆ เรียกว่า voxel แต่ละ voxel เก็บระยะถึงพื้นผิวที่ใกล้ที่สุดที่สังเกตได้ เป็นบวกเมื่ออยู่หน้าพื้นผิวและเป็นลบเมื่ออยู่หลังพื้นผิว ตัดทิ้ง (truncate) เมื่อไกลเกินไม่กี่ voxel แล้วเฉลี่ยค่านี้จากทุกเฟรมที่มองเห็น voxel นั้น จากนั้นจึงสกัดพื้นผิวตรงตำแหน่งที่ค่าเฉลี่ยเปลี่ยนเครื่องหมาย ด้วยอัลกอริทึม marching cubes [33] Kinect-Fusion [34] ทำให้การรวมแบบนี้ทำงานได้แบบเรียลไทม์ กับความลึกจาก Kinect และงานนี้ใช้การทำงานที่มีอยู่ใน Open3D [35] การเฉลี่ยช่วยลดสัญญาณรบกวนที่สุ่มเปลี่ยนไปในแต่ละเฟรม แต่เฟรมที่มีสเกลไม่ตรงกันจะวางผนังเดียวกันไว้ที่ระยะต่างกัน ค่าเฉลี่ยจึงทำให้ผนังเบลอหรือหนาขึ้น ความคงที่ของสเกลระหว่างเฟรม ซึ่งตัวชี้วัดรายภาพไม่ได้วัด จึงกำหนดคุณภาพของห้อง นอกจากนี้ การรวมแบบ TSDF ไม่ขึ้นกับว่าความลึกเป็นเมตรนั้นมาจากแหล่งใด จึงเป็นขั้นตอนคงที่ที่ยุติธรรมกับแหล่งความลึกทุกแหล่ง

ส่วนระบบสร้างแบบจำลองที่เรียนรู้ทั้งกระบวนการ (learned reconstruction) จะแทนที่บางขั้นตอนข้างต้น ด้วยโครงข่ายประสาท

เทียม Atlas [11] ทำนาย TSDF โดยตรง จากคุณลักษณะของภาพหลายภาพที่รู้ท่าทางกล้อง NeuralRecon [12] ทำแบบเดียวกันทีละส่วนและแบบเรียลไทม์ และ SimpleRecon [13] ประเมินความลึกจากหลายเฟรมข้างเคียง ก่อนรวมด้วยวิธีดั้งเดิม ทดงานประเมินผลบน ScanNet [36] ซึ่งเป็นชุดการสแกนภาพสีและความลึกในอาคารขนาดใหญ่ แต่ละงานต้องใช้หลายเฟรมต่อการทำนายหนึ่งครั้ง และใช้โครงข่ายที่ฝึกมาสำหรับกระบวนการของตนเอง จึงตอบคำถามต่างจากงานนี้ ซึ่งถามว่าโมเดลจากภาพเดียวให้ห้องแบบใด เมื่อส่วนอื่นของกระบวนการไม่เปลี่ยน งานนี้จึงไม่เปรียบเทียบกับงานกลุ่มนี้

E. การวัดคุณภาพของแบบจำลองห้อง

แบบจำลองห้องที่สร้างได้จะเทียบกับพื้นผิวอ้างอิงผ่านระยะระหว่างจุดที่สุ่มบนพื้นผิวทั้งสอง Chamfer distance [6] เฉลี่ยระยะจากแต่ละจุดถึงจุดที่ใกล้ที่สุดของอีกพื้นผิวทั้งสองทิศทาง ส่วน Tanks and Temples [18] กำหนดระยะเกณฑ์ไว้ แล้วรายงานความแม่นยำ (precision) คือสัดส่วนของพื้นผิวที่สร้างได้ที่อยู่ภายในระยะเกณฑ์จากพื้นผิวอ้างอิง ความครบถ้วน (recall) คือสัดส่วนของพื้นผิวอ้างอิงที่อยู่ภายในระยะเกณฑ์จากพื้นผิวที่สร้างได้ และค่าเฉลี่ยฮาร์มอนิกของทั้งสอง คือ F-score ระยะเกณฑ์ทำให้คะแนนผูกกับการใช้งาน ซึ่งเป็นวิธีที่พบทั่วไปใช้เชื่อมระยะ 2, 5 และ 10 ซม. กับงานวัดเพื่อปรับปรุงห้อง งานวางเฟอร์นิเจอร์ และงานดูภาพรวมของห้อง สำหรับการวัดรายเฟรม งานนี้ใช้ AbsRel และ within-1.25 $\times$ จากงานด้านการประมาณความลึกจากภาพเดียว [7]

F. ตำแหน่งของงานวิจัยนี้

โดยสรุป งานก่อนหน้ารายงานความแม่นยำรายภาพของโมเดลความลึกบนชุดทดสอบมาตรฐาน ปรับโมเดลเมตริกด้วยข้อมูลกำกับจากภาพสังเคราะห์หรือจากเซนเซอร์ของชุดข้อมูลสาธารณะ ป้อน LiDAR ของอุปกรณ์พกพาเข้าโมเดลขณะใช้งาน หรือทดสอบตัว LiDAR ของอุปกรณ์พกพาเองเทียบกับวิธีสำรวจ เราไม่พบงานที่รวมประเด็นเหล่านี้ไว้แบบงานนี้ กล่าวคือ ใช้ LiDAR ของอุปกรณ์ผู้บริโภคเป็นครูเฉพาะตอนฝึก เปรียบเทียบกับการใช้เครื่องสแกนเลเซอร์ระดับงานสำรวจเป็นครูบนห้องชุดเดียวกัน และตัดสินใจด้วยค่าอ้างอิงจากเลเซอร์ที่เป็นอิสระ ทั้งเป็นเซนติเมตรบนแบบจำลองห้องและแบบรายเฟรม

เอกสารอ้างอิง

- [1] L. Yang, B. Kang, Z. Huang, Z. Zhao, X. Xu, J. Feng, and H. Zhao, "Depth anything V2," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 37, 2024.
- [2] FARO Technologies, "FARO Focus laser scanners," <https://www.faro.com/en/Products/Hardware/Focus-Laser-Scanners>, accessed 2026-09-29.
- [3] G. Baruch, Z. Chen, A. Dehghan, T. Dimry, Y. Feigin, P. Fu, T. Gebauer, B. Joffe, D. Kurz, A. Schwartz, and E. Shulman, "ARKitScenes: A diverse real-world dataset for 3D indoor scene understanding using mobile RGB-D data," in *Proc. Neural Information Processing Systems Track on Datasets and Benchmarks*, 2021.
- [4] R. Ranftl, A. Bochkovskiy, and V. Koltun, "Vision transformers for dense prediction," in *Proc. IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021, pp. 12 179–12 188.
- [5] B. Curless and M. Levoy, "A volumetric method for building complex models from range images," in *Proc. SIGGRAPH*, 1996, pp. 303–312.
- [6] H. Fan, H. Su, and L. J. Guibas, "A point set generation network for 3D object reconstruction from a single image," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 605–613.
- [7] D. Eigen, C. Puhrsch, and R. Fergus, "Depth map prediction from a single image using a multi-scale deep network," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 27, 2014, pp. 2366–2374.

- [8] Apple Inc., "RoomPlan – apple developer documentation," <https://developer.apple.com/documentation/roomplan>, 2022, accessed 2026-09-17.
- [9] R. Ranftl, K. Lasinger, D. Hafner, K. Schindler, and V. Koltun, "Towards robust monocular depth estimation: Mixing datasets for zero-shot cross-dataset transfer," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 44, no. 3, pp. 1623–1637, 2022.
- [10] L. Yang, B. Kang, Z. Huang, X. Xu, J. Feng, and H. Zhao, "Depth anything: Unleashing the power of large-scale unlabeled data," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024, pp. 10371–10381.
- [11] Z. Murez, T. van As, J. Bartolozzi, A. Sinha, V. Badrinarayanan, and A. Rabinovich, "Atlas: End-to-end 3D scene reconstruction from posed images," in *Proc. European Conference on Computer Vision (ECCV)*, 2020, pp. 414–431.
- [12] J. Sun, Y. Xie, L. Chen, X. Zhou, and H. Bao, "NeuralRecon: Real-time coherent 3D reconstruction from monocular video," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021, pp. 15 598–15 607.
- [13] M. Sayed, J. Gibson, J. Watson, V. Prisacariu, M. Firman, and C. Godard, "SimpleRecon: 3D reconstruction without 3D convolutions," in *Proc. European Conference on Computer Vision (ECCV)*, 2022, pp. 1–19.
- [14] S. F. Bhat, R. Birkel, D. Wofk, P. Wonka, and M. Müller, "ZoeDepth: Zero-shot transfer by combining relative and metric depth," *arXiv preprint arXiv:2302.12288*, 2023.
- [15] A. Bochkovskii, A. Delaunoy, H. Germain, M. Santos, Y. Zhou, S. R. Richter, and V. Koltun, "Depth pro: Sharp monocular metric depth in less than a second," in *ICLR*, 2025.
- [16] M. Roberts, J. Ramapuram, A. Ranjan, A. Kumar, M. A. Bautista, N. Paczan, R. Webb, and J. M. Susskind, "Hypersim: A photorealistic synthetic dataset for holistic indoor scene understanding," in *Proc. IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021, pp. 10 892–10 902.
- [17] F. Wilcoxon, "Individual comparisons by ranking methods," *Biometrics Bulletin*, vol. 1, no. 6, pp. 80–83, 1945.
- [18] A. Knapitsch, J. Park, Q.-Y. Zhou, and V. Koltun, "Tanks and temples: Benchmarking large-scale scene reconstruction," *ACM Transactions on Graphics*, vol. 36, no. 4, pp. 78:1–78:13, 2017.
- [19] R. Hartley and A. Zisserman, *Multiple View Geometry in Computer Vision*, 2nd ed. Cambridge University Press, 2004.
- [20] N. Silberman, D. Hoiem, P. Kohli, and R. Fergus, "Indoor segmentation and support inference from RGBD images," in *Proc. European Conference on Computer Vision (ECCV)*, 2012, pp. 746–760.
- [21] A. Geiger, P. Lenz, and R. Urtasun, "Are we ready for autonomous driving? The KITTI vision benchmark suite," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2012, pp. 3354–3361.
- [22] W. Yin, C. Zhang, H. Wang, S. Niklaus, L. Mai, S. Chen, and C. Shen, "Metric3D: Towards zero-shot metric 3D prediction from a single image," in *Proc. IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023, pp. 9043–9053.
- [23] L. Piccinelli, Y.-H. Yang, C. Sakaridis, M. Segu, S. Li, L. Van Gool, and F. Yu, "UniDepth: Universal monocular metric depth estimation," in *CVPR*, 2024.
- [24] M. Oquab, T. Darcet, T. Moutakanni, H. Vo, M. Szafraniec, V. Khali-dov, P. Fernandez, D. Haziza, F. Massa, A. El-Nouby et al., "DINOv2: Learning robust visual features without supervision," *Transactions on Machine Learning Research*, 2024.
- [25] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, "An image is worth 16x16 words: Transformers for image recognition at scale," in *Proc. International Conference on Learning Representations (ICLR)*, 2021.
- [26] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson, "How transferable are features in deep neural networks?" in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 27, 2014, pp. 3320–3328.
- [27] G. Luetzenburg, A. Kroon, and A. A. Bjørk, "Evaluation of the Apple iPhone 12 Pro LiDAR for an application in geosciences," *Scientific Reports*, vol. 11, p. 22221, 2021.
- [28] A. Spreafico, F. Chiabrando, L. Teppati Losè, and F. Giulio Tonolo, "The iPad Pro built-in LiDAR sensor: 3D rapid mapping tests and quality assessment," *The International Archives of the Photogram-metry, Remote Sensing and Spatial Information Sciences*, vol. XLIII-B1-2021, pp. 63–69, 2021.
- [29] H. Lin, S. Peng, J. Chen, S. Peng, J. Sun, M. Liu, H. Bao, J. Feng, X. Zhou, and B. Kang, "Prompting depth anything for 4K resolution accurate metric depth estimation," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2025.
- [30] T. Qin, P. Li, and S. Shen, "VINS-Mono: A robust and versatile monocular visual-inertial state estimator," *IEEE Transactions on Robotics*, vol. 34, no. 4, pp. 1004–1020, 2018.
- [31] K. Tateno, F. Tombari, I. Laina, and N. Navab, "CNN-SLAM: Real-time dense monocular SLAM with learned depth prediction," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 6243–6252.
- [32] Z. Yu, S. Peng, M. Niemeyer, T. Sattler, and A. Geiger, "MonoSDF: Exploring monocular geometric cues for neural implicit surface reconstruction," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 35, 2022.
- [33] W. E. Lorensen and H. E. Cline, "Marching cubes: A high resolution 3D surface construction algorithm," in *Proc. SIGGRAPH*, 1987, pp. 163–169.
- [34] R. A. Newcombe, S. Izadi, O. Hilliges, D. Molyneaux, D. Kim, A. J. Davison, P. Kohli, J. Shotton, S. Hodges, and A. Fitzgibbon, "KinectFusion: Real-time dense surface mapping and tracking," in *Proc. IEEE International Symposium on Mixed and Augmented Reality (ISMAR)*, 2011, pp. 127–136.
- [35] Q.-Y. Zhou, J. Park, and V. Koltun, "Open3D: A modern library for 3D data processing," *arXiv preprint arXiv:1801.09847*, 2018.
- [36] A. Dai, A. X. Chang, M. Savva, M. Halber, T. Funkhouser, and M. Nießner, "ScanNet: Richly-annotated 3D reconstructions of indoor scenes," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 2432–2443.