

สอนหน่วยเมตรให้โมเดลความลึกจากภาพเดี่ยวด้วย LiDAR ของโทรศัพท์เอง: เปรียบเทียบ Depth Anything V2 แบบ fine-tune กับ แบบ pretrained สำหรับการสร้างแบบจำลองห้อง โดยวัด เทียบกับ laser scanner

Author Name
Affiliation
email@example.com

บทคัดย่อ— โทรศัพท์ส่วนใหญ่ไม่มี LiDAR จึงต้องสแกนห้องด้วยการประมาณความลึกจากภาพเดี่ยว แต่โมเดลสำเร็จรูปที่ให้ผลเป็นเมตร เช่น Depth Anything V2 (DA-v2) Metric-Indoor [1] ซึ่งฝึกด้วยภาพสังเคราะห์ ทำให้ห้องที่สร้างได้คลาดเคลื่อน 54.3 ซม. งานวิจัยนี้ศึกษาว่าการปรับจูน (fine-tune) โมเดลดังกล่าวด้วยความลึกจาก LiDAR ของโทรศัพท์เอง โดยใช้เครื่องสแกนเลเซอร์ ทำให้แม่นยำกว่าโมเดลเดิมหรือไม่ เมื่อวัดเทียบกับเครื่องสแกนเลเซอร์ Faro Focus S70 [2] ซึ่งเป็นค่าอ้างอิงของชุดข้อมูล ARKitScenes [3] โดยปรับจูนเฉพาะส่วน DPT head [4] (ตัวถอดรหัสความลึก โดยตรงส่วนเข้ารหัสภาพไว้) ด้วยความลึกจาก LiDAR ของ iPad บน 24 ห้อง ได้โมเดล FT-LiDAR-24 แล้วเปรียบเทียบกับโมเดลเดิมในกระบวนการเดียวกัน คือรวมความลึกรายเฟรมเป็นปริมาตร TSDF (truncated signed distance function) [5] แล้วสร้างเป็นพื้นผิวสามมิติ โดยให้แหล่งความลึกเป็นตัวแปรเดียว บนห้องที่ไม่เคยใช้ฝึก ได้แก่ 6 ห้องที่มีแบบจำลองอ้างอิงจากเครื่องสแกนเลเซอร์ และอีก 20 ห้องที่ประเมินรายเฟรม ผลคือ FT-LiDAR-24 ลดค่า Chamfer distance [6] (ระยะเฉลี่ยถึงจุดที่ใกล้ที่สุดระหว่างพื้นผิวที่สร้างได้กับพื้นผิวอ้างอิง วัดทั้งสองทิศ) จาก 54.3 ซม. เหลือ 15.7 ซม. (ดีขึ้น 3.5 เท่า และดีขึ้นทุกห้อง) และลดค่า AbsRel [7] (ความคลาดเคลื่อนสัมพัทธ์เฉลี่ยของความลึก) จาก 0.410 เหลือ 0.130 (ดีขึ้น 19 จาก 20 ห้อง) โดยไม่ต้องปรับเทียบหรือใช้เซนเซอร์ขณะใช้งาน และการใช้เครื่องสแกนเลเซอร์เป็นครูไม่ได้ดีกว่าอย่างวัดได้ ความคลาดเคลื่อนที่เลือกมาจากสเกลที่กว้างตามมุมมองของแต่ละเฟรม ซึ่งการปรับจูนขัดไม่ได้ จึงยังดีกว่า LiDAR ของ iPad (3.0 ซม.) และยังไปถึงระดับความแม่นยำสำหรับดูภาพรวม (พื้นผิวของห้องอย่างน้อย 90% อยู่ภายใน 10 ซม.)

คำสำคัญ—การประมาณความลึกจากภาพเดี่ยว (monocular depth estimation), การเรียนรู้แบบถ่ายโอน (transfer learning), ความลึกแบบเมตริก (metric depth), การใช้ LiDAR เป็นข้อมูลสอน (LiDAR supervision), การรวมความลึกแบบ TSDF (TSDF fusion), การสร้างแบบจำลองสามมิติของห้อง (3D room reconstruction), ARKitScenes

I. บทนำ

การสแกนห้องเป็นแบบจำลองสามมิติเป็นความสามารถที่มีอยู่แล้วใน iPhone Pro และ iPad Pro (เช่น Apple RoomPlan [8]) โดยอาศัยเซนเซอร์ LiDAR วัดความลึกเป็นหน่วยเมตร แต่อุปกรณ์ที่มี LiDAR เป็นส่วนน้อย iPhone รุ่นที่ไม่ใช่ Pro และโทรศัพท์ Android แทบทุกรุ่นไม่มีเซนเซอร์นี้ ทางเลือกของอุปกรณ์เหล่านี้คือการประมาณความลึกจากภาพเดี่ยว (monocular depth estimation) คือการทำนายความลึกจากภาพสีเพียงภาพเดี่ยว ซึ่งพัฒนาอย่างรวดเร็วตั้งแต่ MiDaS [9] จนถึง Depth Anything [1], [10] ทีมพัฒนาผลิตภัณฑ์จึงต้องรู้ว่า **หากใช้โมเดลจากภาพเดี่ยวแทน LiDAR ห้องที่ได้จะคลาดเคลื่อนกี่เซนติเมตร และยังใช้งานแบบใดบ้าง** เกณฑ์วัดมาตรฐานแบบรายภาพ [7] ซึ่งเฉลี่ย

ความคลาดเคลื่อนของความลึกบนพิกเซลของภาพแต่ละภาพ ตอบคำถามนี้ไม่ได้ และระบบสร้างแบบจำลองแบบครบวงจร (end-to-end) [11]–[13] ก็ตอบไม่ได้ เพราะออกแบบกระบวนการทั้งหมดรอบโมเดลของตนเอง

โมเดลรุ่น ใหม่ บาง ตัว ให้ ความ ลึก เป็น เมตร ได้ โดยตรง [1], [14], [15] แต่ฝึกด้วยภาพที่ไม่ได้มาจากกล้องโทรศัพท์ เช่น DA-v2 Metric-Indoor ฝึกด้วยภาพห้องสังเคราะห์จากชุดข้อมูล Hypersim [16] และในการทดลองของเรา ห้องที่สร้างด้วย DA-v2 Metric-Indoor คลาดเคลื่อนเฉลี่ย 54.3 ซม. วิธีแก้โดยตรงคือการปรับจูน (fine-tune) โมเดลด้วยความลึกจากอุปกรณ์เป้าหมาย คำถามคือข้อมูลสอน (label) นี้จะมาจากไหน ระหว่างเครื่องสแกนเลเซอร์ระดับงานสำรวจ [2] ซึ่งผู้พัฒนาแอปเพียงไม่กี่รายมีใช้ กับ LiDAR ที่มีอยู่แล้วในอุปกรณ์รุ่น Pro ซึ่งแอปเก็บความลึกได้ระหว่างการใช้งานปกติ หากวิธีหลังได้ผล อุปกรณ์ที่มี LiDAR ก็จะเป็นครูสอนอุปกรณ์ที่ไม่มี LiDAR ได้

งานวิจัยนี้จึงตั้งคำถามว่า DA-v2 Metric-Indoor ที่ปรับจูนด้วยความลึกจาก LiDAR ของ iPad โดยใช้เครื่องสแกนเลเซอร์ในการฝึก แม่นยำกว่าโมเดลเดิมที่ไม่ได้ปรับจูนหรือไม่ เมื่อวัดเทียบกับเครื่องสแกนเลเซอร์ Faro ซึ่งเป็นค่าอ้างอิงของชุดข้อมูล ARKitScenes [3] บนห้องที่ไม่เคยใช้ฝึก โดยมีวัตถุประสงค์ 4 ข้อ ได้แก่ (1) ปรับจูนโมเดลด้วยความลึกจาก LiDAR ของ iPad จำนวน 24 ห้อง ได้โมเดล FT-LiDAR-24 แล้วเปรียบเทียบกับโมเดลเดิมบนห้องที่ไม่เคยใช้ฝึก โดยถือว่าดีกว่าเมื่อค่าเฉลี่ยความคลาดเคลื่อนต่ำกว่า และผลต่างรายห้องมีนัยสำคัญทางสถิติที่ระดับ 5% ตามการทดสอบ Wilcoxon signed-rank แบบ exact [17] (2) วัดว่าแหล่งของข้อมูลสอนมีผลหรือไม่ โดยเปรียบเทียบข้อมูลสอนจาก Faro กับจาก LiDAR บน 10 ห้องเดียวกัน (FT-Faro-10 กับ FT-LiDAR-10) เปรียบเทียบข้อมูลสอนจาก LiDAR 10 ห้องกับ 24 ห้อง และเปรียบเทียบกับโมเดลที่ใช้ความยาวโฟกัสของกล้องแทนข้อมูลสอนจากโดเมนเป้าหมาย (Depth Pro [15]) (3) ระบุตำแหน่งของ FT-LiDAR-24 เทียบกับแหล่งความลึกที่ใช้ได้ขณะใช้งาน ได้แก่ LiDAR ของ iPad และโมเดลความลึกสัมพัทธ์ที่ปรับสเกลรายเฟรมด้วยจุดเบาบาง (sparse points) หรือปรับสเกลครั้งเดียวต่อห้อง และ (4) หาที่มาของความคลาดเคลื่อนที่การปรับจูนแก้ไม่ได้ โดยหาสเกลความลึกที่เหมาะสมกับแต่ละเฟรม แล้วทดสอบว่าสเกลนั้นเปลี่ยนตามเวลา ซึ่งบ่งชี้การสะสมความคลาดเคลื่อน (drift) หรือเปลี่ยนตามสิ่งที่อยู่ในภาพ

ทุกการเปรียบเทียบวัดสองแบบ แบบแรกวัดเป็นแบบจำลองห้อง

(mesh) ด้วย Chamfer distance [6] คือระยะเฉลี่ยจากแต่ละพื้นผิวถึงจุดที่ใกล้ที่สุดของอีกพื้นผิว และด้วย F-score ที่ 5 ซม. (F@5 cm) [18] ซึ่งรวมสัดส่วนของพื้นผิวที่สร้างได้ที่อยู่ภายใน 5 ซม. จากพื้นผิวอ้างอิง กับสัดส่วนของพื้นผิวอ้างอิงที่ถูกสร้างขึ้นภายใน 5 ซม. แบบที่สองวัดรายเฟรมด้วย AbsRel [7] คือความคลาดเคลื่อนสัมพัทธ์เฉลี่ยของความลึก และด้วยสัดส่วนของพิกเซลที่ความลึกที่ทำนายต่างจากค่าจริงไม่เกิน 1.25 เท่า (ไม่ว่าจะมากหรือน้อยกว่าค่าจริง) ซึ่งเรียกว่า within-1.25× [7] สำหรับวัตถุประสงค์ข้อ (3) สัดส่วนของพื้นผิวอ้างอิงที่ถูกสร้างขึ้นภายใน 2, 5 และ 10 ซม. ใช้แทนความแม่นยำที่งานวัดเพื่อปรับปรุงห้อง งานวางเฟอร์นิเจอร์ และงานดูภาพรวมของห้องต้องการ ตามลำดับ และถือว่ารองรับงานนั้นได้เมื่อสัดส่วนนี้ถึง 90 %

ขอบเขตของงานวิจัยมีดังนี้ ข้อมูลเป็นห้องในบ้านจากชุดข้อมูล ARKitScenes ที่ถ่ายด้วย iPad Pro รุ่นเดียว (ภาพสีขนาด 640×480 พิกเซล และความลึกจาก LiDAR ขนาด 256×192 พิกเซล) ค่าอ้างอิงคือความลึกจาก Faro ที่มากับชุดข้อมูล และไม่ใช่ LiDAR ของ iPad เป็นค่าอ้างอิง การปรับรุ่นทำเฉพาะส่วน DPT head [4] ซึ่งเป็นตัวถอดรหัสความลึกของ DA-v2 Metric-Indoor ขนาด Large ด้วยสูตรการฝึกเดียว โดยตรงส่วนเข้ารหัสภาพไว้ ประเมินผลบนห้องทดสอบ 6 ห้องทั้งแบบแบบจำลองห้องและแบบรายเฟรม และอีก 20 ห้องแบบรายเฟรมเท่านั้น ทุกห้องไม่ซ้ำกับห้องที่ใช้ฝึกหรือใช้เลือก checkpoint ทุกแหล่งความลึกผ่านกระบวนการแบบออฟไลน์เดียวกัน คือความลึกรายเฟรม การปรับสเกล การรวมเป็นปริมาตร TSDF (truncated signed distance function) [5] และการสร้างพื้นผิว แหล่งความลึกจึงเป็นตัวแปรเดียว นอกจากนี้ ทุกแหล่งและค่าอ้างอิงใช้ตำแหน่งกล้องชุดเดียวกัน ซึ่งบันทึกโดย ARKit ความคลาดเคลื่อนของตำแหน่งกล้องจึงไม่อยู่ในผลการวัด สิ่งที่อยู่นอกขอบเขต ได้แก่ ระบบสร้างแบบจำลองที่เรียนรู้ทั้งกระบวนการ [11]–[13] กล้องโทรศัพท์รุ่นอื่นรวมถึง Android การประมวลผลแบบเรียลไทม์บนอุปกรณ์ และการประมาณตำแหน่งกล้อง

ประโยชน์ที่คาดว่าจะได้รับสอดคล้องกับวัตถุประสงค์ที่ละข้อ ข้อแรก ผู้พัฒนาแอปจะรู้ว่ามีข้อมูลที่เก็บได้อะไรแล้ว จากผู้ใช้อุปกรณ์รุ่น Pro ช่วยให้ทราบขอบเขตของอุปกรณ์ที่ไม่มี LiDAR ดีขึ้นหรือไม่ โดยไม่ต้องเปรียบเทียบหรือใช้เซ็นเซอร์เพิ่มขณะใช้งาน ข้อสอง จะรู้ว่าการสร้างข้อมูลสอนจำเป็นต้องใช้เครื่องสแกนเลเซอร์หรือไม่ ข้อสาม จะรู้ว่ามีอุปกรณ์ที่ไม่มี LiDAR รองรับงานแบบใดบ้าง พร้อมได้กระบวนการที่ประเมินแหล่งความลึกใหม่ได้ด้วยการแก้ค่าตั้งค่าเพียงรายการเดียว และข้อสี่ จะรู้ว่าการลงทุนพัฒนาส่วนใดต่อ ระหว่างสเกลรายเฟรม ข้อมูลฝึก หรือขนาดโมเดล

เอกสารอ้างอิง

- [1] L. Yang, B. Kang, Z. Huang, Z. Zhao, X. Xu, J. Feng, and H. Zhao, "Depth anything V2," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 37, 2024.
- [2] FARO Technologies, "FARO Focus laser scanners," <https://www.faro.com/en/Products/Hardware/Focus-Laser-Scanners>, accessed 2026-09-29.
- [3] G. Baruch, Z. Chen, A. Dehghan, T. Dimry, Y. Feigin, P. Fu, T. Gebauer, B. Joffe, D. Kurz, A. Schwartz, and E. Shulman, "ARKitScenes: A diverse real-world dataset for 3D indoor scene understanding using mobile RGB-D data," in *Proc. Neural Information Processing Systems Track on Datasets and Benchmarks*, 2021.
- [4] R. Ranftl, A. Bochkovskiy, and V. Koltun, "Vision transformers for dense prediction," in *Proc. IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021, pp. 12 179–12 188.
- [5] B. Curless and M. Levoy, "A volumetric method for building complex models from range images," in *Proc. SIGGRAPH*, 1996, pp. 303–312.

- [6] H. Fan, H. Su, and L. J. Guibas, "A point set generation network for 3D object reconstruction from a single image," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 605–613.
- [7] D. Eigen, C. Puhrsch, and R. Fergus, "Depth map prediction from a single image using a multi-scale deep network," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 27, 2014, pp. 2366–2374.
- [8] Apple Inc., "RoomPlan – apple developer documentation," <https://developer.apple.com/documentation/roomplan>, 2022, accessed 2026-09-17.
- [9] R. Ranftl, K. Lasinger, D. Hafner, K. Schindler, and V. Koltun, "Towards robust monocular depth estimation: Mixing datasets for zero-shot cross-dataset transfer," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 44, no. 3, pp. 1623–1637, 2022.
- [10] L. Yang, B. Kang, Z. Huang, X. Xu, J. Feng, and H. Zhao, "Depth anything: Unleashing the power of large-scale unlabeled data," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024, pp. 10 371–10 381.
- [11] Z. Murez, T. van As, J. Bartolozzi, A. Sinha, V. Badrinarayanan, and A. Rabinovich, "Atlas: End-to-end 3D scene reconstruction from posed images," in *Proc. European Conference on Computer Vision (ECCV)*, 2020, pp. 414–431.
- [12] J. Sun, Y. Xie, L. Chen, X. Zhou, and H. Bao, "NeuralRecon: Real-time coherent 3D reconstruction from monocular video," in *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021, pp. 15 598–15 607.
- [13] M. Sayed, J. Gibson, J. Watson, V. Prisacariu, M. Firman, and C. Godard, "SimpleRecon: 3D reconstruction without 3D convolutions," in *Proc. European Conference on Computer Vision (ECCV)*, 2022, pp. 1–19.
- [14] S. F. Bhat, R. Birkel, D. Wofk, P. Wonka, and M. Müller, "ZoeDepth: Zero-shot transfer by combining relative and metric depth," *arXiv preprint arXiv:2302.12288*, 2023.
- [15] A. Bochkovskii, A. Delaunoy, H. Germain, M. Santos, Y. Zhou, S. R. Richter, and V. Koltun, "Depth pro: Sharp monocular metric depth in less than a second," in *ICLR*, 2025.
- [16] M. Roberts, J. Ramapuram, A. Ranjan, A. Kumar, M. A. Bautista, N. Paczan, R. Webb, and J. M. Susskind, "Hypersim: A photorealistic synthetic dataset for holistic indoor scene understanding," in *Proc. IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021, pp. 10 892–10 902.
- [17] F. Wilcoxon, "Individual comparisons by ranking methods," *Biometrics Bulletin*, vol. 1, no. 6, pp. 80–83, 1945.
- [18] A. Knapitsch, J. Park, Q.-Y. Zhou, and V. Koltun, "Tanks and temples: Benchmarking large-scale scene reconstruction," *ACM Transactions on Graphics*, vol. 36, no. 4, pp. 78:1–78:13, 2017.